Calidad perceptual de fotografías de smartphones

Estudio observacional de las asociaciones entre calificaciones perceptuales humanas, contenido de escena, metadatos de adquisición y descriptores digitales interpretables de fotografías.

Curso: Ciencia de Datos

Actividad: caracterización estadística del conjunto SPAQ

(Smartphone Photography Attribute and Quality)

Alumno: Carlos Mario Garzón

Docente: Fabian Camilo Castro

Maestría en Inteligencia Artificial ·

Universidad de La Salle

Bogotá

28 de octubre de 2026

Resumen

Se analizan 11.125 fotografías del conjunto Smartphone Photography Attribute and Quality (SPAQ) mediante análisis exploratorio de datos (EDA). La calidad perceptual se representa mediante la puntuación media de opinión (Mean Opinion Score, MOS), acompañada de cinco atributos evaluados por personas, nueve pesos de pertenencia a escenas, metadatos Exchangeable Image File Format (EXIF) y 68 descriptores computados sobre fotografías JPEG. Se reconocen 10.803 contenidos únicos mediante huellas criptográficas SHA-256 y 322 parejas de archivos idénticos; 321 parejas tienen MOS diferentes. La asociación de rango más elevada entre un descriptor y MOS corresponde a la varianza del Laplaciano a escala 512 (ρ de Spearman = 0,736); 79 de 2.278 pares de descriptores presentan $|\rho| \geq 0{,}9$. Los resultados describen relaciones estadísticas, redundancia y sensibilidad a la escala, sin establecer causalidad ni rendimiento predictivo fuera de muestra.

1. Introducción

La evaluación de la calidad de fotografías producidas por smartphones combina factores de adquisición, procesamiento de la imagen, contenido visual y juicios humanos. El dataset Smartphone *Photography Attribute and Quality*, **SPAQ**, proporciona un índice de juicio humano, *Mean Opinion Score*, **MOS**, de esta calidad, el cual es un resultado perceptual. Cada imagen digital, por simplicidad llamada JPEG, registra información espacial y cromática resultante de la captura y del procesamiento digital; EXIF describe parcialmente condiciones y dispositivos. Fang et al. (2020) establecieron SPAQ como banco de referencia de calidad perceptual y estudiaron vínculos con contenido y metadatos.

Esta investigación surge, de forma general, al reflexionar sobre qué significa encontrar una asociación entre un descriptor interpretable y MOS cuando las características entre sí pueden ser redundantes, cambian con el tamaño de representación y presentan efectos condicionados por contenidos heterogéneos. Esta reflexión se dificulta al notar que dos archivos JPEG idénticos pueden contener MOS o pesos de escena discrepantes, por ejemplo una partición aleatoria por filas puede contar el mismo contenido tanto en entrenamiento como en prueba. Por tanto, una correlación elevada no implica que una familia aporte información adicional a otras, ni acredita generalización. El alcance empírico aquí es caracterizar esa estructura y sus limitaciones antes de estimar aportes incrementales y rendimiento predictivo en fases posteriores.

Pregunta de investigación. ¿En qué medida las características tonales, cromáticas, espaciales, regionales y multiescala extraídas de fotografías de smartphones, junto con los metadatos de adquisición, permiten caracterizar su asociación con la calidad perceptual MOS (Mean Opinion Score), y cómo varían dichas asociaciones según las escenas y la consistencia de las anotaciones?

Pregunta orientadora 1. ¿Qué asociaciones, redundancias y diferencias entre escalas presentan las familias de descriptores digitales respecto de MOS?

Pregunta orientadora 2. ¿Cómo varían las asociaciones según contenido de escena y condiciones de captura, y qué revelan los archivos idénticos con anotaciones discrepantes?

Pregunta orientadora 3. ¿Qué estructura y limitaciones del espacio de descriptores resultan pertinentes para un estudio posterior de agrupamientos no supervisados?

2. Objetivos

Objetivo general. Caracterizar estadísticamente las relaciones entre descriptores digitales interpretables, metadatos de adquisición, contenido de escena y calidad perceptual MOS en SPAQ, considerando la integridad de sus anotaciones, la redundancia y la sensibilidad multiescala.

El alcance de este objetivo y de los objetivos específicos se verificará mediante los estadísticos, tablas y figuras presentados para el conjunto analizado.

Objetivo específico 1. Describir las distribuciones, la integridad y las asociaciones entre anotaciones humanas, descriptores digitales y metadatos en las 11.125 fotografías, con medidas estadísticas y evidencias visuales verificables.

Objetivo específico 2. Examinar la redundancia entre descriptores y sus variaciones según escala y contenido de escena, explicitando los tamaños muestrales y las limitaciones de interpretación.

Objetivo específico 3. Cuantificar las discrepancias de anotación entre contenidos idénticos y las incidencias de metadatos, delimitando su posible influencia sobre la interpretación y evaluación posterior de los datos.

Alcance temporal y verificación. Los cuatro objetivos se desarrollan con el conjunto de 11.125 observaciones de SPAQ y tienen como fecha de cumplimiento el 28 de octubre de 2026. Su cumplimiento se comprueba mediante estadísticas descriptivas y diagnósticos de integridad presentados en este informe y reproducidos en un cuaderno Jupyter presentado en anexo.

3. Conjunto de datos y variables

Dataset: SPAQ (Smartphone Photography Attribute and Quality).

Fuente académica identificada: Fang et al., “Perceptual Quality Assessment of Smartphone Photography”, CVPR 2020; repositorio de los autores https://github.com/h4nwei/SPAQ.

Fecha de extracción del dataset: 24 de octubre de 2026.

Licencia: MIT.

Las entradas usadas en este análisis son tres libros en formato Excel de Microsoft: MOS and Image attribute scores.xlsx, Scene category labels.xlsx y EXIF_tags.xlsx (dos hojas), además de archivos de las imágenes (en adelante, por simplicidad, denominados JPEG originales, o simplemente JPEG).

La unión por identificador reconcilia 11.125 registros; hay 10.803 contenidos binariamente distintos según SHA-256. Los 68 atributos de píxeles se derivan de las imágenes; su presencia en la tabla analítica no equivale a que formen parte del conjunto de anotaciones humanas original.

3.1. Descripción general del dataset

Se trata de un dataset presentado en el congreso CVPR (Conference on Computer Vision and Pattern Recognition) 2020, https://openaccess.thecvf.com/CVPR2020, con la finalidad académica de evaluar la calidad de fotografías obtenidas con celulares inteligentes tanto a través de factores técnicos de hardware/software como mediante estudios de percepción visual humana.

El conjunto contiene 11125 imágenes en resolución nativa, sin compresión ni reducción del mapa de pixels que afecte sus características nativas. Las fotos en su mayoría tienen resolución nativa de 4000 x 3000 pixeles, y algunas se encuentran con tamaño mínimo full HD (1920x1080). Las imágenes fueron capturadas en 66 teléfonos inteligentes diferentes, de un conjunto de 11 fabricantes.

La calidad de las imágenes recibió una puntuación humana (MOS, en escala de 1 a 10), con múltiples evaluadores por imagen. Para las imágenes se anotaron los siguientes atributos, brillo, colorido, contraste, nivel de ruido y nitidez. Además, las imágenes se clasificaron en nueve tipos de escenas, animal, paisaje urbano, personas, interiores, paisaje natural, escenas nocturnas, plantas, naturaleza muerta y otros. Cada fotografía contiene un set de metadatos exif.

La base maneja cinco atributos principales, brillo, colorido, contraste, nivel de ruido, nitidez (brightness, colorfulness, contrast, noisiness, sharpness).

Incluye un grupo de 1,000 imágenes capturadas exactamente bajo las mismas condiciones visuales intercalando los distintos teléfonos, ideal para comparar el rendimiento de procesamiento de color y algoritmos de una marca contra otra.

Familias de variables y significado estadístico

Lectura estadística del conjunto: 11.125 observaciones corresponden a 11.125 entradas de fotografías; sus bytes representan 10.803 contenidos diferentes según SHA-256, pues existen 322 pares duplicados. La variable respuesta MOS y las cinco valoraciones auxiliares Brightness, Colorfulness, Contrast, Noisiness y Sharpness son juicios humanos numéricos. Las nueve variables de escenas expresan membresías simultáneas, no clases nominales únicas. Los campos EXIF contienen atributos numéricos y categóricos del registro de adquisición; sus ausencias y valores sospechosos requieren diagnósticos separados. A partir de los JPEG se calcularon 68 descriptores de tono, color, estructura espacial y distintas escalas. La tabla analítica integra 153 campos de distintas procedencias, incluidos identificadores y variables de auditoría: no representa 153 predictores. Fuentes de comprobación: diccionario de datos de la sección 3.2, tablas join_cardinality.csv y missing_sentinel_audit.csv y manifiesto SHA-256 del notebook aprobado.

Tabla 1. Familias de variables y cautelas de interpretación. Fuente: cálculos propios sobre las anotaciones e imágenes originales de SPAQ.

Familia	Naturaleza	Interpretación y restricción
MOS	Cuantitativa; juicio humano agregado	Variable dependiente central; no equivale a calidad instrumental medida
Cinco ratings	Cuantitativas; valoraciones humanas	Brightness, Colorfulness, Contrast, Noisiness, Sharpness: análisis descriptivo, excluidas de predictores automáticos
Nueve pesos de escena	Cuantitativas discretizadas por fracciones de membresía	Cada categoría activa recibe 1/c; no son probabilidades de confianza ni clases exclusivas
EXIF	Mixtas; metadata nominal y cuantitativa	Unidades y sentinelas requieren verificación; disponibilidad puede depender de dispositivo
68 descriptores	Cuantitativas derivadas de JPEG	Tonales/cromáticas/espaciales/regionales/multiescala; proxies del resultado digital, no mediciones ópticas calibradas
ID/SHA	Identificadores técnicos	Sirven para unir registros y detectar contenidos repetidos; no predictores

3.2. Diccionario de datos

El diccionario agrupa variables que comparten definición y conserva sus nombres exactos. Los dominios indicados son los definidos por el instrumento o por la operación matemática; donde no hay información suficiente se señala «no documentado». Los identificadores, rutas, códigos de error, campos de integración y registros de trazabilidad se describen en el notebook, pero no son variables científicas adicionales. Se documentan por agrupación las definiciones compartidas, pero cada identificador de descriptor incluido en una agrupación designa una columna distinta de la tabla analítica.

Variable(s)	Tipo estadístico	Descripción funcional	Dominio / valores permitidos
MOS	Cuantitativa continua	Puntuación media de opinión: calidad perceptual evaluada por personas.	0–100 (escala SPAQ)
Brightness; Colorfulness; Contrast; Noisiness; Sharpness	Cuantitativas continuas	Cinco puntuaciones humanas auxiliares: brillo, color, contraste, ruido y nitidez percibidos.	0–100 (escala SPAQ)
Animal; Cityscape; Human; Indoor scene; Landscape; Night scene; Plant; Still-life; Others	Cuantitativas discretas (fracciones)	Nueve pertenencias de escena no exclusivas; una fotografía con c escenas activas aporta 1/c a cada una.	0 o 1/c, con c=1,…,9
Focal length	Cuantitativa continua	Distancia focal declarada en el Excel EXIF.	Milímetros; valores positivos; plausibilidad no verificada
F-number	Cuantitativa continua	Relación de apertura declarada en el Excel EXIF.	Números f positivos; plausibilidad no verificada
Exposure time	Cuantitativa continua	Tiempo de exposición declarado en el Excel EXIF.	Segundos positivos; extremos por verificar
ISO	Cuantitativa discreta	Sensibilidad ISO declarada en el Excel EXIF.	Valores ISO positivos; dominio de exportación no documentado
Brightness (Excel EXIF)	Cuantitativa continua	Brillo codificado en anotaciones EXIF; no equivale a juicio humano.	Dominio no acreditado; el cero no implica ausencia
Aperture value	Cuantitativa continua	Valor de apertura en codificación APEX.	Dominio de exportación no documentado
Time value	Cuantitativa continua	Valor temporal codificado en APEX.	Dominio de exportación no documentado
Sensitivity vaue	Cuantitativa continua	Valor de sensibilidad en la hoja APEX; nombre original preservado.	Dominio de exportación no documentado
Brightness value	Cuantitativa continua	Valor de brillo en codificación APEX.	Dominio de exportación no documentado
Flash (Excel EXIF)	Cualitativa nominal	Código de estado del flash declarado en Excel EXIF.	Códigos originales; equivalencias no documentadas
Time (Excel EXIF)	Cuantitativa continua	Componente temporal codificado; no es una fecha completa.	Dominio de exportación no documentado
Unnamed: 8 (Excel EXIF)	Tipo no verificado	Campo sin encabezado semántico en el Excel original.	Valores originales; dominio y significado no documentados
make; model; datetime; datetime_original	Cualitativas nominales	Fabricante, modelo y fechas de cabeceras EXIF de los JPEG.	Cadenas y fechas disponibles; dominio no documentado
focal_length (JPEG)	Cuantitativa continua	Distancia focal en EXIF nativo del JPEG.	Milímetros positivos o ausente
f_number (JPEG)	Cuantitativa continua	Número f en EXIF nativo del JPEG.	Positivo o ausente
exposure_time (JPEG)	Cuantitativa continua	Exposición en EXIF nativo del JPEG.	Segundos positivos o ausente
iso (JPEG)	Cuantitativa discreta	Sensibilidad en EXIF nativo del JPEG.	ISO positivo o ausente

Variable(s)	Tipo estadístico	Descripción funcional	Dominio / valores permitidos
brightness (JPEG)	Cuantitativa continua	BrightnessValue de EXIF nativo.	Escala EXIF/APEX; validación física pendiente
flash (JPEG)	Cualitativa nominal	Código de flash EXIF nativo.	Código entero de estado o ausente
s512_luma_mean; s256_luma_mean; s128_luma_mean	Cuantitativas continuas	Media de luma sRGB codificada a tres escalas (lado máximo 512, 256 y 128 píxeles).	[0,1]
s512_luma_std; s256_luma_std; s128_luma_std	Cuantitativas continuas	Desviación estándar de luma digital a tres escalas.	[0,0,5]
s512_gradient_mean; s256_gradient_mean; s128_gradient_mean	Cuantitativas continuas	Magnitud media del gradiente Sobel digital en tres escalas.	≥0
s512_laplacian_var; s256_laplacian_var; s128_laplacian_var	Cuantitativas continuas	Varianza de respuesta discreta del Laplaciano, en tres escalas.	≥0
s512_fft_high_fraction; s256_fft_high_fraction; s128_fft_high_fraction	Cuantitativas continuas	Fracción de energía espectral digital en altas frecuencias, a tres escalas.	[0,1]
s512_tile_mean_std; s256_tile_mean_std; s128_tile_mean_std	Cuantitativas continuas	Variación entre medias de bloques espaciales en tres escalas.	[0,0,5]
s512_entropy; s256_entropy; s128_entropy	Cuantitativas continuas	Entropía de histograma de luma digital en tres escalas.	[0,8] bits
analysis_width; analysis_height	Cuantitativas discretas	Dimensiones reales de la representación analizada.	Enteros positivos, píxeles
luma_median; luma_min; luma_max; luma_range; luma_skew; luma_p01; luma_p05; luma_p25; luma_p75; luma_p95; luma_p99	Cuantitativas continuas	Localización, amplitud, asimetría y percentiles de luma codificada.	[0,1], salvo luma_skew: real
near_black_01; near_black_05; near_black_10; near_white_245; near_white_250; near_white_254; channel_clip_245; channel_clip_250; channel_clip_254	Cuantitativas continuas	Proporciones de píxeles oscuros, claros o canales cercanos a saturación, según umbrales indicados.	[0,1]
gradient_p95; neighbor_absdiff; tile_gradient_cv	Cuantitativas continuas	Percentil de gradientes, diferencia local absoluta y variabilidad regional de gradientes.	≥0 (neighbor_absdiff en [0,1])
tile_dark_fraction; tile_bright_fraction; tile_entropy_mean; tile_entropy_std	Cuantitativas continuas	Proporciones de regiones oscuras/claras y estadísticos regionales de entropía.	Fracciones [0,1]; entropía en bits
fft_centroid; lbp_entropy	Cuantitativas continuas	Centroide espectral en frecuencia digital y entropía de patrones binarios locales.	≥0; límites definidos por implementación
hsv_s_mean; hsv_s_std; hsv_v_mean	Cuantitativas continuas	Estadísticos de saturación HSV y media de valor HSV.	[0,1]; desviación ≤0,5
rgb_r_mean; rgb_g_mean; rgb_b_mean; rgb_r_minus_g; rgb_b_minus_g	Cuantitativas continuas	Promedios de canales RGB codificados y diferencias medias entre canales.	Medias [0,1]; diferencias [−1,1]
lab_l_mean; lab_a_mean; lab_b_mean; lab_chroma_mean; lab_chroma_std; tile_chroma_std	Cuantitativas continuas	Estadísticos de color CIELAB y croma, global y por regiones.	L* [0,100]; a*,b* aproximadamente [−128,128]; croma ≥0
color_entropy; tile_color_entropy_std	Cuantitativas continuas	Entropía cromática RGB y dispersión de entropía entre regiones.	Entropía [0,9] bits; dispersión ≥0

4. Metodología

Se integraron por identificador las calificaciones perceptuales, las pertenencias de escena y dos hojas de metadatos EXIF del conjunto SPAQ. Cada archivo JPEG fue decodificado y su contenido comprobado mediante un resumen SHA-256, algoritmo criptográfico que permite detectar archivos idénticos byte a byte. Se calcularon 68 descriptores tonales, cromáticos, espaciales, regionales y multiescala, incluyendo estadísticas sobre canales sRGB y medidas digitales de gradientes y frecuencias. La exploración comprendió medidas de tendencia central y dispersión, cuantiles, detección de valores extremos mediante intervalo intercuartílico (IQR) y puntuaciones z, correlaciones de Pearson y Spearman, comparación ponderada entre escenas y prueba χ^2 sobre completitud de metadatos.

La unidad tabular corresponde a una fotografía anotada. La identidad de contenido se examinó por separado para distinguir observaciones distintas de archivos JPEG con bytes idénticos. Los valores extremos y potenciales códigos centinela se señalaron para revisión sin alterar las observaciones originales. Las asociaciones se interpretan como propiedades descriptivas del conjunto de datos y no como estimaciones de efecto causal.

El cálculo de correlaciones es exploratorio. Pearson resume asociación lineal y Spearman asociación monótona sobre rangos; los empates y la dependencia de filas por duplicación restringen el alcance de p nominales incluso con corrección BH. Los análisis de escenas utilizan pesos originales y soporte efectivo, no una asignación arbitraria por argmax. Los criterios IQR y $|z|>3$ identifican candidatos de inspección; no implican eliminación automática ni juicio de error. La prueba χ^2 se aplica solamente a categorías discretas justificadas (modelos agrupados por frecuencia y completitud binaria EXIF).

5. Distribución de MOS, valores ausentes y extremos

En las 11.125 fotografías, la puntuación media de opinión (MOS) tiene media 50,32, mediana 50,20, desviación estándar 20,90 y valores entre 2 y 96. La Figura 1 y la Tabla 2 muestran una distribución amplia y permiten compararla con las cinco evaluaciones humanas auxiliares. La cercanía entre media y mediana no basta para afirmar normalidad.

Las valoraciones de brillo (media 56,00), colorido (60,45) y contraste (57,28) describen dimensiones perceptuales diferentes. No son mediciones físicas ni deben emplearse como entradas de un predictor automático de MOS.

La asimetría y la curtosis, calculadas en las tablas siguientes, complementan la descripción de las distribuciones:

Puntuación humana	Asimetría	Curtosis (exceso)	N
mos	-0.048	-1.142	11125
brightness	-0.505	-0.091	11125
colorfulness	-0.528	0.079	11125
contrast	-0.405	-0.217	11125
noisiness	-0.102	-0.845	11125
sharpness	-0.027	-1.378	11125

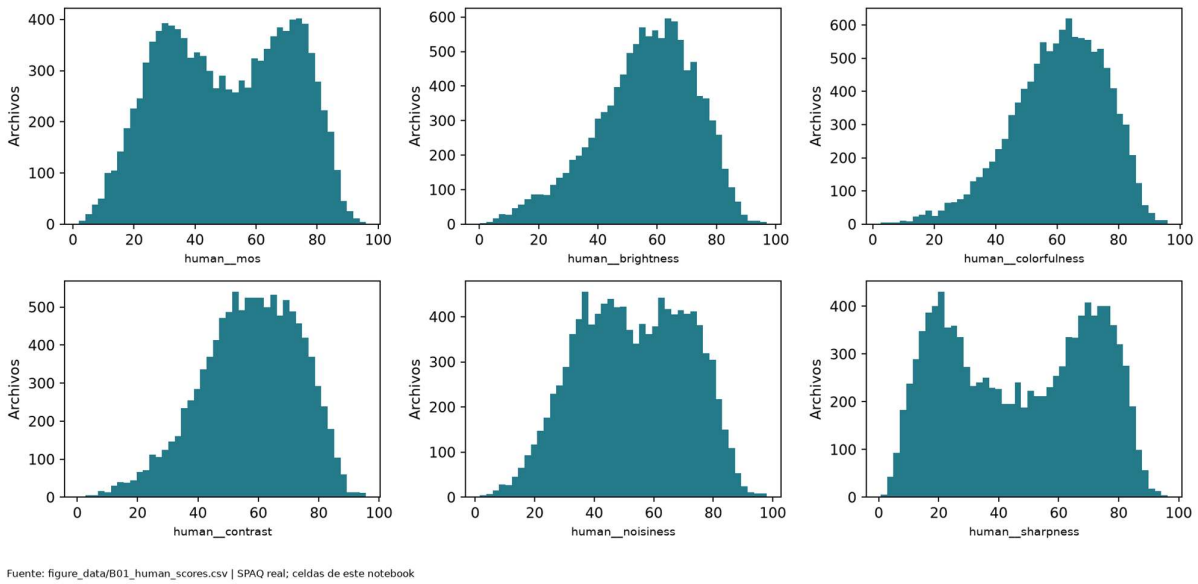


Figura 1. MOS y cinco evaluaciones humanas. Todas las observaciones; las cinco escalas auxiliares son anotaciones humanas. Fuente: cálculos propios sobre SPAQ.

Tabla 2. Distribución de MOS y puntuaciones humanas. Fuente: cálculos propios sobre las anotaciones e imágenes originales de SPAQ.

column	N_valid	mean	median	sd_ddof1	P25	P75
human__mos	11125	50.3179	50.2000	20.9023	32.4600	68.8200
human__brightness	11125	56.0046	57.6000	16.8149	45.5700	68.3000
human__colorfulness	11125	60.4545	61.8600	15.3254	50.6700	72.0000
human__contrast	11125	57.2844	58.3300	16.2383	46.6300	69.8000
human__noisiness	11125	52.9997	53.0000	18.3707	38.4300	68.2700
human__sharpness	11125	47.0470	47.5000	24.2272	24.1400	69.3800
scene__animal	11125	0.0101	0.0000	0.0924	0.0000	0.0000

El análisis distingue valores ausentes, extremos y posibles códigos especiales. Por ejemplo, 7.585 registros tienen Brightness EXIF igual a cero; sin evidencia adicional, ese valor no debe tratarse automáticamente como ausencia. También se examinaron los tiempos de exposición y sus unidades.

Los valores extremos se identificaron mediante la regla de 1,5 veces el intervalo intercuartílico y $|z| > 3$; se señalaron para revisión, sin eliminarlos.

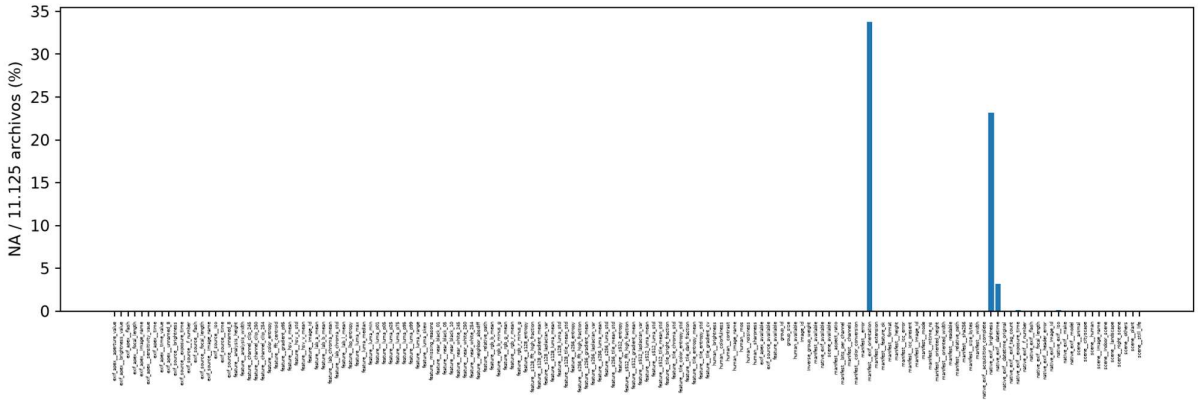
Variable	Fuera de 1,5 IQR	%	$\|z\| > 3$
mos	0	0.00%	0
brightness	102	0.92%	19
colorfulness	119	1.07%	52
contrast	53	0.48%	24
noisiness	0	0.00%	0
sharpness	0	0.00%	0

La tabla siguiente resume los campos con ausencias explícitas (N=11.125). Los porcentajes restantes y los valores sospechosos se conservan en las tablas de resultados del notebook.

Variable	N ausentes	% ausente
manifest__exif_orientation	3758	33.7798%
native_exif__datetime	354	3.1820%
native_exif__datetime_original	6	0.0539%
native_exif__f_number	5	0.0449%
native_exif__exposure_time	13	0.1169%
native_exif__iso	12	0.1079%
native_exif__brightness	2579	23.1820%
native_exif__flash	10	0.0899%

También se calcularon frecuencias absolutas y relativas de variables categóricas, como fabricante, completitud de adquisición y perfil de color.

Campo	Categoría	Frecuencia	Porcentaje
make	HUAWEI	3086	27.74%
make	Apple	2063	18.54%
make	vivo	1369	12.31%
acquisition_complete	True	8545	76.81%
acquisition_complete	False	2580	23.19%
icc_present	False	10771	96.82%
icc_present	True	354	3.18%



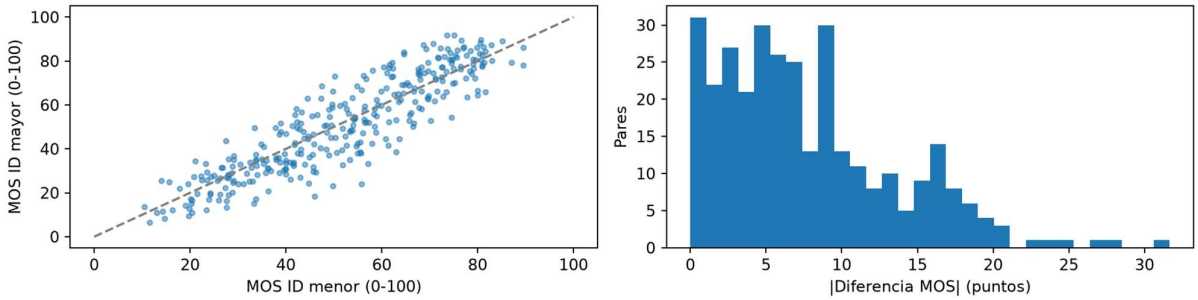
Fuente: data_dictionary.csv | SPAQ real; celdas de este notebook

Figura 2. Ausencia por variable. Se distinguen ausencias reconocidas de ceros o sentinelas candidatos; no se imputan datos en el estudio. Fuente: cálculos propios sobre SPAQ.

Se identificaron 76 cadenas de modelo de dispositivo, 2.580 registros con información de adquisición incompleta y 11 etiquetas de modelo que requieren comprobación. Estas incidencias no invalidan por sí solas las fotografías.

6. Identidad de contenido y consistencia de las anotaciones

Entre las 11.125 observaciones hay 10.803 contenidos únicos según SHA-256: se encontraron 322 pares de JPEG idénticos. En 321 pares difiere MOS (diferencia absoluta mediana de 6,575 y máxima de 31,66 puntos), y en 98 difieren las escenas anotadas. La identidad del archivo no garantiza, por tanto, que coincidan sus etiquetas (Figura 3). No es posible establecer aquí la causa de esas diferencias.



Fuente: eda_tables/duplicate_mos_disagreement.csv | SPAQ real; celdas de este notebook

Figura 3. Desacuerdo MOS en contenidos idénticos. Diferencias entre etiquetas en 322 pares de contenidos binariamente idénticos, no diferencias en píxeles. Fuente: cálculos propios sobre SPAQ.

Estos duplicados deben mantenerse en el mismo grupo cuando se dividan los datos para evaluar modelos. Las correlaciones también pueden variar según cómo se ponderen los contenidos repetidos; las puntuaciones discordantes no se promedian automáticamente.

7. Heterogeneidad del contenido de escena

Las nueve categorías de escena no son excluyentes. Si una fotografía pertenece a c categorías, aporta un peso 1/c a cada una. En 2.771 imágenes existe empate en el peso máximo, por lo que no se puede asignar una clase única sin una regla adicional. La Tabla 3 resume la distribución y los pesos por escena.

Las medias de MOS por escena describen grupos que se superponen. Su interpretación debe considerar el número de fotografías y los pesos de cada categoría; las diferencias observadas no prueban un efecto causal de la escena.

Tabla 3. Distribución y peso de categorías de escena. Fuente: cálculos propios sobre las anotaciones e imágenes originales de SPAQ.

scene	N_positive	weight_sum	kish_n_eff	MOS_weighted_mean
scene__animal	146	112.0000	130.6667	60.1889
scene__cityscape	3114	2331.7833	2784.2021	54.0828
scene__human	1589	1079.9500	1388.1357	53.3639
scene__indoor_scene	1150	798.9500	998.5169	47.3446
scene__landscape	1488	1216.0000	1360.3091	58.1156
scene__night_scene	969	806.8667	889.7808	37.9531
scene__plant	1776	1359.6666	1586.2183	52.9180
scene__still_life	3347	2910.1666	3128.5172	50.8605
scene__others	581	509.6167	544.9495	20.0633

La asociación entre un descriptor y MOS puede variar de una escena a otra. Este resultado aconseja comprobar posteriormente la estabilidad de los modelos entre tipos de contenido, especialmente cuando hay pocos ejemplos.

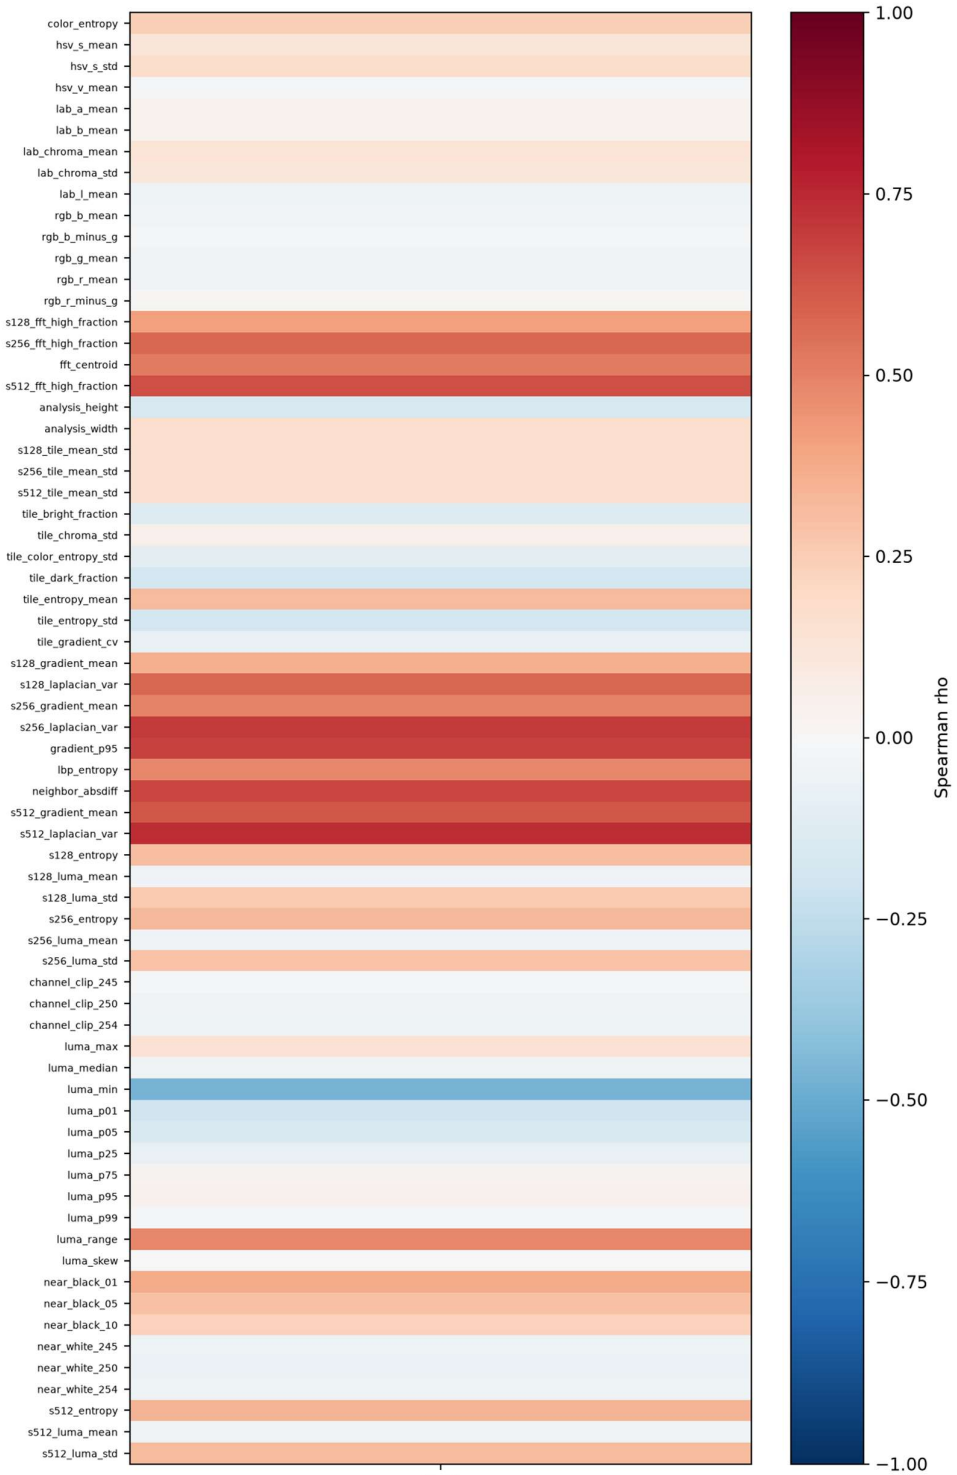
8. Relaciones entre MOS, descriptores y escalas

De los 68 descriptores, “s512_laplacian_var” presenta la mayor correlación de Spearman con MOS (ρ=0,735819; Pearson r=0,522371; N=11.125). En estas fotografías, valores mayores de este descriptor tienden a corresponder a calificaciones más altas (Tabla 4; Figuras 4–5). Sin embargo, el Laplaciano responde también a textura, contraste y ruido, y no mide por sí solo la resolución óptica.

La diferencia entre Spearman y Pearson sugiere que la relación no se resume bien mediante una recta. Las dispersiones muestran variabilidad de MOS para valores semejantes del descriptor. Por tanto, la correlación observada no equivale a capacidad predictiva demostrada.

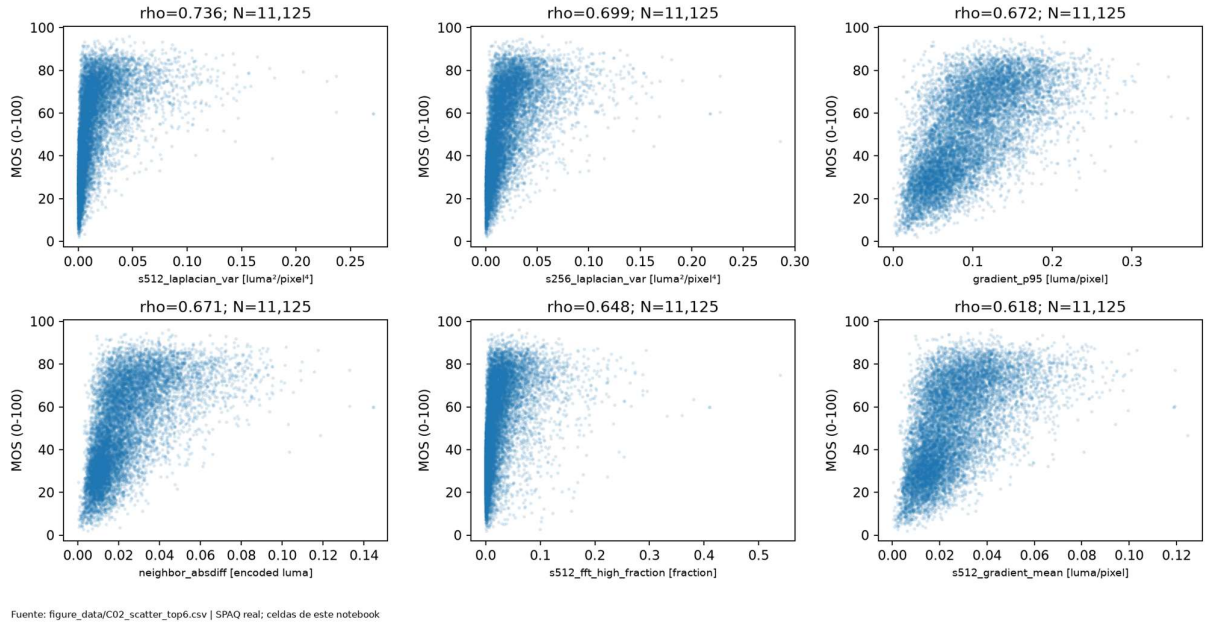
Tabla 4. Correlaciones entre MOS y descriptores digitales. Fuente: cálculos propios sobre las anotaciones e imágenes originales de SPAQ.

original_name	family	pearson_r	spearman_rho	n_valid
s512_laplacian_var	spatial_texture	0.5224	0.7358	11125
s256_laplacian_var	spatial_texture	0.5450	0.6985	11125
gradient_p95	spatial_texture	0.6440	0.6724	11125
neighbor_absdiff	spatial_texture	0.5927	0.6714	11125
s512_fft_high_fraction	frequency	0.4521	0.6483	11125
s512_gradient_mean	spatial_texture	0.5765	0.6183	11125
s256_fft_high_fraction	frequency	0.4344	0.5775	11125
s128_laplacian_var	spatial_texture	0.4945	0.5766	11125



Fuente: eda_tables/feature_mos_correlations.csv | SPAQ real; celdas de este notebook

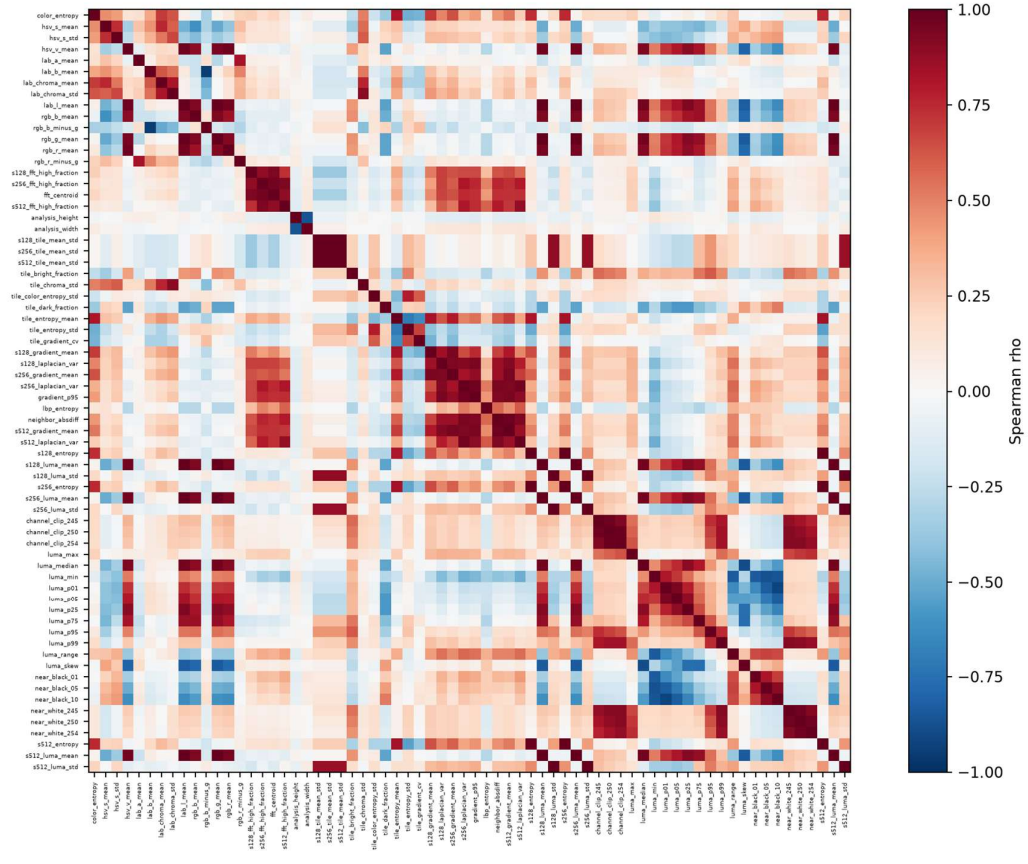
Figura 4. Correlaciones de 68 descriptores con MOS. Magnitud y signo son asociaciones marginales; pruebas nominales requieren cautela ante datos repetidos. Fuente: cálculos propios sobre SPAQ.



Fuente: figure_data/C02_scatter_top6.csv | SPAQ real; celdas de este notebook

Figura 5. Dispersión de asociaciones destacadas. Se observan relaciones bivariadas sin controlar covariables ni medir capacidad predictiva. Fuente: cálculos propios sobre SPAQ.

Entre los 68 descriptores se hallaron 79 pares con |ρ|≥0,9, de 2.278 posibles (Figura 6). Esta redundancia aconseja estudiar la colinealidad y comparar familias de características, pero no significa que deban eliminarse 79 variables.



Fuente: eda_tables/feature_spearman_matrix.csv | SPAQ real; celdas de este notebook

Figura 6. Redundancia dentro del espacio de descriptores. Agrupamientos por correlación pueden orientar selección futura, sin borrado automático de columnas en este análisis. Fuente: cálculos propios sobre SPAQ.

Las comparaciones entre escalas muestran comportamientos distintos: la media de luma mantiene casi el mismo orden de imágenes, mientras que algunos descriptores de gradiente y frecuencia cambian más. Para `fft_high_fraction`, la correlación entre 512 y 128 píxeles es ρ=0,728625 (Tabla 5).

La escala de análisis influye en la información que resume cada descriptor. Por eso conviene evaluar distintas resoluciones antes de seleccionar variables; estos resultados aún no identifican una escala óptima.

Tabla 5. Consistencia de los descriptores entre escalas. Fuente: cálculos propios sobre las anotaciones e imágenes originales de SPAQ.

definition	scale_a	scale_b	spearman_between_scales	MOS_spearman_a	MOS_spearman_b
luma_mean	512	256	1.0000	-0.0374	-0.0374
luma_mean	512	128	1.0000	-0.0374	-0.0373
luma_mean	256	128	1.0000	-0.0374	-0.0373
luma_std	512	256	0.9985	0.3141	0.2881
luma_std	512	128	0.9935	0.3141	0.2582
luma_std	256	128	0.9981	0.2881	0.2582
gradient_mean	512	256	0.9472	0.6183	0.4952

9. Completitud de EXIF y asociación con modelo de dispositivo

La prueba χ^2 comparó el modelo de dispositivo con la completitud de los metadatos EXIF. Se obtuvo χ^2=10.599,0552, con 48 grados de libertad y V de Cramér=0,9761 (Tabla 6), lo que indica una asociación muy fuerte entre ambas variables. Las frecuencias esperadas cumplen los criterios examinados. Este resultado se refiere a disponibilidad de metadatos, no a calidad perceptual.

Tabla 6. Independencia entre dispositivo y completitud EXIF. Fuente: cálculos propios sobre las anotaciones e imágenes originales de SPAQ.

choice	N	chi2	df	cramers_V	expected_min	percent_expected_lt5
all_observations	11125	10599.0552	48	0.9761	12.7551	0.0000
lexicographic_first_ID	10803	10286.1025	48	0.9758	10.5262	0.0000
lexicographic_last_ID	10803	10286.1025	48	0.9758	10.5262	0.0000

10. Discusión

10.1. Asociaciones, redundancia y escala

La asociación más alta con MOS corresponde a la varianza del Laplaciano a escala 512 (ρ=0,735819). También se observaron 79 pares de descriptores muy correlacionados y diferencias de estabilidad entre escalas. En conjunto, estos resultados muestran que las características comparten información, pero no permiten medir todavía su contribución predictiva independiente.

10.2. Escenas y fiabilidad de las anotaciones

Los pesos de escena describen pertenencias simultáneas, por lo que las comparaciones entre escenas son descriptivas y no identifican efectos causales. Las diferencias entre calificaciones de archivos idénticos añaden una fuente de incertidumbre que debe considerarse al evaluar modelos.

10.3. Estructura de variables para análisis no supervisado

Los 68 descriptores ofrecen una base para explorar agrupamientos de fotografías. Antes de interpretarlos habrá que examinar su redundancia y estandarización.

11. Conclusiones

1. La calidad perceptual MOS presenta asociaciones destacadas con descriptores de estructura espacial, especialmente la varianza del Laplaciano a escala 512 (ρ de Spearman = 0,735819). Se trata de asociaciones descriptivas, no de pruebas de causalidad ni de capacidad predictiva.

2. Se identificaron 79 pares de descriptores con $|\rho| \geq 0{,}9$, así como diferencias entre escalas y contenidos de escena. Estos hallazgos muestran redundancia y heterogeneidad que deben considerarse al estudiar el aporte complementario de las variables.

3. Entre los 322 pares de fotografías con contenido idéntico, 321 presentan puntuaciones MOS distintas. Esta discordancia exige controlar las duplicaciones y la consistencia de las anotaciones en futuras evaluaciones, evitando separar copias idénticas entre entrenamiento y prueba.

Referencias

Fang, Y., Zhu, H., Zeng, Y., Ma, K., & Wang, Z. (2020). Perceptual Quality Assessment of Smartphone Photography. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 3677–3686. https://doi.org/10.1109/CVPR42600.2020.00373

Fang et al. SPAQ, repositorio de los autores: https://github.com/h4nwei/SPAQ (consulta documentada en la auditoría técnica: 25 de octubre de 2026; licencia MIT declarada por el responsable del repositorio el 20 de septiembre de 2023).

NIST/SEMATECH. e-Handbook of Statistical Methods, sección sobre detección de valores atípicos: https://www.itl.nist.gov/div898/handbook/eda/section3/eda35h.htm

SciPy. Documentación de scipy.stats.chi2_contingency: https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.chi2_contingency.html

Anexo

Se anexa el script Python usado para este análisis, implementado en un cuaderno Jupyter. El script puede ser descargado desde

https://drive.google.com/file/d/1cOJfqhldWYkU-fvXCWow-FJZBRaCkfh2/view?usp=sharing

October 24, 2026

Calidad perceptual de las fotografías SPAQ

Este notebook está disponible en https://drive.google.com/file/d/1cOJfqhldWYkU-fvXCWow-FJZBRaCkfh2/view?usp=sharing

Este cuaderno no está diseñado para la ejecusión en linea, pues requiere el dataset en disco local.

SPAQ (Smartphone Photography Attribute and Quality) es un conjunto de datos (dataset) para la evaluación de la calidad de imágenes en visión por computadora.

Consta de 11125 imagenes obtenidas desde 66 télefonos inteligentes diferentes. Cuanta con puntuación de Mean Opinion Scores) sobre la calidad perceptual general de cada fotografía.

https://github.com/h4nwei/SPAQ

En este cuaderno se calculan 68 descriptores a partir de 11.125 JPEG originales y analiza su relación con MOS. Incluye las seis figuras y las tablas del estudio: distribuciones, valores ausentes, contenidos repetidos, escenas, correlaciones, escalas y completitud EXIF.

Se utilizan tablas separadas para puntuaciones, escenas, descriptores y metadatos. El nombre de la fotografía es el índice común.

Problema y objetivos

Pregunta de investigación. ¿En qué medida las características tonales, cromáticas, espaciales, regionales y multiescala extraídas de fotografías de smartphones, junto con los metadatos de adquisición, permiten caracterizar su asociación con la calidad perceptual MOS (Mean Opinion Score), y cómo varían dichas asociaciones según las escenas y la consistencia de las anotaciones?

Pregunta secundaria 1. ¿Qué asociaciones, redundancias y diferencias entre escalas presentan las familias de descriptores digitales respecto de MOS?

Pregunta secundaria 2. ¿Cómo varían las asociaciones según contenido de escena y condiciones de captura, y qué revelan los archivos idénticos con anotaciones discrepantes?

Pregunta secundaria 3. ¿Qué estructura y limitaciones del espacio de descriptores resultan pertinentes para un estudio posterior de agrupamientos no supervisados?

Objetivo general. Caracterizar estadísticamente las relaciones entre descriptores digitales interpretables, metadatos de adquisición, contenido de escena y calidad perceptual MOS en SPAQ, considerando la integridad de sus anotaciones, la redundancia y la sensibilidad multiescala. El alcance de estos objetivos se verifica mediante los estadísticos, tablas y figuras presentados para el conjunto analizado.

Objetivo específico 1. Describir las distribuciones, la integridad y las asociaciones entre anotaciones humanas, descriptores digitales y metadatos en las 11.125 fotografías, con medidas estadísticas y evidencias visuales verificables.

Objetivo específico 2. Examinar la redundancia entre descriptores y sus variaciones según escala y contenido de escena, explicitando los tamaños muestrales y las limitaciones de interpretación.

Objetivo específico 3 . Cuantificar las discrepancias de anotación entre contenidos idénticos y las incidencias de metadatos, delimitando su posible influencia sobre la interpretación y evaluación posterior de los datos.

1. Bibliotecas y carpetas

Cambie `raiz` si SPAQ está en otra ubicación. Las entradas son los tres Excel de `Annotations/` y los JPEG de `TestImage/`. Todos los cálculos están escritos aquí. `tabla` muestra una tabla y guarda su CSV; `figura` muestra una figura y guarda su PNG.

[ ]:
```
from pathlib import Path
from concurrent.futures import ThreadPoolExecutor
import hashlib, io, itertools, re
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import cv2
from scipy import stats
from PIL import Image, ImageOps, ImageCms
from skimage.feature import local_binary_pattern
raiz = Path('../spaq/SPAQ')
salida = Path('outputs')
for carpeta in ('eda_tables', 'figures', 'derived'):
    (salida / carpeta).mkdir(parents=True, exist_ok=True)
cv2.setNumThreads(1)
def tabla(nombre, datos):
    datos.to_csv(salida / 'eda_tables' / (nombre + '.csv'))
    display(datos)
def figura(nombre, titulo):
    plt.suptitle(titulo)
    plt.tight_layout(rect=(0, 0, 1, .95))
    plt.savefig(salida / 'figures' / (nombre + '.png'), dpi=170)
    plt.show()
```

2. Anotaciones originales

MOS y los cinco atributos humanos tienen escala de 0 a 100. Las nueve escenas contienen pesos de pertenencia: una fotografía puede pertenecer a varias escenas. Las dos hojas EXIF se conservan para describir la disponibilidad de los datos originales.

```
[ ]: carpeta = raiz / 'Annotations'
notas = pd.read_excel(carpeta / 'MOS and Image attribute scores.xlsx').
 ↪set_index('Image name')
escenas = pd.read_excel(carpeta / 'Scene category labels.xlsx').
 ↪set_index('Image name')
escenas.columns = escenas.columns.str.lower().str.replace(r'[^a-z0-9]+', '_',␣
 ↪regex=True)
libro = pd.read_excel(carpeta / 'EXIF_tags.xlsx', sheet_name=None)
originales = {'human': notas, 'scene': escenas}
for nombre, hoja in libro.items():
    originales[nombre] = hoja.set_index('Image name')
rutas = sorted((raiz / 'TestImage').glob('*.jpg'))
assert len(rutas) == len(notas) == 11125
assert all(t.index.equals(notas.index) for t in originales.values())
```

3. Variables y definiciones

Grupo	Variables	Interpretación
Calidad perceptual	MOS	Evaluación humana de calidad, de 0 a 100
Atributos humanos	Brillo, colorido, contraste, ruido y nitidez	Cinco puntuaciones auxiliares
Contenido	Nueve escenas	Pesos que permiten escenas superpuestas
Captura	EXIF de Excel y del JPEG	Dispositivo y condiciones de adquisición
Descriptores	68 medidas de píxeles	Tono, color, textura, regiones, frecuencia y geometría
Identificación	ID y SHA-256	Archivo y contenido binario

Campos	Tipo y unidad	Uso
ID, nombre y ruta	Texto	Unir cada archivo con sus anotaciones
SHA-256	Texto hexadecimal	Reconocer contenidos idénticos
MOS y atributos humanos	Numérico, puntos de 0 a 100	Resumir evaluaciones humanas
Pesos de escena	Numérico, proporción	Ponderar el análisis de cada escena
Marca, modelo, fechas EXIF	Texto	Describir dispositivo y captura
Focal, apertura, exposición, ISO	Numérico; mm, número f, segundos e ISO	Describir adquisición
Brillo y flash EXIF	Valor EXIF y código categórico	Examinar disponibilidad de metadatos
Orientación y perfil ICC	Código EXIF y presencia booleana	Interpretar los píxeles correctamente

Campos	Tipo y unidad	Uso
Descriptores digitales	Numérico	Unidades y dominios en la tabla siguiente

Diccionario de los 68 descriptores

Descriptor	Definición	Unidad	Dominio
s512_luma_mean	Mean Y; max side 512px, no upsampling.	encoded luma	[0,1]
s512_luma_std	Population SD Y; global RMS contrast; max side 512px, no upsampling.	encoded luma	[0,0.5]
s512_gradient_mean	Mean sqrt(Sobel_x^2+Sobel_y^2); 3x3 Sobel divided by 8; max side 512px, no upsampling.	luma/pixel	>=0
s512_laplacian_var	Population variance of 3x3 Laplacian (OpenCV ksize=1); max side 512px, no upsampling.	$luma^2$/pixel	>=0
s512_fft_high_fraction	Hann-windowed, demeaned FFT energy with radial frequency >=0.25 cycles/pixel / total non-DC energy; max side 512px, no upsampling.	fraction	[0,1]
s512_tile_mean_std	SD of mean Y over 4x4 equal-index tiles; max side 512px, no upsampling.	encoded luma	[0,0.5]
s512_entropy	Shannon entropy -sum(p log2 p), 256 equal Y bins on [0,1]; max side 512px, no upsampling.	bits	[0,8]
s256_luma_mean	Mean Y; max side 256px, no upsampling.	encoded luma	[0,1]
s256_luma_std	Population SD Y; global RMS contrast; max side 256px, no upsampling.	encoded luma	[0,0.5]

Descriptor	Definición	Unidad	Dominio
s256_gradient_mean	Mean sqrt(Sobel_x²+Sobel_y²); 3x3 Sobel divided by 8; max side 256px, no upsampling.	luma/pixel	>=0
s256_laplacian_var	Population variance of 3x3 Laplacian (OpenCV ksize=1); max side 256px, no upsampling.	luma²/pixel	>=0
s256_fft_high_fraction	Hann-windowed, demeaned FFT energy with radial frequency >=0.25 cycles/pixel / total non-DC energy; max side 256px, no upsampling.	fraction	[0,1]
s256_tile_mean_std	SD of mean Y over 4x4 equal-index tiles; max side 256px, no upsampling.	encoded luma	[0,0.5]
s256_entropy	Shannon entropy -sum(p log2 p), 256 equal Y bins on [0,1]; max side 256px, no upsampling.	bits	[0,8]
s128_luma_mean	Mean Y; max side 128px, no upsampling.	encoded luma	[0,1]
s128_luma_std	Population SD Y; global RMS contrast; max side 128px, no upsampling.	encoded luma	[0,0.5]
s128_gradient_mean	Mean sqrt(Sobel_x²+Sobel_y²); 3x3 Sobel divided by 8; max side 128px, no upsampling.	luma/pixel	>=0
s128_laplacian_var	Population variance of 3x3 Laplacian (OpenCV ksize=1); max side 128px, no upsampling.	luma²/pixel	>=0

Descriptor	Definición	Unidad	Dominio
s128_fft_high_fraction	Hann-windowed, demeaned FFT energy with radial frequency >=0.25 cycles/pixel / total non-DC energy; max side 128px, no upsampling.	fraction	[0,1]
s128_tile_mean_std	SD of mean Y over 4x4 equal-index tiles; max side 128px, no upsampling.	encoded luma	[0,0.5]
s128_entropy	Shannon entropy -sum(p log2 p), 256 equal Y bins on [0,1]; max side 128px, no upsampling.	bits	[0,8]
analysis_width	Actual width at s512	pixel	positive integer
analysis_height	Actual height at s512	pixel	positive integer
luma_median	Median Y	encoded luma	[0,1]
luma_min	Minimum Y	encoded luma	[0,1]
luma_max	Maximum Y	encoded luma	[0,1]
luma_range	max(Y)-min(Y)	encoded luma	[0,1]
luma_skew	mean((Y-mean(Y))^3)/SD(Y)^3; missing if SD<=1e-8	1	real
gradient_p95	95th percentile Sobel magnitude	luma/pixel	>=0
tile_gradient_cv	SD of tile gradient means / mean; missing if denominator <=1e-8	1	>=0
tile_dark_fraction	Fraction of tiles with mean Y<0.1	fraction	[0,1]
tile_bright_fraction	Fraction of tiles with mean Y>0.9	fraction	[0,1]
tile_entropy_mean	Mean of 16 tile Y entropies	bits	[0,8]
tile_entropy_std	SD of 16 tile Y entropies	bits	[0,4]
hsv_s_mean	Mean HSV S from float RGB conversion	fraction	[0,1]
hsv_s_std	SD HSV S	fraction	[0,0.5]
hsv_v_mean	Mean HSV V=max(R,G,B)	encoded channel	[0,1]
rgb_r_mean	Mean encoded red	encoded channel	[0,1]
rgb_g_mean	Mean encoded green	encoded channel	[0,1]

Descriptor	Definición	Unidad	Dominio
rgb_b_mean	Mean encoded blue	encoded channel	[0,1]
rgb_r_minus_g	Mean R-G	encoded channel	[-1,1]
rgb_b_minus_g	Mean B-G	encoded channel	[-1,1]
lab_l_mean	Mean CIELAB L*; OpenCV float RGB2Lab sRGB D65	L*	[0,100]
lab_a_mean	Mean CIELAB a*	a*	approximately [-128,128]
lab_b_mean	Mean CIELAB b*	b*	approximately [-128,128]
lab_chroma_mean	Mean sqrt(a^2+b^2)	Lab chroma	>=0
lab_chroma_std	SD sqrt(a^2+b^2)	Lab chroma	>=0
tile_chroma_std	SD of tile mean Lab chroma	Lab chroma	>=0
color_entropy	Joint Shannon RGB entropy, 8 bins/channel, 512 joint bins	bits	[0,9]
tile_color_entropy_std	SD of 16 joint RGB entropies	bits	>=0
lbp_entropy	Shannon entropy of rotation invariant uniform LBP (P=8,R=1), 10 bins; border excluded	bits	[0,log2(10)]
neighbor_absdiff	Mean absolute horizontal/vertical Y difference	encoded luma	[0,1]
fft_centroid	Energy weighted radial FFT frequency, Hann, demeaned, DC excluded	cycles/pixel	[0,sqrt(0.5)]
luma_p01	Y percentile 1	encoded luma	[0,1]
luma_p05	Y percentile 5	encoded luma	[0,1]
luma_p25	Y percentile 25	encoded luma	[0,1]
luma_p75	Y percentile 75	encoded luma	[0,1]
luma_p95	Y percentile 95	encoded luma	[0,1]
luma_p99	Y percentile 99	encoded luma	[0,1]
near_black_01	Fraction Y <= 1/255	fraction	[0,1]
near_black_05	Fraction Y <= 5/255	fraction	[0,1]
near_black_10	Fraction Y <= 10/255	fraction	[0,1]
near_white_245	Fraction Y >= 245/255	fraction	[0,1]
channel_clip_245	Fraction max(R,G,B) >= 245/255	fraction	[0,1]

Descriptor	Definición	Unidad	Dominio
near_white_250	Fraction Y >= 250/255	fraction	[0,1]
channel_clip_250	Fraction max(R,G,B) >= 250/255	fraction	[0,1]
near_white_254	Fraction Y >= 254/255	fraction	[0,1]
channel_clip_254	Fraction max(R,G,B) >= 254/255	fraction	[0,1]

Cálculo de los descriptores

`entropy` mide la diversidad de intensidades; `color_entropy`, la diversidad conjunta de RGB. `tiles` divide una imagen en 16 regiones. `spectrum` obtiene energía de alta frecuencia y frecuencia media ponderada mediante FFT, con ventana de Hann y sin componente continua.

`extract` repite las siete medidas básicas a 512, 256 y 128 píxeles, conservando la proporción y sin ampliar las imágenes pequeñas. Las medidas restantes se calculan a escala 512. Los bucles guardan cada resultado con los nombres del diccionario anterior. `None` indica una medida matemáticamente indefinida, por ejemplo una asimetría con luminancia constante.

[ ]:
```
CORE = ('luma_mean luma_std gradient_mean laplacian_var '
        'fft_high_fraction tile_mean_std entropy').split()
def entropy(a):
    return stats.entropy(np.histogram(a, bins=256, range=(0, 1))[0], base=2)
def color_entropy(rgb):
    q = np.minimum((rgb * 8).astype(int), 7)
    codigos = q[:, :, 0] * 64 + q[:, :, 1] * 8 + q[:, :, 2]
    return stats.entropy(np.bincount(codigos.ravel(), minlength=512), base=2)
def tiles(imagen):
    regiones = []
    for fila in np.array_split(imagen, 4):
        regiones.extend(np.array_split(fila, 4, axis=1))
    return regiones
def spectrum(y):
    h, w = y.shape
    ventana = np.outer(np.hanning(h), np.hanning(w))
    potencia = abs(np.fft.fft2((y - y.mean()) * ventana, norm='ortho')) ** 2
    potencia[0, 0] = 0
    radio = np.hypot(np.fft.fftfreq(h)[:, None], np.fft.fftfreq(w))
    total = potencia.sum()
    if total <= 1e-20:
        return None, None
    return potencia[radio >= .25].sum() / total, (potencia * radio).sum() /␣
 ↪total
def extract(image):
    result = {}
```

```
    for scale in (512, 256, 128):
        w, h = image.size
        ratio = min(1, scale / max(w, h))
        size = (max(1, round(w * ratio)), max(1, round(h * ratio)))
        rgb = np.asarray(image.resize(size, Image.Resampling.LANCZOS), dtype=np.
↪float32) / 255
        y = rgb @ np.array([.2126, .7152, .0722], dtype=np.float32)
        gx = cv2.Sobel(y, cv2.CV_32F, 1, 0, ksize=3, borderType=cv2.
↪BORDER_REFLECT_101) / 8
        gy = cv2.Sobel(y, cv2.CV_32F, 0, 1, ksize=3, borderType=cv2.
↪BORDER_REFLECT_101) / 8
        grad = np.hypot(gx, gy)
        lap = cv2.Laplacian(y, cv2.CV_32F, ksize=1, borderType=cv2.
↪BORDER_REFLECT_101)
        ts = tiles(y)
        tm = np.array([t.mean() for t in ts])
        high, centroid = spectrum(y)
        basicos = [y.mean(), y.std(), grad.mean(), lap.var(), high, tm.std(),␣
↪entropy(y)]
        for nombre, valor in zip(CORE, basicos):
            result[f's{scale}_{nombre}'] = valor
        if scale != 512:
            continue
        result['analysis_width'], result['analysis_height'] = y.shape[1], y.
↪shape[0]
        for nombre, valor in zip(('median', 'min', 'max', 'range'),
                                 (np.median(y), y.min(), y.max(), np.ptp(y))):
            result['luma_' + nombre] = valor
        sd = float(y.std())
        result['luma_skew'] = None
        if sd > 1e-8:
            result['luma_skew'] = np.mean((y - y.mean()) ** 3) / sd ** 3
        for p, valor in zip((1, 5, 25, 75, 95, 99), np.percentile(y, [1, 5, 25,␣
↪75, 95, 99])):
            result[f'luma_p{p:02}'] = valor
        for t in (1, 5, 10):
            result[f'near_black_{t:02}'] = np.mean(y <= t / 255)
        for t in (245, 250, 254):
            result[f'near_white_{t}'] = np.mean(y >= t / 255)
            result[f'channel_clip_{t}'] = np.mean(rgb.max(axis=2) >= t / 255)
        tg = np.array([t.mean() for t in tiles(grad)])
        te = np.array([entropy(t) for t in ts])
        result['gradient_p95'] = np.percentile(grad, 95)
        result['tile_gradient_cv'] = None
        if tg.mean() > 1e-8:
            result['tile_gradient_cv'] = float(tg.std() / tg.mean())
```

```
        result['tile_dark_fraction'] = np.mean(tm < .1)
        result['tile_bright_fraction'] = np.mean(tm > .9)
        result['tile_entropy_mean'], result['tile_entropy_std'] = te.mean(), te.
↪std()
        result['fft_centroid'] = centroid
        hsv = cv2.cvtColor(rgb, cv2.COLOR_RGB2HSV)
        lab = cv2.cvtColor(rgb, cv2.COLOR_RGB2Lab)
        chroma = np.hypot(lab[:, :, 1], lab[:, :, 2])
        result['hsv_s_mean'], result['hsv_s_std'] = hsv[:, :, 1].mean(), hsv[:,␣
↪:, 1].std()
        result['hsv_v_mean'] = hsv[:, :, 2].mean()
        cm = rgb.mean(axis=(0, 1))
        for nombre, valor in zip(('r', 'g', 'b'), cm):
            result['rgb_' + nombre + '_mean'] = valor
        result['rgb_r_minus_g'], result['rgb_b_minus_g'] = cm[0] - cm[1], cm[2]␣
↪- cm[1]
        for i, nombre in enumerate(('l', 'a', 'b')):
            result['lab_' + nombre + '_mean'] = lab[:, :, i].mean()
        result['lab_chroma_mean'], result['lab_chroma_std'] = chroma.mean(),␣
↪chroma.std()
        result['tile_chroma_std'] = np.std([t.mean() for t in tiles(chroma)])
        result['color_entropy'] = color_entropy(rgb)
        result['tile_color_entropy_std'] = np.std([color_entropy(t) for t in␣
↪tiles(rgb)])
        vertical = np.abs(np.diff(y, axis=0)).mean()
        horizontal = np.abs(np.diff(y, axis=1)).mean()
        result['neighbor_absdiff'] = float(vertical + horizontal) / 2
        gray = np.round(y * 255).astype(np.uint8)
        lbp = local_binary_pattern(gray, 8, 1, 'uniform')[1:-1, 1:-1]
        result['lbp_entropy'] = stats.entropy(np.bincount(lbp.astype(int).
↪ravel(), minlength=10),
            base=2)
    for nombre, valor in result.items():
        if valor is None or not np.isfinite(valor):
            result[nombre] = None
        else:
            result[nombre] = float(valor)
    return result
```

Lectura de cada JPEG

Se leen las etiquetas EXIF del archivo, se aplica su orientación y se convierte su perfil ICC a sRGB cuando está presente. SHA-256 permite reconocer archivos con contenido binario idéntico. Se recogen únicamente los metadatos necesarios para las tablas y figuras del estudio.

[ ]:
```
campos = {'focal_length': 37386, 'f_number': 33437, 'exposure_time': 33434,
          'iso': 34855, 'brightness': 37379, 'flash': 37385}
```

```
def leer_imagen(ruta):
    with Image.open(ruta) as imagen:
        base = imagen.getexif()
        camara = base.get_ifd(34665) if 34665 in base else {}
        exif = {'make': base.get(271), 'model': base.get(272), 'datetime': base.
 ↪get(306),
                'datetime_original': camara.get(36867), 'orientation': base.
 ↪get(274),
                'icc_present': bool(imagen.info.get('icc_profile'))}
        for nombre, codigo in campos.items():
            try:
                exif[nombre] = float(camara.get(codigo, base.get(codigo)))
            except (TypeError, ValueError, ZeroDivisionError):
                exif[nombre] = None
        for nombre in ('make', 'model', 'datetime', 'datetime_original'):
            if exif[nombre] is not None:
                exif[nombre] = str(exif[nombre]).strip().strip('\x00') or None
        rgb = ImageOps.exif_transpose(imagen).convert('RGB')
        if exif['icc_present']:
            perfil = ImageCms.ImageCmsProfile(io.BytesIO(imagen.
 ↪info['icc_profile']))
            rgb = ImageCms.profileToProfile(rgb, perfil, ImageCms.
 ↪createProfile('sRGB'))
        huella = hashlib.sha256(ruta.read_bytes()).hexdigest()
        return extract(rgb), exif, huella
```

Procesamiento del conjunto

Se procesan ocho imágenes simultáneamente para aprovechar el equipo. Esta es la etapa más larga. El contador muestra cuántas fotografías se han procesado. `rasgos`, `nativo` y `huellas` quedan alineados por el nombre de archivo, igual que `notas` y `escenas`.

La completitud de adquisición exige valores numéricos finitos en los seis campos de captura y al menos una fecha. No equivale a disponer de todas las etiquetas EXIF posibles.

[ ]:
```
resultados = []
with ThreadPoolExecutor(max_workers=8) as pool:
    for resultado in pool.map(leer_imagen, rutas):
        resultados.append(resultado)
        if len(resultados) % 500 == 0:
            print(len(resultados), 'imágenes procesadas', flush=True)
nombres = [ruta.name for ruta in rutas]
rasgos = pd.DataFrame([r[0] for r in resultados], index=nombres)
nativo = pd.DataFrame([r[1] for r in resultados], index=nombres)
huellas = pd.Series([r[2] for r in resultados], index=nombres, name='SHA256')
fechas = nativo.datetime_original.fillna(nativo.datetime).notna()
nativo['acquisition_complete'] = np.isfinite(nativo[list(campos)]).all(axis=1)␣
 ↪& fechas
```

```
assert rasgos.shape == (11125, 68) and rasgos.index.equals(notas.index)
rasgos.to_parquet(salida / 'derived/image_features.parquet')
nativo.join(huellas).to_csv(salida / 'derived/image_metadata.csv')
```

```
500 imágenes procesadas
1000 imágenes procesadas
1500 imágenes procesadas
2000 imágenes procesadas
2500 imágenes procesadas
3000 imágenes procesadas
3500 imágenes procesadas
4000 imágenes procesadas
4500 imágenes procesadas
5000 imágenes procesadas
5500 imágenes procesadas
6000 imágenes procesadas
6500 imágenes procesadas
7000 imágenes procesadas
7500 imágenes procesadas
8000 imágenes procesadas
8500 imágenes procesadas
9000 imágenes procesadas
9500 imágenes procesadas
10000 imágenes procesadas
10500 imágenes procesadas
11000 imágenes procesadas
```

4. Distribuciones y valores extremos

La desviación es muestral; la asimetría y el exceso de curtosis usan corrección de sesgo. Los criterios IQR y $|z|>3$ señalan observaciones para revisión. Los datos originales se conservan.

[ ]:
```
valores = notas.join(escenas[['animal']])
resumen = valores.describe().T
resumen['skew'] = valores.skew()
resumen['kurtosis'] = valores.kurt()
tabla('human_shape', resumen.loc[notas.columns, ['count', 'skew', 'kurtosis']])
tabla('univariate_numeric', resumen)
q1, q3 = notas.quantile(.25), notas.quantile(.75)
iqr = q3 - q1
fuera = ((notas < q1 - 1.5 * iqr) | (notas > q3 + 1.5 * iqr)).sum()
atipicos = pd.DataFrame({'N_IQR': fuera, 'porcentaje_IQR': 100 * fuera /␣
 ↪len(notas)})
atipicos['N_z3'] = ((notas - notas.mean()) / notas.std()).abs().gt(3).sum()
tabla('outlier_audit', atipicos)
```

```
               count      skew  kurtosis
MOS          11125.0 -0.047839 -1.142444
```

```
Brightness    11125.0 -0.505273 -0.090767
Colorfulness  11125.0 -0.528201  0.078658
Contrast      11125.0 -0.405043 -0.217265
Noisiness     11125.0 -0.101702 -0.845304
Sharpness     11125.0 -0.026664 -1.378374
```

	count	mean	std	…	max	skew	kurtosis
MOS	11125.0	50.317889	20.902295	…	96.00	-0.047839	-1.142444
Brightness	11125.0	56.004618	16.814893	…	97.00	-0.505273	-0.090767
Colorfulness	11125.0	60.454467	15.325357	…	96.00	-0.528201	0.078658
Contrast	11125.0	57.284443	16.238312	…	95.67	-0.405043	-0.217265
Noisiness	11125.0	52.999706	18.370710	…	98.00	-0.101702	-0.845304
Sharpness	11125.0	47.047013	24.227165	…	96.33	-0.026664	-1.378374
animal	11125.0	0.010067	0.092351	…	1.00	9.755379	97.298997

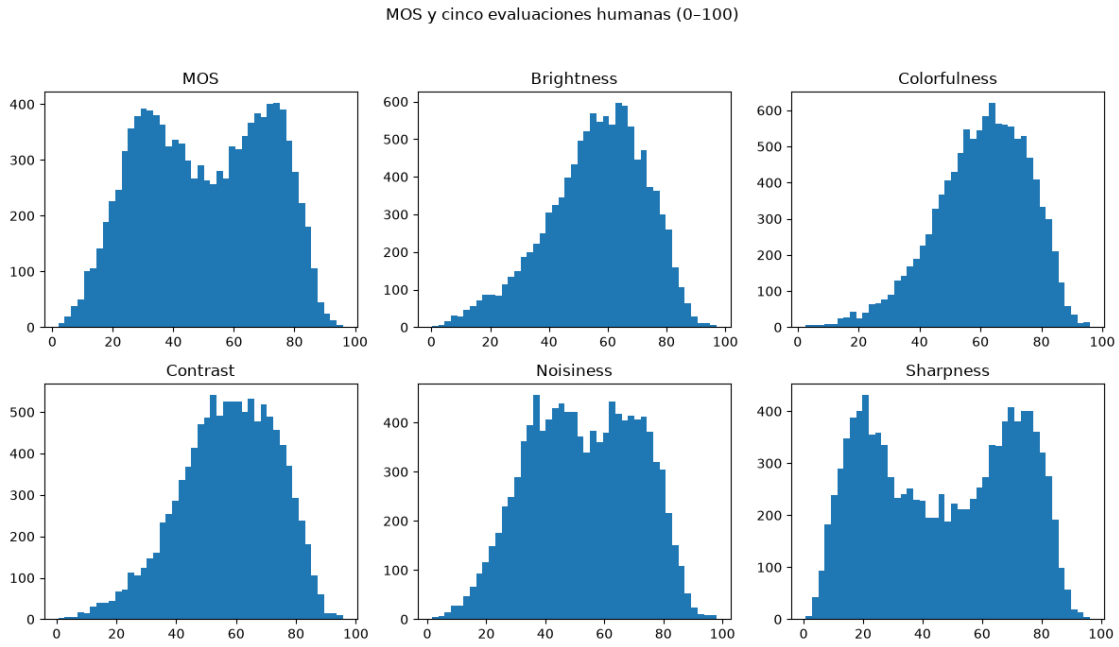
[7 rows x 10 columns]

	N_IQR	porcentaje_IQR	N_z3
MOS	0	0.000000	0
Brightness	102	0.916854	19
Colorfulness	119	1.069663	52
Contrast	53	0.476404	24
Noisiness	0	0.000000	0
Sharpness	0	0.000000	0

Figura 1. MOS y cinco atributos humanos

Los seis histogramas incluyen las 11.125 fotografías, con 45 intervalos por variable.

[ ]:
```
notas.hist(bins=45, layout=(2, 3), figsize=(12, 7), grid=False)
figura('B01_human_scores', 'MOS y cinco evaluaciones humanas (0-100)')
```



5. Disponibilidad de anotaciones y metadatos

Se cuentan las ausencias de las anotaciones originales, los descriptores y los EXIF leídos del JPEG. Los ceros originales no se consideran ausencias. La tabla y la Figura 2 muestran las ocho variables con valores ausentes; el denominador es 11.125 fotografías.

[ ]:
```
fuentes = dict(originales, native_exif=nativo, feature=rasgos)
partes = [t.add_prefix(nombre + '__') for nombre, t in fuentes.items()]
ausencias = pd.concat(partes, axis=1).isna().sum().sort_index()
faltantes = pd.DataFrame({'N': ausencias, 'porcentaje': 100 * ausencias /␣
 ↪len(notas)})
faltantes = faltantes[faltantes.N > 0]
tabla('missing_sentinel_audit', faltantes)
frecuencias = []
for columna in ('make', 'acquisition_complete', 'icc_present'):
    conteo = nativo[columna].value_counts().rename_axis('categoria').
 ↪reset_index(name='N')
    conteo['variable'] = columna
    frecuencias.append(conteo)
tabla('categorical_frequencies', pd.concat(frecuencias, ignore_index=True))
```

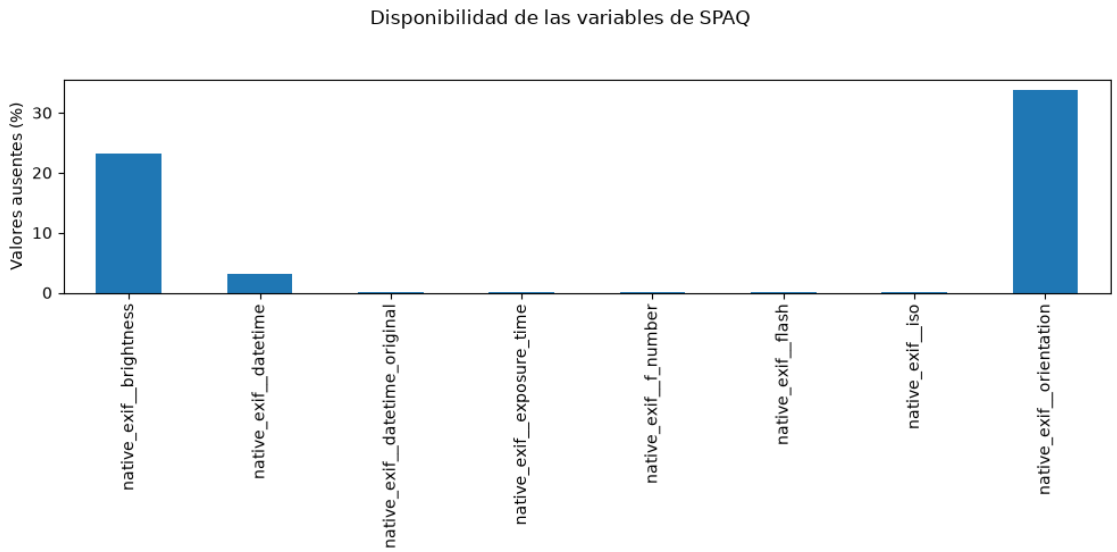
	N	porcentaje
native_exif__brightness	2579	23.182022
native_exif__datetime	354	3.182022
native_exif__datetime_original	6	0.053933
native_exif__exposure_time	13	0.116854
native_exif__f_number	5	0.044944

```
native_exif__flash                10    0.089888
native_exif__iso                  12    0.107865
native_exif__orientation        3758   33.779775
```

	categoria	N	variable
0	HUAWEI	3086	make
1	Apple	2063	make
2	vivo	1369	make
3	OPPO	1127	make
4	Xiaomi	1065	make
5	nubia	882	make
6	Meitu	668	make
7	samsung	609	make
8	Meizu	149	make
9	GiONEE	63	make
10	XIAOMI	18	make
11	Canon	11	make
12	SAMSUNG	11	make
13	Letv	4	make
14	True	8545	acquisition_complete
15	False	2580	acquisition_complete
16	False	10771	icc_present
17	True	354	icc_present

Figura 2. Variables con valores ausentes

```
[ ]: faltantes.porcentaje.plot.bar(figsize=(10, 5), ylabel='Valores ausentes (%)')
     figura('B04_missingness', 'Disponibilidad de las variables de SPAQ')
```



6. Contenidos idénticos y escenas

En este conjunto cada SHA-256 repetido aparece en dos archivos. Se comparan los MOS y los nueve pesos de escena entre el primer y el último nombre de archivo de cada pareja.

[ ]:
```
base = notas[['MOS']].join(escenas).join(huellas)
assert huellas.value_counts().max() == 2
a = base[base.SHA256.duplicated(keep='last')].set_index('SHA256')
b = base[base.SHA256.duplicated()].set_index('SHA256').loc[a.index]
pares = pd.DataFrame({'mos_a': a.MOS, 'mos_b': b.MOS})
pares['diferencia'] = (pares.mos_b - pares.mos_a).abs()
pares['MOS_distinto'] = pares.diferencia > 1e-9
pares['escena_distinta'] = ~np.isclose(a[escenas.columns], b[escenas.columns],
                                       atol=1e-9, rtol=0).all(axis=1)
tabla('duplicate_mos_disagreement', pares)
print('Contenidos únicos:', huellas.nunique(), '| Pares idénticos:', len(pares))
print('Pares discrepantes:', pares[['MOS_distinto', 'escena_distinta']].sum().
 ↪to_dict())
print('Diferencia MOS mediana y máxima:', pares.diferencia.median(), pares.
 ↪diferencia.max())
```

SHA256	mos_a	…	escena_distinta
87449e59dde2290290d4178fec6ef41edde506f6545a601…	49.14	…	False
32989d82f5a9ab9dc2b6dec5f8b12d3e62a855dbc5d9d54…	38.88	…	True
210e42611b959cabce273efaab5076f206980bd42f0c66e…	61.42	…	False
ef7467a631276698c77234c3edd29c58df0b85e48bbfffd…	33.77	…	True
904ec15b2e5c0e3c3cecf86200fa2b824a998abcfc3db75…	62.25	…	False
…	…	…	…
9becae6f85f022c4c9f2b8e5ac0f5558ea4d2d6c0af0911…	32.50	…	False
d300ec253efa10d9d4462b108ffaa62a2a81614404a41c6…	28.67	…	False
fc132a9550991a7aba47a638bb57dc5c00739e91156f9c3…	27.50	…	True
e2f7334567c6ea76ced3f8c708ebf1ac9a995f0d796177c…	28.00	…	False
437dd930522bd9eec2ed7e9ee65410e313ec931acf69e74…	67.67	…	True

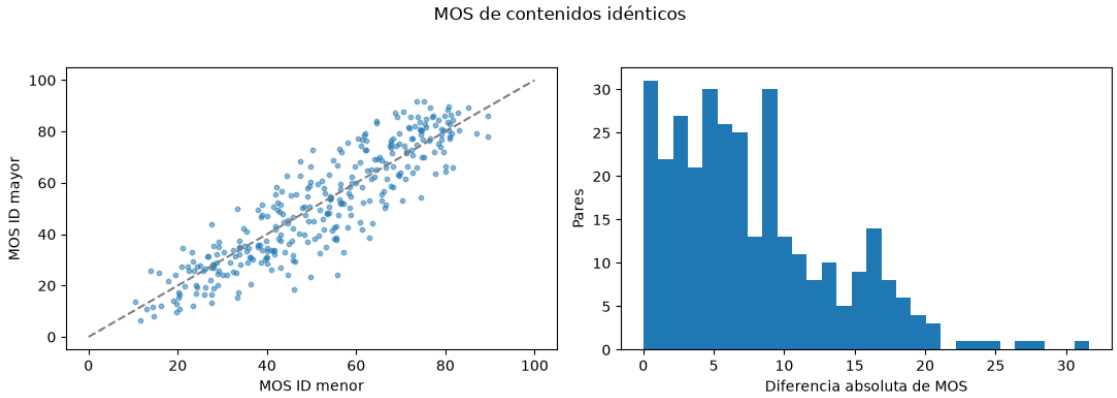
[322 rows x 5 columns]

```
Contenidos únicos: 10803 | Pares idénticos: 322
Pares discrepantes: {'MOS_distinto': 321, 'escena_distinta': 98}
Diferencia MOS mediana y máxima: 6.574999999999999 31.659999999999997
```

Figura 3. Diferencias de MOS entre archivos idénticos

[ ]:
```
fig, ejes = plt.subplots(1, 2, figsize=(11, 4))
ejes[0].scatter(pares.mos_a, pares.mos_b, s=10, alpha=.5)
ejes[0].plot([0, 100], [0, 100], '--', color='gray')
ejes[0].set(xlabel='MOS ID menor', ylabel='MOS ID mayor')
ejes[1].hist(pares.diferencia, bins=30)
ejes[1].set(xlabel='Diferencia absoluta de MOS', ylabel='Pares')
```

```
figura('B06_duplicate_disagreement', 'MOS de contenidos idénticos')
```



Comparación ponderada de escenas

Se mantienen los nueve pesos originales. El tamaño efectivo de Kish es la suma de pesos al cuadrado dividida por la suma de los pesos cuadrados. Los empates no se resuelven asignando una escena única.

[ ]:
```
filas = []
for escena in escenas:
    peso = escenas[escena]
    filas.append([escena, (peso > 0).sum(), peso.sum(),
                  peso.sum() ** 2 / (peso ** 2).sum(), np.average(notas.MOS,␣
 ↪weights=peso)])
campos_escena = ['scene', 'N_positive', 'weight_sum', 'kish_n_eff',␣
 ↪'MOS_weighted_mean']
tabla('scene_weight_summary', pd.DataFrame(filas, columns=campos_escena))
empates = escenas.eq(escenas.max(axis=1), axis=0).sum(axis=1) > 1
print('Imágenes con empate de escena:', empates.sum())
```

	scene	N_positive	weight_sum	kish_n_eff	MOS_weighted_mean
0	animal	146	111.999997	130.666662	60.188914
1	cityscape	3114	2331.783298	2784.202123	54.082830
2	human	1589	1079.949957	1388.135699	53.363862
3	indoor_scene	1150	798.949956	998.516892	47.344612
4	landscape	1488	1215.999979	1360.309078	58.115650
5	night_scene	969	806.866652	889.780767	37.953068
6	plant	1776	1359.666627	1586.218310	52.918024
7	still_life	3347	2910.166623	3128.517199	50.860471
8	others	581	509.616660	544.949471	20.063345

```
Imágenes con empate de escena: 2771
```

7. Correlaciones y redundancia

Pearson describe asociación lineal y Spearman asociación de rangos. Se ordenan los resultados por magnitud de Spearman; los mapas de calor agrupan las variables por familia y escala. Estas son asociaciones marginales descriptivas, con dependencia entre archivos repetidos.

[ ]:
```
familias = {'regional': 'tile_', 'color': 'hsv_ rgb_ lab_ color_entropy',
            'spatial_texture': 'gradient_ laplacian_ lbp_ neighbor_',
            'frequency': 'fft_', 'geometry': 'analysis_'}
def familia(nombre):
    medida = re.sub(r'^s\d+_', '', nombre)
    for grupo, prefijos in familias.items():
        if medida.startswith(tuple(prefijos.split())):
            return grupo
    return 'tonal'
correlaciones = pd.DataFrame(index=rasgos.columns)
correlaciones.index.name = 'descriptor'
correlaciones['family'] = correlaciones.index.map(familia)
correlaciones['scale'] = correlaciones.index.str.extract(r'^s(\d+)_',␣
 ↪expand=False).fillna('512')
correlaciones['scale'] = correlaciones.scale.astype(int)
correlaciones['pearson_r'] = rasgos.corrwith(notas.MOS)
correlaciones['spearman_rho'] = rasgos.corrwith(notas.MOS, method='spearman')
correlaciones['n_valid'] = rasgos.count()
correlaciones = correlaciones.sort_values('spearman_rho', key=abs,␣
 ↪ascending=False)
correlaciones.to_csv(salida / 'eda_tables/feature_mos_correlations.csv')
display(correlaciones.head(8))
matriz = rasgos.corr(method='spearman')
orden = correlaciones.sort_values(['family', 'scale', 'descriptor']).index
redundantes = (matriz.abs().ge(.9).to_numpy().sum() - len(rasgos.columns)) // 2
print('Pares de descriptores con |rho|  0,9:', redundantes)
```

descriptor	family	scale	…	spearman_rho	n_valid
s512_laplacian_var	spatial_texture	512	…	0.735819	11125
s256_laplacian_var	spatial_texture	256	…	0.698509	11125
gradient_p95	spatial_texture	512	…	0.672449	11125
neighbor_absdiff	spatial_texture	512	…	0.671370	11125
s512_fft_high_fraction	frequency	512	…	0.648264	11125
s512_gradient_mean	spatial_texture	512	…	0.618330	11125
s256_fft_high_fraction	frequency	256	…	0.577479	11125
s128_laplacian_var	spatial_texture	128	…	0.576584	11125

[8 rows x 5 columns]

```
Pares de descriptores con |rho|  0,9: 79
```

Figura 4. Las 68 asociaciones con MOS

[ ]:
```
plt.figure(figsize=(8, 15))
sns.heatmap(correlaciones.loc[orden, ['spearman_rho']], vmin=-1, vmax=1,␣
 ↪cmap='RdBu_r',
            yticklabels=True, cbar_kws={'label': 'Spearman rho'})
plt.yticks(fontsize=6)
figura('C01_feature_MOS', 'Asociaciones de los 68 descriptores con MOS')
```

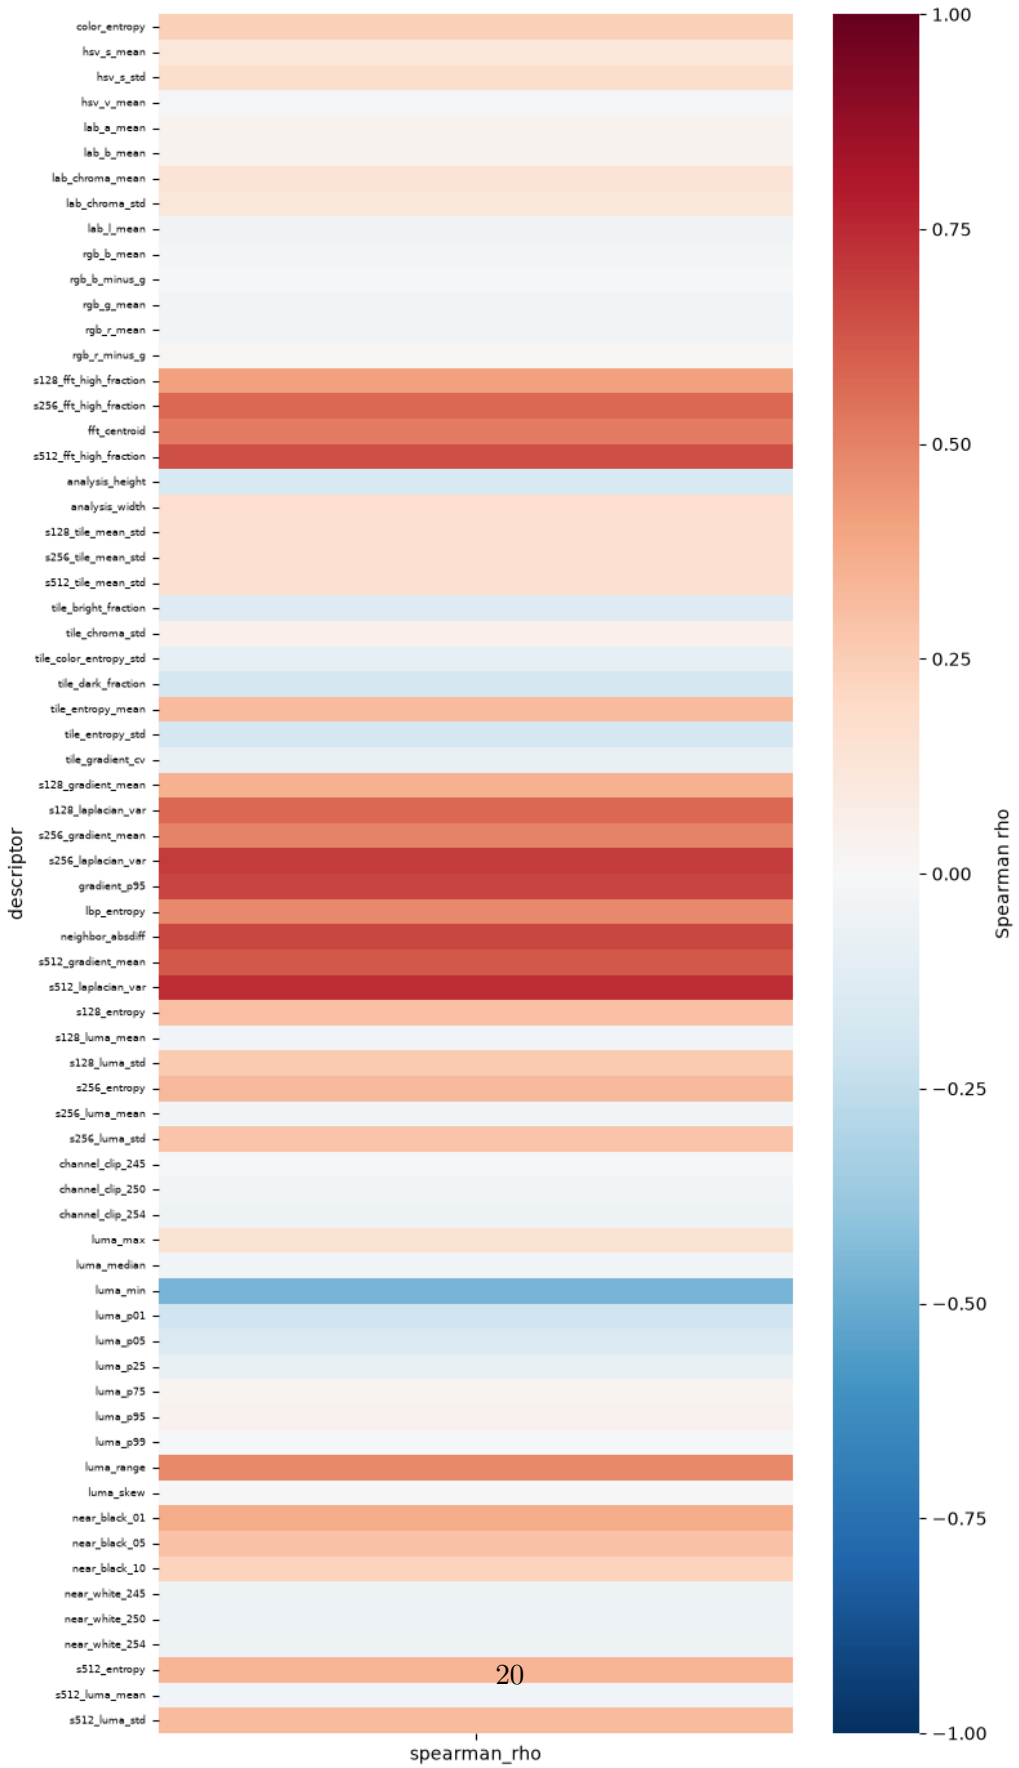

Asociaciones de los 68 descriptores con MOS
descriptor
color_entropy
hsv_s_mean
hsv_s_std
hsv_v_mean
lab_a_mean
lab_b_mean
lab_chroma_mean
lab_chroma_std
lab_l_mean
rgb_b_mean
rgb_b_minus_g
rgb_g_mean
rgb_r_mean
rgb_r_minus_g
s128_fft_high_fraction
s256_fft_high_fraction
fft_centroid
s512_fft_high_fraction
analysis_height
analysis_width
s128_tile_mean_std
s256_tile_mean_std
s512_tile_mean_std
tile_bright_fraction
tile_chroma_std
tile_color_entropy_std
tile_dark_fraction
tile_entropy_mean
tile_entropy_std
tile_gradient_cv
s128_gradient_mean
s128_laplacian_var
s256_gradient_mean
s256_laplacian_var
gradient_p95
lbp_entropy
neighbor_absdiff
s512_gradient_mean
s512_laplacian_var
s128_entropy
s128_luma_mean
s128_luma_std
s256_entropy
s256_luma_mean
s256_luma_std
channel_clip_245
channel_clip_250
channel_clip_254
luma_max
luma_median
luma_min
luma_p01
luma_p05
luma_p25
luma_p75
luma_p95
luma_p99
luma_range
luma_skew
near_black_01
near_black_05
near_black_10
near_white_245
near_white_250
near_white_254
s512_entropy
s512_luma_mean
s512_luma_std
spearman_rho
Spearman rho
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00

Figura 5. Las seis asociaciones de mayor magnitud

Cada panel incluye las 11.125 fotografías. Los ejes conservan las unidades de los descriptores; las diferencias entre MOS para valores semejantes de un descriptor se interpretan como dispersión, sin ajustar modelos ni atribuir causalidad.

```
[ ]: unidades = {'laplacian_var': 'luma²/pixel ', 'gradient_mean': 'luma/pixel',
                 'gradient_p95': 'luma/pixel', 'neighbor_absdiff': 'encoded luma',
                 'fft_high_fraction': 'fraction'}
     fig, ejes = plt.subplots(2, 3, figsize=(13, 8))
     for eje, nombre in zip(ejes.flat, correlaciones.head(6).index):
         eje.scatter(rasgos[nombre], notas.MOS, s=3, alpha=.1)
         unidad = unidades[re.sub(r'^s\d+_', '', nombre)]
         eje.set(xlabel=nombre + ' [' + unidad + ']', ylabel='MOS (0-100)')
         eje.set_title(f'rho={correlaciones.loc[nombre, "spearman_rho"]:.3f};␣
      ↪N={len(notas)}')
     figura('C02_scatter_top6', 'Seis asociaciones marginales de mayor magnitud')
```

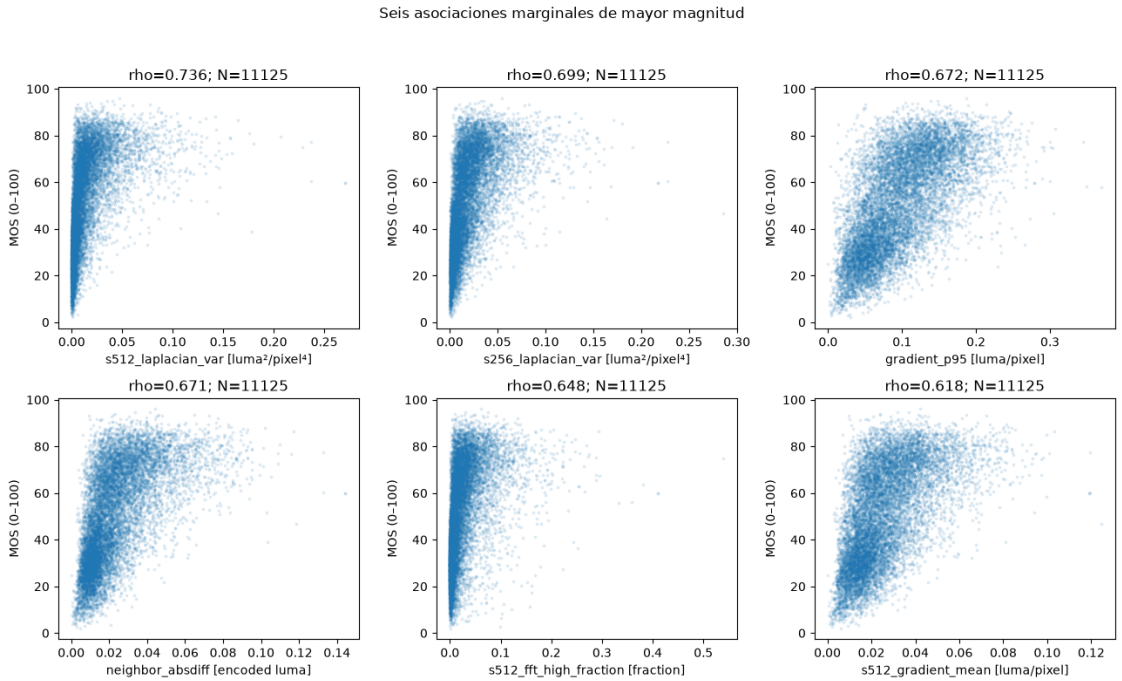
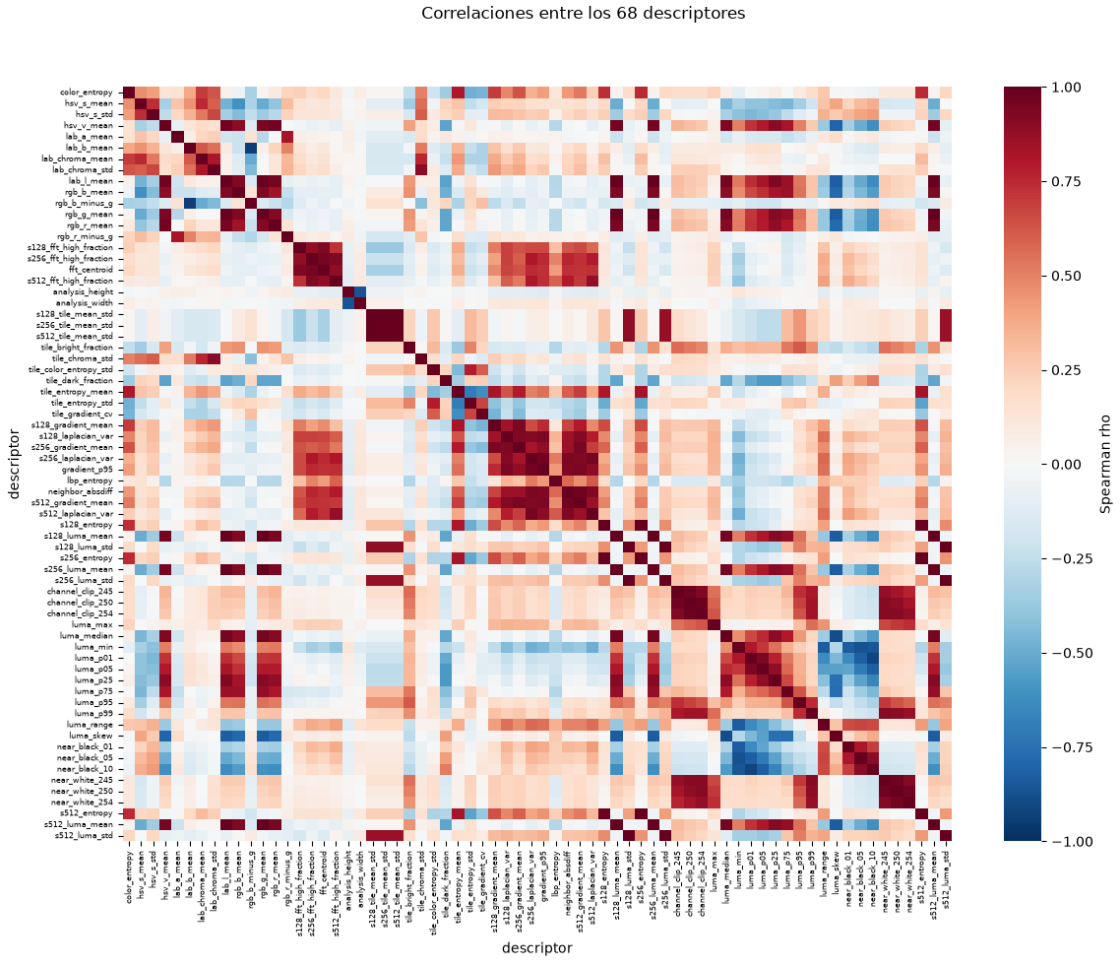


Figura 6. Redundancia de los 68 descriptores

```
[ ]: plt.figure(figsize=(12, 10))
sns.heatmap(matriz.loc[orden, orden], vmin=-1, vmax=1, cmap='RdBu_r',
            xticklabels=True, yticklabels=True, cbar_kws={'label': 'Spearman␣
 ↪rho'})
plt.xticks(rotation=90, fontsize=6)
plt.yticks(fontsize=6)
figura('C04_feature_redundancy', 'Correlaciones entre los 68 descriptores')
```



8. Comparación de escalas y completitud EXIF

Las siete medidas básicas se comparan entre los tres pares de escalas. El contraste chi cuadrado compara modelo de cámara y completitud de adquisición. Se agrupan los modelos con menos de 50 imágenes. Se repite el contraste conservando todas las filas, el primer ID y el último ID de cada SHA-256. V de Cramér resume la intensidad de esta asociación binaria.

[ ]:
```
filas = []
for medida in CORE:
    for a, b in itertools.combinations((512, 256, 128), 2):
        na, nb = f's{a}_{medida}', f's{b}_{medida}'
        filas.append([medida, a, b, matriz.loc[na, nb],
                      correlaciones.loc[na, 'spearman_rho'], correlaciones.
 ↪loc[nb, 'spearman_rho']])
columnas = ['definition', 'scale_a', 'scale_b', 'spearman_between_scales',
            'MOS_spearman_a', 'MOS_spearman_b']
tabla('scale_stability', pd.DataFrame(filas, columns=columnas))
conteos = nativo.model.value_counts()
comunes = conteos[conteos >= 50].index
filas = []
for conservar in ('todas', 'first', 'last'):
    muestra = nativo
    if conservar != 'todas':
        muestra = nativo.loc[huellas.drop_duplicates(keep=conservar).index]
    modelo = muestra.model.where(muestra.model.isin(comunes),␣
 ↪'OTHER_RARE_DEVICE')
    observados = pd.crosstab(modelo, muestra.acquisition_complete)
    chi, p, grados, esperado = stats.chi2_contingency(observados,␣
 ↪correction=False)
    filas.append([conservar, len(muestra), chi, grados, np.sqrt(chi /␣
 ↪len(muestra)),
                  esperado.min(), 100 * (esperado < 5).mean()])
columnas = ['choice', 'N', 'chi2', 'df', 'cramers_V', 'expected_min',␣
 ↪'percent_expected_lt5']
tabla('chi_square_tests', pd.DataFrame(filas, columns=columnas))
```

	definition	scale_a	…	MOS_spearman_a	MOS_spearman_b
0	luma_mean	512	…	-0.037411	-0.037405
1	luma_mean	512	…	-0.037411	-0.037341
2	luma_mean	256	…	-0.037405	-0.037341
3	luma_std	512	…	0.314089	0.288117
4	luma_std	512	…	0.314089	0.258218
5	luma_std	256	…	0.288117	0.258218
6	gradient_mean	512	…	0.618330	0.495166
7	gradient_mean	512	…	0.618330	0.351772
8	gradient_mean	256	…	0.495166	0.351772
9	laplacian_var	512	…	0.735819	0.698509
10	laplacian_var	512	…	0.735819	0.576584
11	laplacian_var	256	…	0.698509	0.576584
12	fft_high_fraction	512	…	0.648264	0.577479
13	fft_high_fraction	512	…	0.648264	0.408941
14	fft_high_fraction	256	…	0.577479	0.408941
15	tile_mean_std	512	…	0.163497	0.163495
16	tile_mean_std	512	…	0.163497	0.163493

```
17      tile_mean_std      256  …        0.163495        0.163493
18            entropy      512  …        0.338336        0.324852
19            entropy      512  …        0.338336        0.303529
20            entropy      256  …        0.324852        0.303529

[21 rows x 6 columns]
```

```
  choice      N          chi2  …  cramers_V  expected_min  percent_expected_lt5
0  todas  11125  10599.055177  …   0.976076     12.755056                   0.0
1  first  10803  10286.102479  …   0.975783     10.526243                   0.0
2   last  10803  10286.102479  …   0.975783     10.526243                   0.0

[3 rows x 7 columns]
```