Integridad de datos e ingeniería de características en la base de datos *Smartphone Photography Attribute and Quality*:

Evidencia sobre anotaciones discordantes, representación tonal y validación independiente por contenido

Curso: Ciencia de Datos

Maestría en Inteligencia Artificial

Universidad de La Salle

Estudiante: Carlos Mario Garzón

Docente: Fabián Camilo Castro

Bogotá · 2 de noviembre de 2026

Resumen

El análisis de 11.125 fotografías de la base de datos *Smartphone Photography Attribute and Quality* (SPAQ) permitió establecer tres resultados relevantes para la preparación científica de datos. Primero, 322 parejas de archivos binariamente idénticos revelaron que 321 contenidos recibieron puntuaciones perceptuales discordantes, distinguiendo la identidad de imagen de la variabilidad de anotación. Segundo, el diagnóstico de metadatos y descriptores cuantificó ceros ambiguos, ausencias y valores extremos, justificando su conservación y el escalamiento robusto sin modificaciones arbitrarias de las fotografías. Tercero, dos características interpretables de heterogeneidad regional y amplitud tonal se evaluaron mediante ablación: su incorporación conjunta redujo el error absoluto medio (MAE) de validación de 12,5544 a 12,5055 puntos, una ganancia modesta de 0,0489. La partición por huellas SHA-256 mantuvo separados los contenidos idénticos entre entrenamiento (8.364), validación (1.365) y prueba reservada (1.396). Un modelo de referencia permitió comprobar utilidad predictiva conjunta de los descriptores (R^2 = 0,4529). El estudio aporta evidencia cuantitativa sobre qué las características asociadas a la calidad que condicionan la interpretación de SPAQ, qué tratamientos resultan justificables y cuánto añaden las características derivadas.

1. Introducción

La calidad de una fotografía es una valoración multidimensional que incluye la valoración por un observador de una imagen que representa visualmente una escena. Un observador digital, como un algoritmo, puede valorar aspectos predefinidos relacionados con la calidad de la imagen (resolución, nitidez, ruido, y un largo etcétera), aunque no existe un índice universal que pondere tales índices. Un observador de hasta qué punto una imagen representa visualmente una escena de manera satisfactoria para un observador, humano puede valorar también estos atributos, de una forma menos reproducible, y otros relacionados con la composición, la originalidad, etcétera. Este trabajo se centra en la ***calidad perceptual***, la que es una consecuencia de cómo un observador juzga la imagen resultante desde un compuesto subjetivo que implica las propiedades técnicas, el contenido visual y de cómo el sistema visual humano percibe sus degradaciones o mejoras. Por ejemplo, una desviación cromática puede resultar casi imperceptible en una escena y muy evidente en otra.

La calidad perceptual de una fotografía es una consecuencia del proceso entero desde la captura, el procesamiento computacional, la escena representada y las valoraciones humanas. Ninguna característica digital aislada equivale a ese juicio. El conjunto *Smartphone Photography Attribute and Quality* (SPAQ), desarrollado por Fang et al. (2020), permite examinar esas relaciones mediante fotografías reales, puntuaciones medias de opinión (Mean Opinion Score, MOS), categorías de escena y metadatos de adquisición.

SPAQ ofrece una oportunidad científica específica: examinar la correspondencia entre registros, imágenes y valoraciones antes de construir modelos. Cuando dos registros comparten exactamente los mismos píxeles pero muestran puntuaciones distintas, la variación observada no procede de diferencias en el contenido digital. Del mismo modo, un valor EXIF igual a cero puede ser una codificación legítima o una señal de información no interpretable, y un descriptor extremo puede representar una escena singular en lugar de un error de medida. Distinguir estos casos evita que las operaciones de preparación oculten información relevante.

El estudio se concentra, por tanto, en tres aportes verificables: identificar y cuantificar las fuentes de heterogeneidad del conjunto; justificar una representación que preserve las observaciones y permita una evaluación independiente por contenido; y comprobar si dos nuevos descriptores tonales aportan información predictiva adicional. Los modelos sencillos cumplen una función instrumental: contrastan la utilidad de esa representación, sin sustituir el análisis científico de los datos.

La pregunta de investigación es: ¿qué revela el diagnóstico de integridad y de las variables digitales de SPAQ acerca de la fiabilidad de su representación, y cómo contribuyen las decisiones de preparación y las características derivadas a establecer una evaluación predictiva interpretable?

2. Objetivos

Objetivo general. Elaborar una representación analítica trazable de SPAQ que permita distinguir heterogeneidad de las anotaciones, problemas de metadatos y variabilidad genuina de los descriptores, y comprobar la utilidad de transformaciones justificadas para la evaluación inicial de calidad perceptual.

Objetivos específicos. (1) Cuantificar duplicados, discordancias perceptuales, valores faltantes, ceros ambiguos y extremos, interpretando sus consecuencias. (2) Definir y caracterizar dos descriptores tonales y medir su contribución incremental mediante una comparación controlada. (3) Establecer conjuntos separados por identidad de contenido y evaluar modelos de referencia sin fuga por duplicados.

3. Datos y metodología

3.1. Fuente, unidades y construcción de descriptores

Se integraron tres libros Excel originales de SPAQ —puntuaciones humanas, escenas y metadatos EXIF— y 11.125 imágenes JPEG, obtenidas el 24 de octubre de 2026. De sus píxeles se extrajeron 68 características tonales, cromáticas, espaciales, regionales y frecuenciales; las imágenes se orientaron según EXIF y se interpretaron en sRGB cuando correspondía. Las puntuaciones humanas y las escenas se reservaron como respuestas o variables de caracterización: no se incorporaron como atajos para predecir MOS.

La identificación por SHA-256 estableció una diferencia decisiva entre número de anotaciones e imágenes únicas: 11.125 registros corresponden a 10.803 contenidos, con 322 parejas idénticas. Entre ellas, 321 contienen MOS diferentes. Este hallazgo permite separar dos cuestiones que no deben confundirse: la repetición de contenidos puede contaminar una partición predictiva, mientras que las valoraciones discordantes expresan variación de anotación aun cuando la entrada visual es exactamente la misma.

3.2. Decisiones de preparación

La preparación de los datos se orientó a preservar la variabilidad original del conjunto y garantizar una interpretación consistente de sus registros. Se aplicó el criterio de 1,5 veces el intervalo intercuartílico (IQR) para identificar y cuantificar valores extremos, conservándolos como parte de la diversidad de las fotografías analizadas. Los valores iguales a cero y las ausencias en los metadatos EXIF se caracterizaron por separado, considerando el significado de cada campo y las particularidades

de los dispositivos de adquisición. En los catorce predictores del modelo principal no hubo sustituciones efectivas por imputación: este resultado delimita con precisión qué transformaciones cambiaron la representación y cuáles fueron salvaguardas preventivas.

3.3. Ingeniería de características y transformaciones

La ingeniería de variables produjo dos descriptores con significado complementario. La heterogeneidad regional relativa H = s512_tile_mean_std / s512_luma_std expresa cuánto varían los promedios tonales de 16 regiones respecto de la dispersión global, con denominador mayor que 10^{-8}. La amplitud tonal A = P95(Y) − P05(Y), con Y como luma digital normalizada, caracteriza el intervalo entre percentiles sin depender de los valores mínimo y máximo. Ambas variables amplían la descripción de la distribución tonal; su utilidad adicional se determinó empíricamente, no se supuso por su interpretabilidad.

Para preservar una comparación válida, el imputador de mediana y RobustScaler se ajustaron únicamente en entrenamiento. El escalamiento robusto permitió trabajar con descriptores de escalas diferentes sin suprimir fotografías de textura o contraste extremos. Como comprobación de codificación categórica, OneHotEncoder se ajustó con los dispositivos observados en entrenamiento; esta representación se mantuvo separada del modelo principal, basado en píxeles.

3.4. Partición y evaluación

El criterio de partición fue la identidad exacta del contenido, no únicamente el identificador del archivo. La asignación determinista por grupos SHA-256 (semilla 20261115) separó entrenamiento, validación y prueba reservada, evitando que una copia binaria apareciera en conjuntos diferentes. La composición de MOS y escenas se contrastó descriptivamente entre los conjuntos de desarrollo. Esta protección verificable contra fuga por duplicación no equivale a estratificación formal, que no se realizó, y no sustituye una evaluación externa.

4. Resultados de preparación y de ingeniería

4.1. Integridad y composición de las particiones

Subconjunto	Registros	Contenidos únicos	% registros
Entrenamiento	8.364	8.128	75,18
Validación	1.365	1.321	12,27
Prueba reservada	1.396	1.354	12,55
Total	11.125	10.803	100,00

La partición conservó las 11.125 anotaciones y obtuvo cero huellas SHA-256 compartidas entre conjuntos. El MOS en entrenamiento fue 50,3855 ± 20,9365 y en validación 49,5863 ± 20,5998. La similitud de estas distribuciones y de las prevalencias de escenas aporta una comprobación descriptiva útil del equilibrio obtenido, aunque no garantiza estratificación. El aporte metodológico verificable es haber conseguido independencia por identidad binaria sin borrar las anotaciones discordantes.

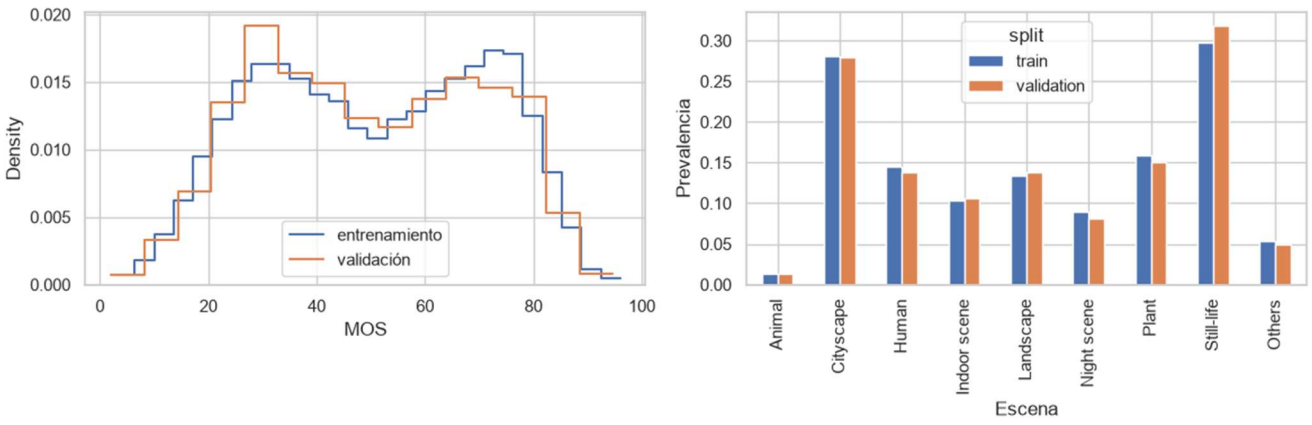


Figura 1. Distribución de MOS en entrenamiento y validación y prevalencias de las nueve escenas en ambos subconjuntos. El conjunto de prueba permanece reservado.

4.2. Ausencias, ceros y decisiones

Campo / fuente	Ausentes	Ceros	Decisión
Brightness (Excel)	0 (0 %)	7.585 (68,18 %)	Retener; valor no interpretado como ausencia
Flash (Excel)	0 (0 %)	10.860 (97,62 %)	Retener código; no predictor
Time (Excel)	0 (0 %)	378 (3,40 %)	Retener; revisar semántica
Unnamed: 8 (Excel)	0 (0 %)	630 (5,66 %)	Sin interpretación física acreditada
f_number (JPEG)	5 (0,045 %)	0	No entra al modelo MOS
exposure_time (JPEG)	13 (0,117 %)	0	No entra al modelo MOS
iso (JPEG)	12 (0,108 %)	0	No entra al modelo MOS
brightness (JPEG)	2.579 (23,18 %)	5.015 (45,08 %)	Separar ausencia de cero
flash (JPEG)	10 (0,090 %)	4.789 (43,05 %)	Código, no magnitud continua

El diagnóstico reveló que la completitud aparente de los metadatos puede resultar engañosa. En el Excel, Brightness contiene 7.585 ceros (68,18 %), mientras que el campo de brillo nativo JPEG presenta 2.579 ausencias (23,18 %) y 5.015 ceros (45,08 %). Estas cifras identifican una diferencia sustantiva entre ausencia explícita y valor registrado cuyo significado requiere comprobación. Conservarlos por separado impide introducir sustituciones arbitrarias. El modelo basado en píxeles no depende de estos campos y sus catorce predictores no necesitaron imputación.

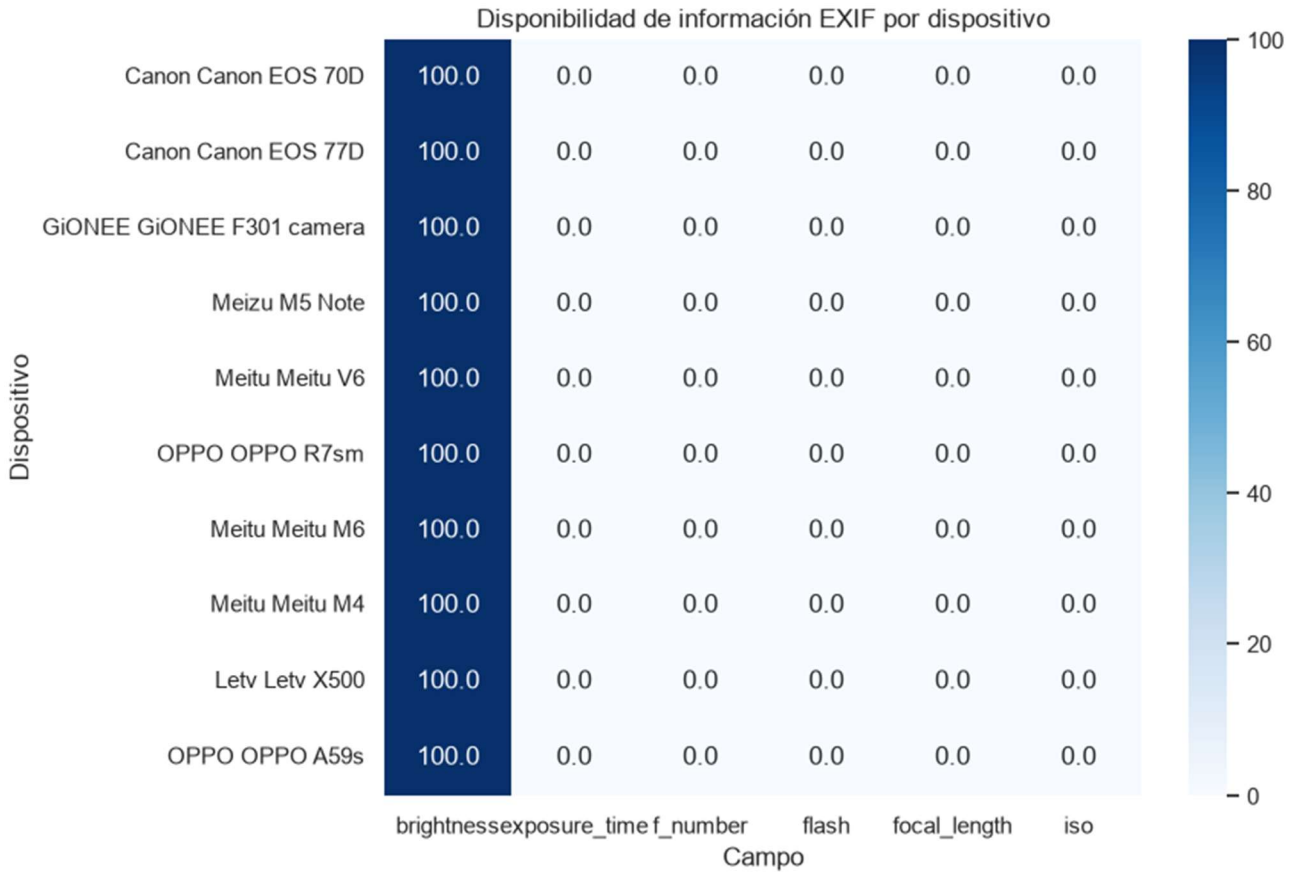


Figura 2. Porcentaje de valores ausentes en campos EXIF por dispositivo. La escala de 0 a 100 representa ausencia, no disponibilidad de metadatos; se conservan los porcentajes originales.

4.3. Incidencia cuantitativa de extremos

Descriptor	Fuera de 1,5 × IQR	Porcentaje
Media de luma	686	6,17 %
Desviación de luma	156	1,40 %
Gradiente medio	312	2,80 %
Varianza del Laplaciano	807	7,25 %
Fracción espectral alta	758	6,81 %
Saturación HSV media	288	2,59 %
Croma CIELAB medio	455	4,09 %
Entropía cromática	429	3,86 %
Heterogeneidad regional relativa	15	0,13 %
Amplitud tonal P95–P05	265	2,38 %

Los extremos se concentraron de forma desigual entre familias: la varianza del Laplaciano alcanzó 7,25 % de observaciones fuera del criterio IQR y la fracción de alta frecuencia 6,81 %, frente a 0,13 % para heterogeneidad relativa. Este contraste evidencia que los descriptores responden de forma diferente a la diversidad visual del corpus. En ausencia de verificación de error, conservar esas observaciones permite estudiar esa heterogeneidad en lugar de reducir artificialmente el dominio de escenas. El escalamiento robusto controla la escala numérica del ajuste sin borrar esos casos.

4.4. Características derivadas: magnitud observada y aporte

Variable	Media	Mediana	DE	P05–P95	Rango observado
Heterogeneidad relativa H	0,6527	0,6660	0,1514	0,3811–0,8748	0,1136–0,9745
Amplitud tonal A	0,6647	0,6947	0,1730	0,3254–0,8953	0–1

Las dos variables pudieron definirse en todas las fotografías. H mostró media 0,6527 y desviación estándar 0,1514; A registró media 0,6647 y desviación estándar 0,1730. Sus distribuciones documentan dos dimensiones tonales distintas: organización espacial relativa del contraste y amplitud de los tonos centrales. Esa descripción es valiosa aun si su capacidad predictiva incremental resulta pequeña, porque permite distinguir significado de una variable y rendimiento de un modelo.

Especificación de regresión	**MAE**	**RMSE**	**R^2**
Con 14 características	12,5055	15,2313	0,4529
Sin las dos derivadas (12)	12,5544	15,2717	0,4500

La ablación proporcionó una respuesta cuantitativa a esa distinción. El modelo con catorce características obtuvo MAE de 12,5055 y R^2 de 0,4529; al retirar conjuntamente H y A, el MAE fue 12,5544 y R^2 de 0,4500. La mejora de 0,0489 puntos MOS es pequeña respecto de un error absoluto cercano a 12,5 puntos. Así, el estudio no confunde una formulación interpretable con una aportación predictiva importante: demuestra el beneficio incremental observado y delimita su magnitud, sin atribuir efectos separados ni significación estadística no estimada.

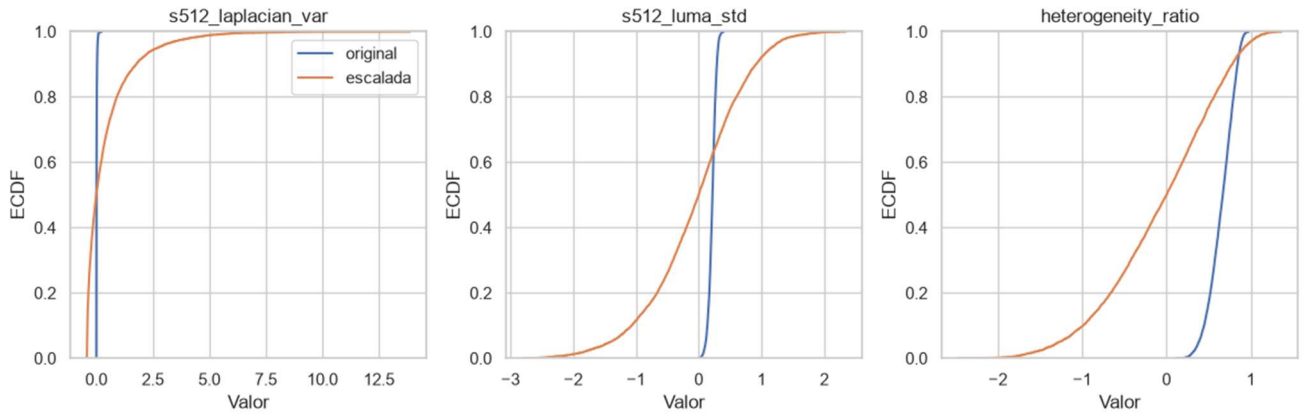


Figura 3. Distribuciones empíricas de descriptores antes y después del escalamiento robusto. El escalamiento no elimina ni recorta observaciones.

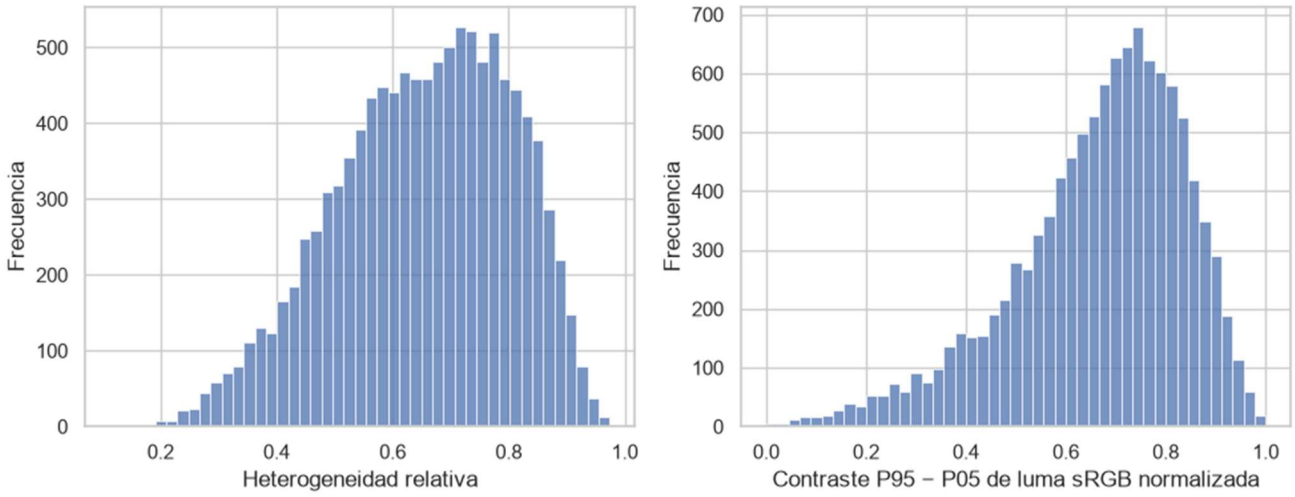


Figura 4. Distribuciones observadas de heterogeneidad regional relativa y amplitud tonal P95 − P05 de luma sRGB codificada normalizada, sobre las fotografías de SPAQ.

4.5. Codificación y composición del contenido

La codificación de dispositivo mostró que es posible transformar una variable categórica sin utilizar información de validación para aprender categorías: OneHotEncoder identificó 76 dispositivos en entrenamiento y produjo 76 columnas, sin categorías desconocidas en validación. Su exclusión del predictor principal preservó una comparación centrada en características de imagen. Las nueve escenas, por su parte, se conservaron como pertenencias simultáneas y no se redujeron artificialmente a una sola clase.

5. Modelos de referencia y discusión

5.1. Calidad perceptual: contraste frente a un predictor constante

Modelo	MAE	RMSE	R^2	n validación
Media de entrenamiento	17,9645	20,6078	−0,0015	1.365
Regresión lineal	12,5055	15,2313	0,4529	1.365

Como referencia predictiva, los catorce descriptores redujeron el MAE de 17,9645 puntos de un estimador constante a 12,5055 (30,4 %), con R^2 de 0,4529. El resultado confirma que su información conjunta permite estimar parte de la variación de MOS en validación. Su función en este estudio es

establecer un punto de partida cuantificado para comparaciones posteriores, no desplazar el resultado central sobre integridad, preparación y aporte de variables. La dispersión de predicciones indica que la representación todavía deja diferencias perceptuales relevantes por describir.

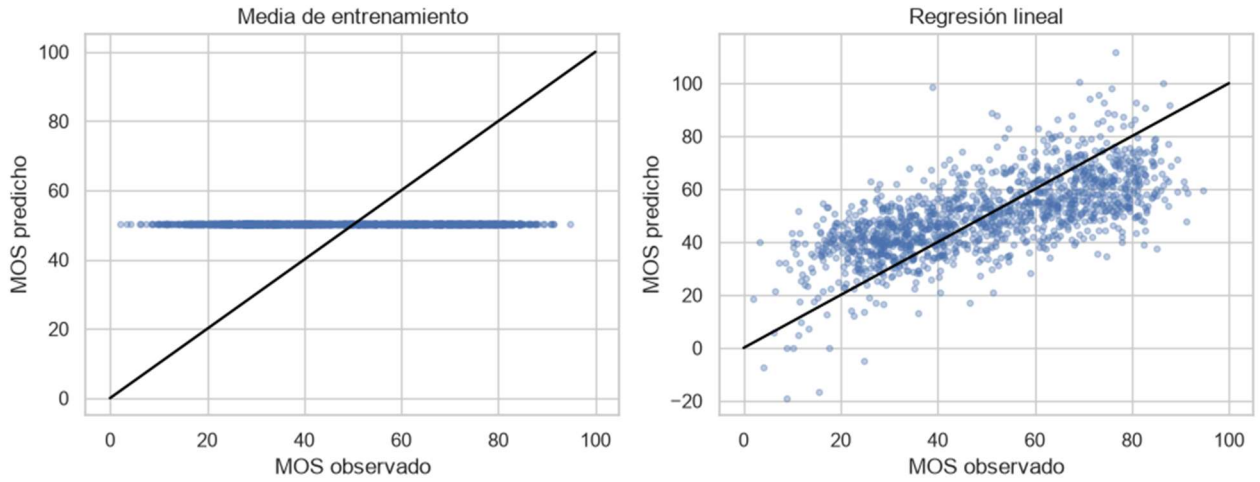


Figura 5. MOS observado y predicho por el estimador constante y la regresión lineal en validación. La diagonal representa coincidencia ideal.

5.2. Clasificación simultánea de escenas

Modelo	F1 micro	F1 macro	Precisión micro	Sensibilidad micro	Hamming
Ausencia en todas las escenas	0,0000	0,0000	0,0000	0,0000	0,1416
Regresión logística balanceada	0,4213	0,3936	0,2971	0,7236	0,2816

La clasificación multietiqueta permitió caracterizar un compromiso operativo: la regresión logística ponderada detectó una proporción elevada de escenas presentes (sensibilidad micro de 0,7236), pero con precisión micro de 0,2971. Aunque F1 micro alcanzó 0,4213, la pérdida de Hamming fue 0,2816 frente a 0,1416 del predictor que no asigna etiquetas. Esta comparación identifica una preferencia por recuperación de positivos a costa de falsos positivos y evita equiparar una mejora en F1 con

superioridad general. La variabilidad por escena, especialmente cuando hay pocos positivos, delimita el alcance del resultado.

5.3. Repetición de contenidos y estabilidad de evaluación

El análisis de duplicados permitió distinguir dos efectos estadísticos. La ponderación inversa por tamaño de grupo SHA redujo el MAE de evaluación de 12,5055 a 12,4529, y ponderar además el ajuste produjo 12,4490; bajo evaluación por registro y ajuste ponderado se obtuvo 12,5024. Estos cambios pequeños muestran que la multiplicidad exacta no domina el error agregado de esta validación. Simultáneamente, las 321 parejas con puntuaciones discordantes demuestran variación en el objetivo que no procede de diferencias binarias en la imagen. La estabilidad de una métrica global y la heterogeneidad de las anotaciones son resultados compatibles y conceptualmente distintos.

5.4. Alcance de la evidencia y decisiones metodológicas

El trabajo establece tres conocimientos conectados. Primero, una misma fotografía puede estar asociada a puntuaciones perceptuales diferentes, de modo que la unidad de contenido debe distinguirse de la unidad de anotación. Segundo, los extremos y ceros de metadatos no son automáticamente errores: cuantificarlos y conservarlos cuando su significado es incierto preserva la diversidad del conjunto. Tercero, el aporte de un descriptor debe medirse además de justificarse conceptualmente; aquí, dos variables definidas físicamente en términos de representación tonal agregaron una mejora predictiva pequeña. La separación por SHA y los transformadores ajustados solo en entrenamiento hacen que estas comparaciones sean metodológicamente interpretables.

El alcance está definido por la evidencia obtenida: las particiones evitan fuga por archivos idénticos, no por escenas visualmente semejantes; la asignación agrupada no fue una estratificación formal; la codificación de dispositivo se demostró por separado; y la evaluación corresponde a validación, con prueba reservada. Ninguna cifra permite atribuir causalidad a los descriptores ni generalizar a nuevos dispositivos. Estas distinciones identifican qué resultados están establecidos y qué contrastes corresponderían a estudios posteriores.

6. Conclusiones

1. El estudio descubrió que 321 de las 322 parejas de fotografías idénticas presentan MOS discordantes. El resultado distingue variabilidad de anotación e identidad de contenido y fundamenta una partición por SHA-256 que evita la fuga de copias exactas sin descartar observaciones.

2. La caracterización de faltantes, ceros y extremos permitió tomar decisiones basadas en evidencia: preservar códigos EXIF de semántica incierta, conservar escenas con descriptores extremos y ajustar escalas solo en entrenamiento. La distribución desigual de extremos entre familias aporta información sobre la heterogeneidad de representación del corpus.

3. La formulación de dos descriptores tonales produjo variables interpretables y una evaluación de su utilidad real. La ablación encontró una mejora conjunta pequeña (ΔMAE = 0,0489 puntos MOS), separando aporte conceptual y rendimiento incremental. Los modelos de referencia establecieron un punto de comparación para trabajos posteriores, mientras que el análisis de duplicados mostró que un MAE global estable puede coexistir con valoraciones humanas discordantes para imágenes idénticas.

Referencias

Fang, Y., Zhu, H., Zeng, Y., Ma, K., & Wang, Z. (2020). Perceptual Quality Assessment of Smartphone Photography. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 3677–3686. https://doi.org/10.1109/CVPR42600.2020.00373

SPAQ. Repositorio de los autores: https://github.com/h4nwei/SPAQ. Licencia MIT declarada por el responsable del repositorio el 20 de septiembre de 2023. La licencia de los archivos fotográficos individuales no se acredita de forma independiente en este trabajo.

Universidad de La Salle (2026). Guía detallada del Proyecto Integrador de Ciencia de Datos. Material docente del curso.

Anexo 1

Se anexa el script Python usado para este análisis, implementado en un cuaderno Jupyter. El script puede ser descargado desde

https://drive.google.com/file/d/1wWJ4S5vZtfrJEOhFT76Ohj8HqVm6TgIO/view?usp=sharing

1 SPAQ Fase 2

[1]:
```
from pathlib import Path
import hashlib, io, math
import cv2, matplotlib.pyplot as plt, numpy as np, pandas as pd, seaborn as sns
from IPython.display import display
from joblib import Parallel, delayed
from PIL import Image, ImageCms, ImageOps
from skimage.feature import local_binary_pattern
from sklearn.impute import SimpleImputer
from sklearn.linear_model import LinearRegression, LogisticRegression
from sklearn.metrics import␣
 ↪f1_score,hamming_loss,mean_absolute_error,mean_squared_error,precision_score,r2_score,recal
from sklearn.multioutput import MultiOutputClassifier
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import OneHotEncoder, RobustScaler

RAIZ = Path(r"D:\Data analisys")
SEMILLA = 20261115
SALIDA = RAIZ / "spaq_fase2_final_output"
SALIDA.mkdir(exist_ok=True)
DATOS = RAIZ / "spaq" / "SPAQ" / "Annotations"
EXCEL = {n:DATOS/n for n in ["MOS and Image attribute scores.xlsx","Scene␣
 ↪category labels.xlsx","EXIF_tags.xlsx"]}
IMAGENES = RAIZ / "spaq" / "SPAQ" / "TestImage"
assert all(p.is_file() for p in EXCEL.values()) and len(list(IMAGENES.glob("*.
 ↪jpg"))) == 11125
cv2.setNumThreads(1)
SRGB = ImageCms.createProfile("sRGB")
```

1.1 Descriptores de imagen

Orientación EXIF, conversión ICC a sRGB cuando procede y 68 descriptores exactos en tres escalas. Esta es la única parte extensa porque define las mediciones que sustentan el análisis.

[2]:
```
```

```
ESCENAS = ["Animal", "Cityscape", "Human", "Indoor scene", "Landscape", "Night␣
 ↪scene", "Plant", "Still-life", "Others"]
PREDICTORES = ["s512_luma_mean", "s512_luma_std", "heterogeneity_ratio",␣
 ↪"luma_p95_minus_p05",
               "s512_gradient_mean", "s512_laplacian_var",␣
 ↪"s512_fft_high_fraction", "s512_entropy",
               "hsv_s_mean", "lab_chroma_mean", "color_entropy",␣
 ↪"neighbor_absdiff", "lbp_entropy", "tile_entropy_std"]
BASE = ["luma_mean", "luma_std", "gradient_mean", "laplacian_var",␣
 ↪"fft_high_fraction", "tile_mean_std", "entropy"]
EXTRA = ["analysis_width", "analysis_height", "luma_median", "luma_min",␣
 ↪"luma_max", "luma_range", "luma_skew",
         "gradient_p95", "tile_gradient_cv", "tile_dark_fraction",␣
 ↪"tile_bright_fraction", "tile_entropy_mean",
         "tile_entropy_std", "hsv_s_mean", "hsv_s_std", "hsv_v_mean",␣
 ↪"rgb_r_mean", "rgb_g_mean", "rgb_b_mean",
         "rgb_r_minus_g", "rgb_b_minus_g", "lab_l_mean", "lab_a_mean",␣
 ↪"lab_b_mean", "lab_chroma_mean",
         "lab_chroma_std", "tile_chroma_std", "color_entropy",␣
 ↪"tile_color_entropy_std", "lbp_entropy",
         "neighbor_absdiff", "fft_centroid"]
DESCRIPTORES = [f"s{s}_{n}" for s in (512, 256, 128) for n in BASE] + EXTRA
DESCRIPTORES += [f"luma_p{p:02}" for p in (1, 5, 25, 75, 95, 99)]
DESCRIPTORES += [f"near_black_{p:02}" for p in (1, 5, 10)]
DESCRIPTORES += [x for p in (245, 250, 254) for x in (f"near_white_{p}",␣
 ↪f"channel_clip_{p}")]
assert len(DESCRIPTORES) == 68 and len(PREDICTORES) == 14

def entropia(a, bins=256):
    c = np.histogram(a, bins=bins, range=(0, 1))[0]
    p = c[c > 0] / c.sum()
    return float(-(p * np.log2(p)).sum())

def bloques(a):
    return [q for fila in np.array_split(a, 4, axis=0) for q in np.
 ↪array_split(fila, 4, axis=1)]

def espectro(y):
    alto, ancho = y.shape
    potencia = np.abs(np.fft.rfft2((y-y.mean()) * np.outer(np.hanning(alto), np.
 ↪hanning(ancho)), norm="ortho")) ** 2
    pesos = np.full(potencia.shape[1], 2.0)
    pesos[0] = 1
    if ancho % 2 == 0: pesos[-1] = 1
    potencia *= pesos[None, :]
    potencia[0, 0] = 0
```

```
    radio = np.hypot(np.fft.fftfreq(alto)[:, None], np.fft.
↪rfftfreq(ancho)[None, :])
    total = potencia.sum()
    return (None, None) if total <= 1e-20 else (float(potencia[radio >= .25].
↪sum()/total), float((potencia*radio).sum()/total))
```

[3]:
```
def entropia_color(rgb):
    q = np.minimum((rgb*8).astype(np.int32), 7)
    c = np.bincount((q[:,:,0]*64 + q[:,:,1]*8 + q[:,:,2]).ravel(),␣
↪minlength=512)
    p = c[c > 0] / c.sum()
    return float(-(p*np.log2(p)).sum())
```

[4]:
```
def extraer(imagen):
    r = {}
    for escala in (512, 256, 128):
        w, h = imagen.size
        f = min(1, escala/max(w, h))
        rgb = np.asarray(imagen.resize((max(1, round(w*f)), max(1,␣
↪round(h*f))), Image.Resampling.LANCZOS), dtype=np.float32)/255
        y = rgb @ np.array([.2126, .7152, .0722], dtype=np.float32)
        gx = cv2.Sobel(y, cv2.CV_32F, 1, 0, ksize=3, borderType=cv2.
↪BORDER_REFLECT_101)/8
        gy = cv2.Sobel(y, cv2.CV_32F, 0, 1, ksize=3, borderType=cv2.
↪BORDER_REFLECT_101)/8
        grad = np.hypot(gx, gy)
        yt = bloques(y)
        medias = np.array([q.mean() for q in yt])
        alta, centro = espectro(y)
        p = f"s{escala}_"
        r.update({p+"luma_mean": float(y.mean()), p+"luma_std": float(y.std()),␣
↪p+"gradient_mean": float(grad.mean()),
                  p+"laplacian_var": float(cv2.Laplacian(y, cv2.CV_32F,␣
↪ksize=1, borderType=cv2.BORDER_REFLECT_101).var()),
                  p+"fft_high_fraction": alta, p+"tile_mean_std": float(medias.
↪std()), p+"entropy": entropia(y)})
        if escala != 512: continue
        sd = float(y.std())
        r.update(analysis_width=y.shape[1], analysis_height=y.shape[0],␣
↪luma_median=float(np.median(y)), luma_min=float(y.min()),
                 luma_max=float(y.max()), luma_range=float(np.ptp(y)),␣
↪luma_skew=float(np.mean((y-y.mean())**3)/sd**3) if sd > 1e-8 else None)
        for n, v in zip((1,5,25,75,95,99), np.percentile(y, (1,5,25,75,95,99))):
↪ r[f"luma_p{n:02}"] = float(v)
        for n in (1,5,10): r[f"near_black_{n:02}"] = float(np.mean(y <= n/255))
        for n in (245,250,254):
```

```
            r[f"near_white_{n}"] = float(np.mean(y >= n/255))
            r[f"channel_clip_{n}"] = float(np.mean(rgb.max(axis=2) >= n/255))
        gt = np.array([q.mean() for q in bloques(grad)])
        et = np.array([entropia(q) for q in yt])
        hsv, lab = cv2.cvtColor(rgb, cv2.COLOR_RGB2HSV), cv2.cvtColor(rgb, cv2.
↪COLOR_RGB2Lab)
        chroma, cm = np.hypot(lab[:,:,1], lab[:,:,2]), rgb.mean(axis=(0,1))
        r.update(gradient_p95=float(np.percentile(grad,95)),␣
↪tile_gradient_cv=float(gt.std()/gt.mean()) if gt.mean()>1e-8 else None,
                 tile_dark_fraction=float(np.mean(medias<.1)),␣
↪tile_bright_fraction=float(np.mean(medias>.9)), tile_entropy_mean=float(et.
↪mean()),
                 tile_entropy_std=float(et.std()), fft_centroid=centro,␣
↪hsv_s_mean=float(hsv[:,:,1].mean()), hsv_s_std=float(hsv[:,:,1].std()),
                 hsv_v_mean=float(hsv[:,:,2].mean()), rgb_r_mean=float(cm[0]),␣
↪rgb_g_mean=float(cm[1]), rgb_b_mean=float(cm[2]),
                 rgb_r_minus_g=float(cm[0]-cm[1]),␣
↪rgb_b_minus_g=float(cm[2]-cm[1]), lab_l_mean=float(lab[:,:,0].mean()),
                 lab_a_mean=float(lab[:,:,1].mean()), lab_b_mean=float(lab[:,:
↪,2].mean()), lab_chroma_mean=float(chroma.mean()),
                 lab_chroma_std=float(chroma.std()), tile_chroma_std=float(np.
↪std([q.mean() for q in bloques(chroma)])),
                 color_entropy=entropia_color(rgb),␣
↪tile_color_entropy_std=float(np.std([entropia_color(q) for q in␣
↪bloques(rgb)])),
                 neighbor_absdiff=float((np.abs(np.diff(y,axis=0)).mean()+np.
↪abs(np.diff(y,axis=1)).mean())/2))
        lbp = local_binary_pattern(np.round(y*255).astype(np.uint8), 8, 1,␣
↪"uniform")[1:-1,1:-1]
        c = np.bincount(lbp.astype(int).ravel(), minlength=10)
        p_lbp = c[c>0]/c.sum()
        r["lbp_entropy"] = float(-(p_lbp*np.log2(p_lbp)).sum())
    assert set(r) == set(DESCRIPTORES)
    return r
```

1.2 Entradas y procesamiento

Una lectura de cada JPEG obtiene descriptores, identidad SHA-256 y EXIF nativo. La paralelización se adapta al equipo mediante `n_jobs=-1`; no presupone un número fijo de núcleos ni usa GPU.

[5]:
```
ESCENAS = ["Animal", "Cityscape", "Human", "Indoor scene", "Landscape", "Night␣
 ↪scene", "Plant", "Still-life", "Others"]
PREDICTORES =␣
 ↪["s512_luma_mean","s512_luma_std","heterogeneity_ratio","luma_p95_minus_p05","s512_gradient
```

```
  ␣
 ↪"s512_laplacian_var","s512_fft_high_fraction","s512_entropy","hsv_s_mean","lab_chroma_mean"
human = pd.read_excel(EXCEL["MOS and Image attribute scores.xlsx"])
scene = pd.read_excel(EXCEL["Scene category labels.xlsx"])
exif = pd.read_excel(EXCEL["EXIF_tags.xlsx"], sheet_name="Source EXIF tags")
assert list(scene) == ["Image name", *ESCENAS] and len(human) == len(scene) ==␣
 ↪11125
for frame in (human, scene):
    frame["image_id"] = frame["Image name"].map(lambda x: Path(str(x)).stem.
 ↪zfill(5))
ids = sorted(human.image_id)

def procesar(image_id):
    ruta = IMAGENES / f"{image_id}.jpg"
    contenido = ruta.read_bytes()
    with Image.open(io.BytesIO(contenido)) as raw:
        raw.load()
        ex = raw.getexif()
        nested = ex.get_ifd(34665) if 34665 in ex else {}
        nativo = {"make": ex.get(271), "model": ex.get(272)}
        for nombre, tag in {"focal_length":37386, "f_number":33437,␣
 ↪"exposure_time":33434,
                            "iso":34855, "brightness":37379, "flash":37385}.
 ↪items():
            valor = nested.get(tag, ex.get(tag))
            try: nativo[nombre] = float(valor) if valor is not None else np.nan
            except (TypeError, ValueError, ZeroDivisionError): nativo[nombre] =␣
 ↪np.nan
        imagen = ImageOps.exif_transpose(raw)
        perfil = raw.info.get("icc_profile")
        try:
            if perfil:
                imagen = ImageCms.profileToProfile(imagen,ImageCms.
 ↪ImageCmsProfile(io.BytesIO(perfil)),SRGB,outputMode="RGB")
        except Exception:
            pass
        imagen = imagen.convert("RGB")
        valores = extraer(imagen)
    return {"image_id":image_id,"sha256":hashlib.sha256(contenido).
 ↪hexdigest(),**nativo,**valores}

imagenes = pd.
 ↪DataFrame(Parallel(n_jobs=-1,prefer="threads")(delayed(procesar)(i) for i in␣
 ↪ids))
imagenes.to_parquet(SALIDA/"descriptores_generados_en_ejecucion.
 ↪parquet",index=False)
```

```
for columna in ("make","model"):
    imagenes[columna] = imagenes[columna].fillna("Unknown").astype(str).str.
 ↪strip().str.strip("\x00")
imagenes["device"] = imagenes.make+" "+imagenes.model
assert len(imagenes)==11125 and set(DESCRIPTORES).issubset(imagenes)
```

1.3 Integración y particiones

Los duplicados exactos se agrupan por SHA-256. Las cinco valoraciones humanas auxiliares no entran en los modelos. La prueba se conserva sin predicciones ni métricas.

Familia	Variables	Uso
MOS y valoraciones humanas	6	MOS es la respuesta; las otras cinco se excluyen de los predictores
Escenas	9	Objetivos binarios simultáneos
EXIF fuente y APEX	16	Descripción de metadatos
Descriptores de píxel	68	Candidatos predictivos

Familia predictiva	Identificadores técnicos
Tono y contraste	s512_luma_mean, s512_luma_std, luma_p95_minus_p05
Heterogeneidad regional	heterogeneity_ratio, tile_entropy_std
Estructura y textura	s512_gradient_mean, s512_laplacian_var, neighbor_absdiff, lbp_entropy
Frecuencia y entropía	s512_fft_high_fraction, s512_entropy
Color	hsv_s_mean, lab_chroma_mean, color_entropy

`heterogeneity_ratio` divide la dispersión regional por la dispersión global solo cuando el denominador supera `1e-8`. `luma_p95_minus_p05` es la amplitud P95 − P05 de luma digital codificada sRGB normalizada; no representa luminancia física calibrada.

[6]:
```
datos = human.merge(scene, on=["image_id","Image name"], validate="one_to_one").
 ↪merge(imagenes, on="image_id", validate="one_to_one")
denominador = datos.s512_luma_std
datos["heterogeneity_ratio"] = np.where(denominador > 1e-8, datos.
 ↪s512_tile_mean_std / denominador, np.nan)
datos["luma_p95_minus_p05"] = datos.luma_p95 - datos.luma_p05

def asignar(sha):
    valor = int(hashlib.sha256(f"{SEMILLA}|{sha}".encode()).hexdigest()[:16],␣
 ↪16) / 2**64
```

```
    return "train" if valor < .75 else ("validation" if valor < .875 else␣
 ↪"test")

datos["split"] = datos.sha256.map(asignar)
analizables = datos.split.isin(["train","validation"])
for etiqueta in ESCENAS:
    datos[f"target_{etiqueta}"] = pd.Series(pd.NA,index=datos.
 ↪index,dtype="Int8")
    datos.loc[analizables,f"target_{etiqueta}"] = (datos.
 ↪loc[analizables,etiqueta] > 0).astype("int8")
grupos = datos.groupby("sha256").size()
datos["peso_sha"] = 1 / datos.sha256.map(grupos)
train, validacion, prueba = [datos[datos.split == s].copy() for s in␣
 ↪("train","validation","test")]
duplicados = datos.groupby("sha256").size().loc[lambda s:s > 1]
conteos = datos.split.value_counts()
assert [conteos[s] for s in ("train","validation","test")] == [8364,1365,1396]
assert datos.sha256.nunique()==10803 and len(duplicados)==322
assert sum(len(set(datos.loc[datos.split==a,"sha256"]) & set(datos.loc[datos.
 ↪split==b,"sha256"]))
           for a,b in␣
 ↪(("train","validation"),("train","test"),("validation","test"))) == 0
```

La asignación es determinista y agrupa contenidos idénticos por SHA-256, con cero cruces entre particiones. No constituye estratificación formal por MOS ni por escenas; ese control se declara **FAIL** y no se altera retrospectivamente la partición validada.

1.4 Modelos y tablas

Imputación y escalamiento se ajustan dentro de las tuberías con entrenamiento. La clasificación usa nueve regresiones logísticas balanceadas mediante `MultiOutputClassifier`. Como control metodológico secundario, una codificación categórica de dispositivo se ajusta solo con entrenamiento; no modifica los modelos principales.

[7]:
```
def preparar():
    return␣
 ↪Pipeline([("imputar",SimpleImputer(strategy="median",add_indicator=True)),("escalar",Robust

def reg_metricas(y,p,w=None):
    return [mean_absolute_error(y,p,sample_weight=w), math.
 ↪sqrt(mean_squared_error(y,p,sample_weight=w)),
            r2_score(y,p,sample_weight=w), np.average(p-y,weights=w)]

Xtr, Xva = train[PREDICTORES], validacion[PREDICTORES]
ytr, yva = train.MOS, validacion.MOS
lineal = Pipeline([("preparar",preparar()),("modelo",LinearRegression())]).
 ↪fit(Xtr,ytr)
```

```
pred_dummy, pred_lineal = np.full(len(yva),ytr.mean()), lineal.predict(Xva)
regresion = pd.DataFrame([["Dummy mean",*reg_metricas(yva,pred_dummy),len(yva)],
                          ["Linear",*reg_metricas(yva,pred_lineal),len(yva)]],
                         columns=["Modelo","MAE","RMSE","R²","Sesgo␣
 ↪medio","n"])
Ytr = train[[f"target_{e}" for e in ESCENAS]].to_numpy(dtype="int8")
Yva = validacion[[f"target_{e}" for e in ESCENAS]].to_numpy(dtype="int8")
logistica = Pipeline([("preparar",preparar()),("modelo",MultiOutputClassifier(
   ␣
 ↪LogisticRegression(max_iter=2000,class_weight="balanced",random_state=SEMILLA),n_jobs=1))])
 ↪fit(Xtr,Ytr)
pred_log = logistica.predict(Xva)
pred_trivial = np.zeros_like(Yva)
def class_metricas(p):
    return␣
 ↪[f1_score(Yva,p,average="micro",zero_division=0),f1_score(Yva,p,average="macro",zero_divisi
          ␣
 ↪precision_score(Yva,p,average="micro",zero_division=0),recall_score(Yva,p,average="micro",z
clasificacion = pd.
 ↪DataFrame([["Dummy",*class_metricas(pred_trivial)],["Logistic",*class_metricas(pred_log)]],
    columns=["Modelo","F1 micro","F1 macro","Precisión micro","Sensibilidad␣
 ↪micro","Pérdida de Hamming"])
por_escena = pd.DataFrame([[e,int(Yva[:,j].sum()),precision_score(Yva[:
 ↪,j],pred_log[:,j],zero_division=0),
    recall_score(Yva[:,j],pred_log[:,j],zero_division=0),f1_score(Yva[:
 ↪,j],pred_log[:,j],zero_division=0)]
    for j,e in enumerate(ESCENAS)],columns=["Escena","Casos␣
 ↪positivos","Precisión","Sensibilidad","F1"])
ponderado = Pipeline([("preparar",preparar()),("modelo",LinearRegression())]).
 ↪fit(
    Xtr,ytr,modelo__sample_weight=train.peso_sha)
pred_ponderado = ponderado.predict(Xva)
sensibilidad = pd.DataFrame([["Dummy mean","1/
 ↪n_SHA",*reg_metricas(yva,pred_dummy,validacion.peso_sha)[:3]],
    ["Linear","1/n_SHA",*reg_metricas(yva,pred_lineal,validacion.peso_sha)[:3]],
    ["Linear ajuste ponderado","registro",*reg_metricas(yva,pred_ponderado)[:
 ↪3]],
    ["Linear ajuste ponderado","1/
 ↪n_SHA",*reg_metricas(yva,pred_ponderado,validacion.peso_sha)[:3]]],
    columns=["Modelo","Ponderación al evaluar","MAE","RMSE","R²"])

sin_derivadas = [p for p in PREDICTORES if p not in␣
 ↪{"heterogeneity_ratio","luma_p95_minus_p05"}]
ablacion = Pipeline([("preparar",preparar()),("modelo",LinearRegression())]).
 ↪fit(train[sin_derivadas],ytr)
pred_ablacion = ablacion.predict(validacion[sin_derivadas])
```

```
ablacion_derivadas = pd.DataFrame([
    ["Modelo principal (14)",*reg_metricas(yva,pred_lineal)[:3]],
    ["Sin las 2 derivadas (12)",*reg_metricas(yva,pred_ablacion)[:
 ↪3]]],columns=["Especificación","MAE","RMSE","R²"])

codificador = OneHotEncoder(handle_unknown="ignore",sparse_output=False).
 ↪fit(train[["device"]])
Ztr, Zva = codificador.transform(train[["device"]]), codificador.
 ↪transform(validacion[["device"]])
dispositivos_desconocidos = (~validacion.device.isin(codificador.
 ↪categories_[0])).sum()
control_codificacion = pd.DataFrame([["Ajuste", "solo entrenamiento"],
    ["Categorías aprendidas",len(codificador.categories_[0])],["Columnas␣
 ↪generadas",Ztr.shape[1]],
    ["Filas de validación con categoría␣
 ↪desconocida",int(dispositivos_desconocidos)]],columns=["Control","Resultado"])
```

[8]:
```
filas_exif=[]
for c in ["Brightness","Flash","Time","Unnamed: 8"]:
    s=pd.to_numeric(exif[c],errors="coerce")
    filas_exif.append([c,"Excel fuente",int(s.isna().sum()),100*s.isna().
 ↪mean(),int(s.eq(0).sum()),100*s.eq(0).mean(),"conservar; no predictor"])
for c in ["f_number","exposure_time","iso","brightness","flash"]:
    s=imagenes[c]
    filas_exif.append([c,"JPEG nativo",int(s.isna().sum()),100*s.isna().
 ↪mean(),int(s.eq(0).sum()),100*s.eq(0).mean(),"ausente cero; no predictor"])
tabla_exif=pd.DataFrame(filas_exif,columns=["Campo","Fuente","Ausentes","%␣
 ↪ausentes","Ceros","% ceros","Tratamiento"])
particiones = datos.groupby("split").
 ↪agg(Registros=("image_id","size"),Contenidos_distintos=("sha256","nunique"))
particiones["% registros"] = particiones.Registros/len(datos)*100
particiones["% contenidos"] = particiones.Contenidos_distintos/datos.sha256.
 ↪nunique()*100
variables_outlier=["s512_luma_mean","s512_luma_std","s512_gradient_mean","s512_laplacian_var",
   ␣
 ↪"s512_fft_high_fraction","hsv_s_mean","lab_chroma_mean","color_entropy","heterogeneity_rati
filas_outlier=[]
for c in variables_outlier:
    q1,q3=datos[c].quantile([.25,.75]); iqr=q3-q1
    n=int(((datos[c] < q1-1.5*iqr)|(datos[c] > q3+1.5*iqr)).sum())
    filas_outlier.append([c,q1,q3,n,100*n/len(datos),"conservar"])
outliers=pd.DataFrame(filas_outlier,columns=["Variable","Q1","Q3","Fuera␣
 ↪1,5×IQR","%","Decisión"])
derivadas=[]
```

```
for c,definicion in [("heterogeneity_ratio","DE de medias de teselas / DE␣
 ↪global; denominador > 1e-8"),("luma_p95_minus_p05","P95 - P05 de luma␣
 ↪digital sRGB normalizada")]:
    s=datos[c]
    derivadas.append([c,definicion,int(s.isna().sum()),s.mean(),s.median(),s.
 ↪std(),s.quantile(.05),s.quantile(.95),s.min(),s.max()])
resumen_derivadas=pd.
 ↪DataFrame(derivadas,columns=["Variable","Definición","Indefinidos","Media","Mediana","DE","
mos_split=pd.DataFrame([["train",len(train),train.MOS.mean(),train.MOS.
 ↪std(),"descriptivo"],
    ["validation",len(validacion),validacion.MOS.mean(),validacion.MOS.
 ↪std(),"descriptivo"],
    ["test",len(prueba),np.nan,np.nan,"sellado"]],
    columns=["Partición","n","MOS medio","DE MOS","Uso"])
datos_desarrollo=datos.loc[datos.split.isin(["train","validation"])]
prevalencia_split=(datos_desarrollo.groupby("split")[[f"target_{e}" for e in␣
 ↪ESCENAS]].mean()*100).T
prevalencia_split.index=ESCENAS
tablas = {
"0 Resumen":pd.DataFrame([["Universo","11.125 filas y 10.803 SHA únicos"],
    ["Regresión lineal",f"MAE {regresion.iloc[1].MAE:.3f}; RMSE {regresion.
 ↪iloc[1].RMSE:.3f}; R² {regresion.iloc[1]['R²']:.4f}"],
    ["Clasificación logística",f"F1 micro {clasificacion.iloc[1]['F1 micro']:.
 ↪4f}; F1 macro {clasificacion.iloc[1]['F1 macro']:.4f}"],
    ["Control de fuga","0 SHA compartidos"],["Prueba","1.396 filas␣
 ↪selladas"]],columns=["Resultado","Valor"]),
"2 Operaciones":pd.DataFrame([["Observaciones␣
 ↪integradas",len(datos)],["Entrenamiento",len(train)],["Validación",len(validacion)],
    ["Prueba reservada",len(prueba)],["Heterogeneidad indefinida",int(datos.
 ↪heterogeneity_ratio.isna().sum())],
    ["Contraste fuera del dominio [0,1]",int(((datos.
 ↪luma_p95_minus_p05<0)|(datos.luma_p95_minus_p05>1)).sum())],
    ["Imputaciones en 14 predictores",int(datos[PREDICTORES].isna().sum().
 ↪sum())]],columns=["Operación","Cantidad"]),
"3 EXIF":tabla_exif,"4 Atípicos":outliers,"5 Derivadas":resumen_derivadas,
"6 Particiones":particiones.reset_index(),"7 MOS por partición":mos_split,"8␣
 ↪Prevalencia de escenas (%)":prevalencia_split,
"9 Codificación train-only":control_codificacion,"10 Regresión":regresion,"11␣
 ↪Ablación":ablacion_derivadas,
"12 Clasificación":clasificacion,"13 Escenas":por_escena,"14 Sensibilidad":
 ↪sensibilidad}
assert round(regresion.iloc[1].MAE,3)==12.505 and round(regresion.iloc[1].
 ↪RMSE,3)==15.231 and round(regresion.iloc[1]["R²"],4)==.4529
assert [round(clasificacion.iloc[1][c],4) for c in ["F1 micro","F1␣
 ↪macro","Pérdida de Hamming"]] == [.4213,.3936,.2816]
for nombre,tabla in tablas.items():
```

```
    print(nombre)
    display(tabla.round(4))
```

```
0 Resumen
```

	Resultado	Valor
0	Universo	11.125 filas y 10.803 SHA únicos
1	Regresión lineal	MAE 12.505; RMSE 15.231; R^2 0.4529
2	Clasificación logística	F1 micro 0.4213; F1 macro 0.3936
3	Control de fuga	0 SHA compartidos
4	Prueba	1.396 filas selladas

```
2 Operaciones
```

	Operación	Cantidad
0	Observaciones integradas	11125
1	Entrenamiento	8364
2	Validación	1365
3	Prueba reservada	1396
4	Heterogeneidad indefinida	0
5	Contraste fuera del dominio [0,1]	0
6	Imputaciones en 14 predictores	0

```
3 EXIF
```

	Campo	Fuente	Ausentes	% ausentes	Ceros	% ceros	Tratamiento
0	Brightness	Excel fuente	0	0.0000	7585	68.1798	conservar; no predictor
1	Flash	Excel fuente	0	0.0000	10860	97.6180	conservar; no predictor
2	Time	Excel fuente	0	0.0000	378	3.3978	conservar; no predictor
3	Unnamed: 8	Excel fuente	0	0.0000	630	5.6629	conservar; no predictor
4	f_number	JPEG nativo	5	0.0449	0	0.0000	ausente cero; no predictor
5	exposure_time	JPEG nativo	13	0.1169	0	0.0000	ausente cero; no predictor
6	iso	JPEG nativo	12	0.1079	0	0.0000	ausente cero; no predictor
7	brightness	JPEG nativo	2579	23.1820	5015	45.0787	ausente cero; no predictor
8	flash	JPEG nativo	10	0.0899	4789	43.0472	ausente cero; no predictor

```
4 Atípicos
```

	Variable	Q1	Q3	Fuera 1,5×IQR	%	Decisión
0	s512_luma_mean	0.3910	0.5644	686	6.1663	conservar

1	s512_luma_std	0.1789	0.2552	156	1.4022	conservar
2	s512_gradient_mean	0.0147	0.0329	312	2.8045	conservar
3	s512_laplacian_var	0.0017	0.0182	807	7.2539	conservar
4	s512_fft_high_fraction	0.0031	0.0330	758	6.8135	conservar
5	hsv_s_mean	0.1453	0.3039	288	2.5888	conservar
6	lab_chroma_mean	6.4354	14.6533	455	4.0899	conservar
7	color_entropy	3.7231	4.8089	429	3.8562	conservar
8	heterogeneity_ratio	0.5470	0.7717	15	0.1348	conservar
9	luma_p95_minus_p05	0.5700	0.7910	265	2.3820	conservar

5 Derivadas

	Variable	Definición
0	heterogeneity_ratio	DE de medias de teselas / DE global; denominad…
1	luma_p95_minus_p05	P95 − P05 de luma digital sRGB normalizada

	Indefinidos	Media	Mediana	DE	P05	P95	Mínimo	Máximo
0	0	0.6527	0.6660	0.1514	0.3811	0.8748	0.1136	0.9745
1	0	0.6647	0.6947	0.1730	0.3254	0.8953	0.0000	1.0000

6 Particiones

	split	Registros	Contenidos_distintos	% registros	% contenidos
0	test	1396	1354	12.5483	12.5336
1	train	8364	8128	75.1820	75.2384
2	validation	1365	1321	12.2697	12.2281

7 MOS por partición

	Partición	n	MOS medio	DE MOS	Uso
0	train	8364	50.3855	20.9365	descriptivo
1	validation	1365	49.5863	20.5998	descriptivo
2	test	1396	NaN	NaN	sellado

8 Prevalencia de escenas (%)

split	train	validation
Animal	1.351	1.3187
Cityscape	28.0966	27.9121
Human	14.5026	13.7729
Indoor scene	10.318	10.6227
Landscape	13.3429	13.7729
Night scene	8.9909	8.1319
Plant	15.9493	15.0916
Still-life	29.7107	31.8681
Others	5.3563	4.9817

9 Codificación train-only

	Control	Resultado
0	Ajuste	solo entrenamiento
1	Categorías aprendidas	76

```
2                              Columnas generadas                  76
3  Filas de validación con categoría desconocida                    0
```

```
10 Regresión
```

```
       Modelo      MAE     RMSE      R²  Sesgo medio     n
0  Dummy mean  17.9645  20.6078 -0.0015       0.7992  1365
1      Linear  12.5055  15.2313  0.4529       0.6037  1365
```

```
11 Ablación
```

```
             Especificación      MAE     RMSE      R²
0     Modelo principal (14)  12.5055  15.2313  0.4529
1  Sin las 2 derivadas (12)  12.5544  15.2717  0.4500
```

```
12 Clasificación
```

```
     Modelo  F1 micro  F1 macro  Precisión micro  Sensibilidad micro  \
0     Dummy    0.0000    0.0000           0.0000              0.0000
1  Logistic    0.4213    0.3936           0.2971              0.7236

   Pérdida de Hamming
0              0.1416
1              0.2816
```

```
13 Escenas
```

```
         Escena  Casos positivos  Precisión  Sensibilidad      F1
0        Animal               18     0.0421        0.8889  0.0804
1     Cityscape              381     0.4433        0.7087  0.5455
2         Human              188     0.2487        0.7713  0.3761
3  Indoor scene              145     0.2505        0.8621  0.3882
4     Landscape              188     0.2970        0.7394  0.4238
5   Night scene              111     0.3855        0.9099  0.5416
6         Plant              206     0.2762        0.6408  0.3860
7    Still-life              435     0.4475        0.6276  0.5225
8        Others               68     0.1667        0.8529  0.2788
```

```
14 Sensibilidad
```

```
                    Modelo Ponderación al evaluar      MAE     RMSE      R²
0              Dummy mean                1/n_SHA  17.9990  20.6350 -0.0013
1                  Linear                1/n_SHA  12.4529  15.1844  0.4578
2  Linear ajuste ponderado               registro  12.5024  15.2332  0.4528
3  Linear ajuste ponderado                1/n_SHA  12.4490  15.1858  0.4577
```

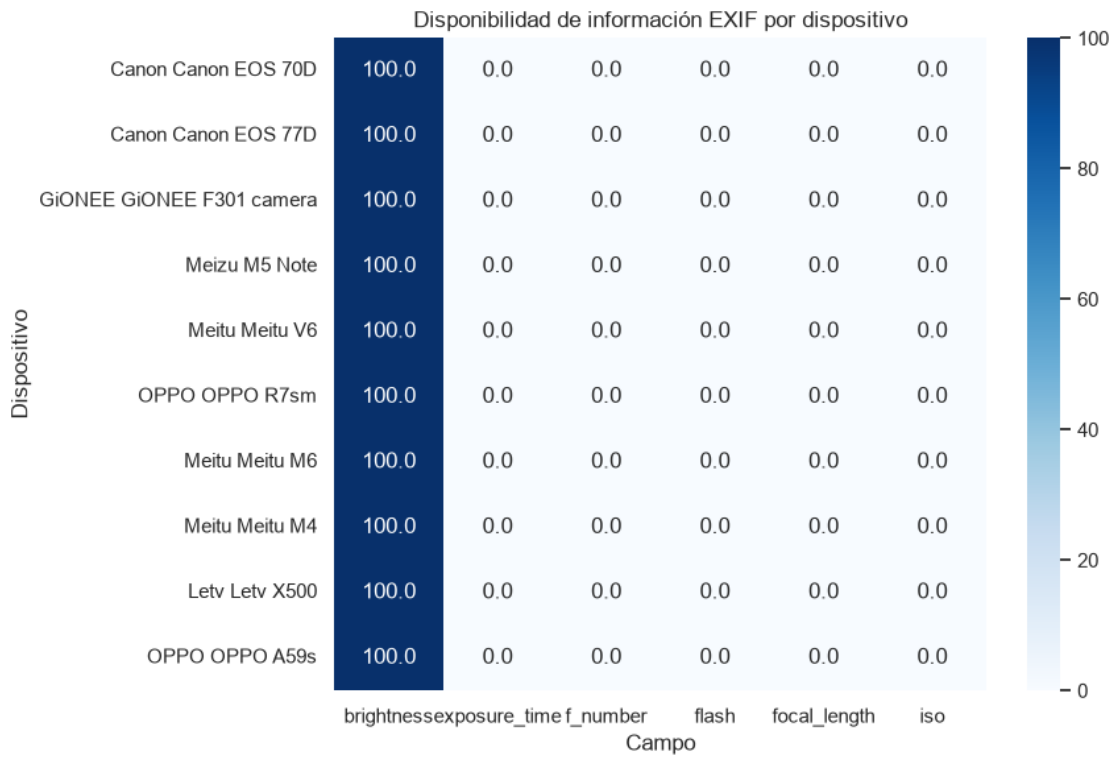
1.5 Cinco figuras del informe

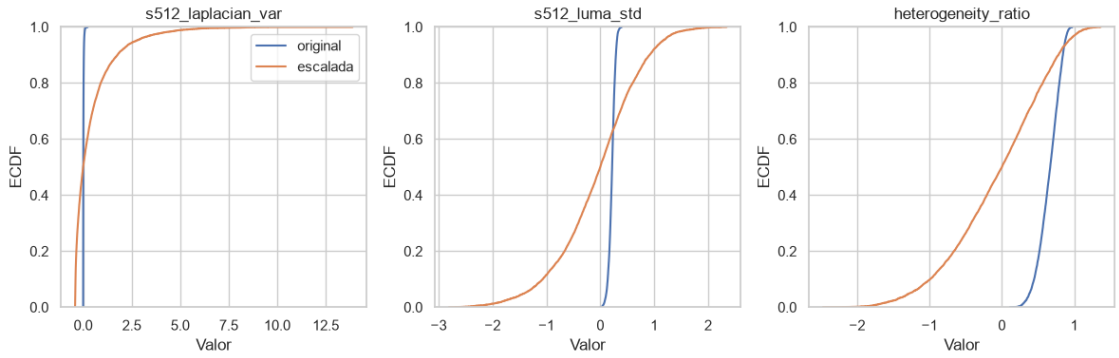
[9]:
```
sns.set_theme(style="whitegrid")
def guardar(fig,nombre):
    fig.tight_layout()
    fig.savefig(SALIDA/nombre,dpi=180)
```

```
    plt.show()

imagenes["device"] = imagenes.make.fillna("Unknown").astype(str)+" "+imagenes.
 ↪model.fillna("Unknown").astype(str)
campos = ["brightness","exposure_time","f_number","flash","focal_length","iso"]
ausencia = imagenes.groupby("device")[campos].agg(lambda x:x.isna().mean()*100).
 ↪sort_values("brightness",ascending=False).head(10)
fig,ax=plt.subplots(figsize=(9,6))
sns.heatmap(ausencia,annot=True,fmt=".1f",cmap="Blues",vmin=0,vmax=100,ax=ax)
ax.set(xlabel="Campo",ylabel="Dispositivo",title="Disponibilidad de información␣
 ↪EXIF por dispositivo")
guardar(fig,"figura_1_exif.png")

transformador = lineal.named_steps["preparar"]
escaladas = transformador.transform(Xtr)
fig,axs=plt.subplots(1,3,figsize=(12,4))
for ax,nombre in␣
 ↪zip(axs,["s512_laplacian_var","s512_luma_std","heterogeneity_ratio"]):
    j=PREDICTORES.index(nombre)
    sns.ecdfplot(Xtr[nombre],ax=ax,label="original")
    sns.ecdfplot(escaladas[:,j],ax=ax,label="escalada")
    ax.set(title=nombre,xlabel="Valor",ylabel="ECDF")
axs[0].legend()
guardar(fig,"figura_2_escalamiento.png")
```

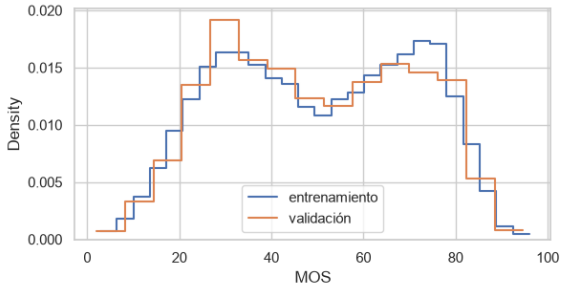


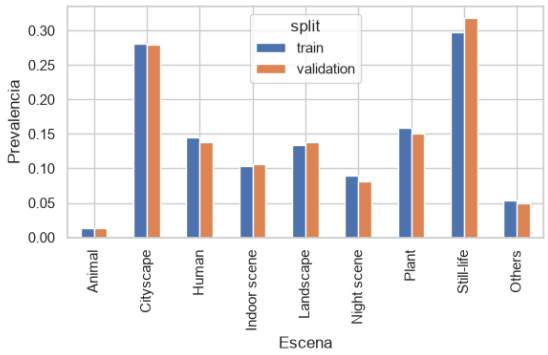


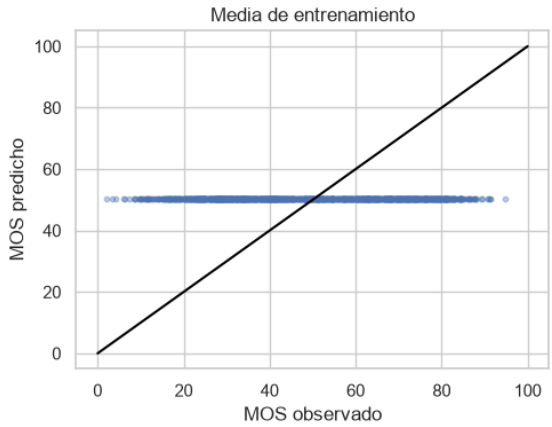
[10]:
```
fig,axs=plt.subplots(1,2,figsize=(12,4))
sns.
 ↪histplot(train,x="MOS",stat="density",element="step",fill=False,ax=axs[0],label="entrenamie
sns.
 ↪histplot(validacion,x="MOS",stat="density",element="step",fill=False,ax=axs[0],label="valid
axs[0].legend()
prevalencias=datos.loc[datos.split.isin(["train","validation"])].
 ↪groupby("split")[[f"target_{e}" for e in ESCENAS]].mean().T
prevalencias.index=ESCENAS
prevalencias.plot.bar(ax=axs[1])
axs[1].set(ylabel="Prevalencia",xlabel="Escena")
guardar(fig,"figura_3_particiones.png")

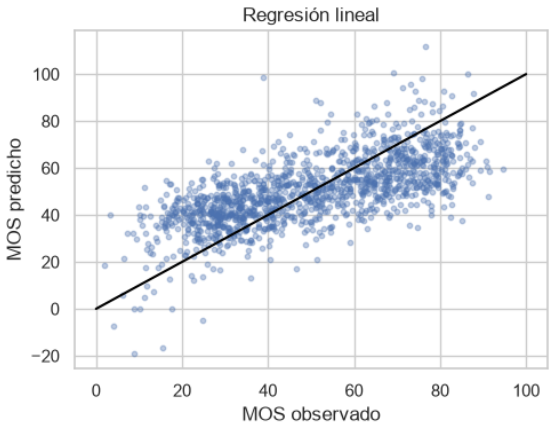
fig,axs=plt.subplots(1,2,figsize=(10,4))
for ax,p,titulo in zip(axs,[pred_dummy,pred_lineal],["Media de␣
 ↪entrenamiento","Regresión lineal"]):
    ax.scatter(yva,p,s=10,alpha=.35)
    ax.plot([0,100],[0,100],color="black")
    ax.set(title=titulo,xlabel="MOS observado",ylabel="MOS predicho")
guardar(fig,"figura_4_predicciones.png")

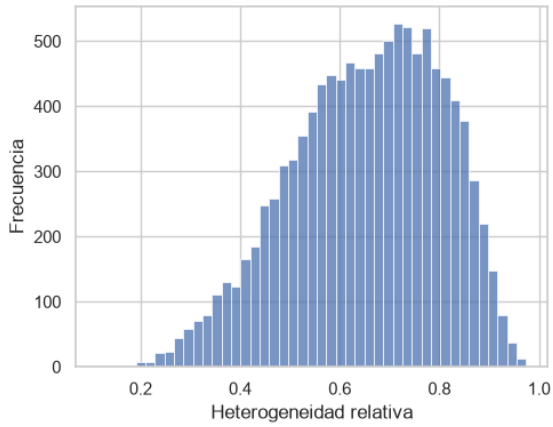
fig,axs=plt.subplots(1,2,figsize=(10,4))
sns.histplot(datos,x="heterogeneity_ratio",bins=45,ax=axs[0])
axs[0].set(xlabel="Heterogeneidad relativa",ylabel="Frecuencia")
sns.histplot(datos,x="luma_p95_minus_p05",bins=45,ax=axs[1])
axs[1].set(xlabel="Contraste P95 - P05 de luma sRGB␣
 ↪normalizada",ylabel="Frecuencia")
guardar(fig,"figura_5_derivadas.png")
```

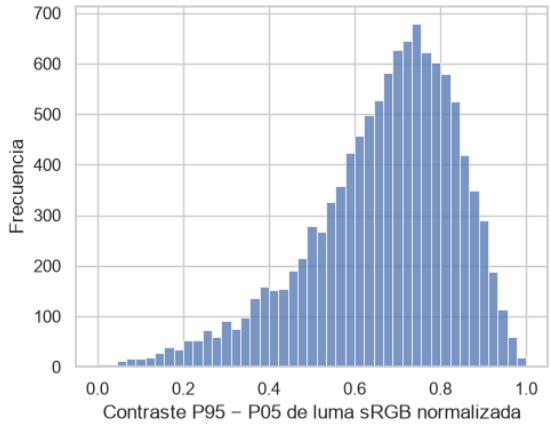

Density
MOS
entrenamiento
validación


split
train
validation
Prevalencia
Escena
Animal
Cityscape
Human
Indoor scene
Landscape
Night scene
Plant
Still-life
Others


Media de entrenamiento
MOS predicho
MOS observado


Regresión lineal
MOS predicho
MOS observado


Frecuencia
Heterogeneidad relativa


Frecuencia
Contraste P95 − P05 de luma sRGB normalizada

Anexo 2

Para facilitar la consulta, se anexa el informe generado en la realización de la primera fase (primera de cuatro) de este proyecto.

Calidad perceptual de fotografías de smartphones

Estudio observacional de las asociaciones entre calificaciones perceptuales humanas, contenido de escena, metadatos de adquisición y descriptores digitales interpretables de fotografías.

Curso: Ciencia de Datos

Actividad: caracterización estadística del conjunto SPAQ

(Smartphone Photography Attribute and Quality)

Alumno: Carlos Mario Garzón

Docente: Fabian Camilo Castro

Maestría en Inteligencia Artificial ·

Universidad de La Salle

Bogotá

28 de octubre de 2026

Resumen

Se analizan 11.125 fotografías del conjunto Smartphone Photography Attribute and Quality (SPAQ) mediante análisis exploratorio de datos (EDA). La calidad perceptual se representa mediante la puntuación media de opinión (Mean Opinion Score, MOS), acompañada de cinco atributos evaluados por personas, nueve pesos de pertenencia a escenas, metadatos Exchangeable Image File Format (EXIF) y 68 descriptores computados sobre fotografías JPEG. Se reconocen 10.803 contenidos únicos mediante huellas criptográficas SHA-256 y 322 parejas de archivos idénticos; 321 parejas tienen MOS diferentes. La asociación de rango más elevada entre un descriptor y MOS corresponde a la varianza del Laplaciano a escala 512 (ρ de Spearman = 0,736); 79 de 2.278 pares de descriptores presentan $|\rho| \geq 0{,}9$. Los resultados describen relaciones estadísticas, redundancia y sensibilidad a la escala, sin establecer causalidad ni rendimiento predictivo fuera de muestra.

1. Introducción

La evaluación de la calidad de fotografías producidas por smartphones combina factores de adquisición, procesamiento de la imagen, contenido visual y juicios humanos. El dataset Smartphone *Photography Attribute and Quality*, **SPAQ**, proporciona un índice de juicio humano, *Mean Opinion Score*, **MOS**, de esta calidad, el cual es un resultado perceptual. Cada imagen digital, por simplicidad llamada JPEG, registra información espacial y cromática resultante de la captura y del procesamiento digital; EXIF describe parcialmente condiciones y dispositivos. Fang et al. (2020) establecieron SPAQ como banco de referencia de calidad perceptual y estudiaron vínculos con contenido y metadatos.

Esta investigación surge, de forma general, al reflexionar sobre qué significa encontrar una asociación entre un descriptor interpretable y MOS cuando las características entre sí pueden ser redundantes, cambian con el tamaño de representación y presentan efectos condicionados por contenidos heterogéneos. Esta reflexión se dificulta al notar que dos archivos JPEG idénticos pueden contener MOS o pesos de escena discrepantes, por ejemplo una partición aleatoria por filas puede contar el mismo contenido tanto en entrenamiento como en prueba. Por tanto, una correlación elevada no implica que una familia aporte información adicional a otras, ni acredita generalización. El alcance empírico aquí es caracterizar esa estructura y sus limitaciones antes de estimar aportes incrementales y rendimiento predictivo en fases posteriores.

Pregunta de investigación. ¿En qué medida las características tonales, cromáticas, espaciales, regionales y multiescala extraídas de fotografías de smartphones, junto con los metadatos de adquisición, permiten caracterizar su asociación con la calidad perceptual MOS (Mean Opinion Score), y cómo varían dichas asociaciones según las escenas y la consistencia de las anotaciones?

Pregunta orientadora 1. ¿Qué asociaciones, redundancias y diferencias entre escalas presentan las familias de descriptores digitales respecto de MOS?

Pregunta orientadora 2. ¿Cómo varían las asociaciones según contenido de escena y condiciones de captura, y qué revelan los archivos idénticos con anotaciones discrepantes?

Pregunta orientadora 3. ¿Qué estructura y limitaciones del espacio de descriptores resultan pertinentes para un estudio posterior de agrupamientos no supervisados?

2. Objetivos

Objetivo general. Caracterizar estadísticamente las relaciones entre descriptores digitales interpretables, metadatos de adquisición, contenido de escena y calidad perceptual MOS en SPAQ, considerando la integridad de sus anotaciones, la redundancia y la sensibilidad multiescala.

El alcance de este objetivo y de los objetivos específicos se verificará mediante los estadísticos, tablas y figuras presentados para el conjunto analizado.

Objetivo específico 1. Describir las distribuciones, la integridad y las asociaciones entre anotaciones humanas, descriptores digitales y metadatos en las 11.125 fotografías, con medidas estadísticas y evidencias visuales verificables.

Objetivo específico 2. Examinar la redundancia entre descriptores y sus variaciones según escala y contenido de escena, explicitando los tamaños muestrales y las limitaciones de interpretación.

Objetivo específico 3. Cuantificar las discrepancias de anotación entre contenidos idénticos y las incidencias de metadatos, delimitando su posible influencia sobre la interpretación y evaluación posterior de los datos.

Alcance temporal y verificación. Los cuatro objetivos se desarrollan con el conjunto de 11.125 observaciones de SPAQ y tienen como fecha de cumplimiento el 28 de octubre de 2026. Su cumplimiento se comprueba mediante estadísticas descriptivas y diagnósticos de integridad presentados en este informe y reproducidos en un cuaderno Jupyter presentado en anexo.

3. Conjunto de datos y variables

Dataset: SPAQ (Smartphone Photography Attribute and Quality).

Fuente académica identificada: Fang et al., “Perceptual Quality Assessment of Smartphone Photography”, CVPR 2020; repositorio de los autores https://github.com/h4nwei/SPAQ.

Fecha de extracción del dataset: 24 de octubre de 2026.

Licencia: MIT.

Las entradas usadas en este análisis son tres libros en formato Excel de Microsoft: MOS and Image attribute scores.xlsx, Scene category labels.xlsx y EXIF_tags.xlsx (dos hojas), además de archivos de las imágenes (en adelante, por simplicidad, denominados JPEG originales, o simplemente JPEG).

La unión por identificador reconcilia 11.125 registros; hay 10.803 contenidos binariamente distintos según SHA-256. Los 68 atributos de píxeles se derivan de las imágenes; su presencia en la tabla analítica no equivale a que formen parte del conjunto de anotaciones humanas original.

3.1. Descripción general del dataset

Se trata de un dataset presentado en el congreso CVPR (Conference on Computer Vision and Pattern Recognition) 2020, https://openaccess.thecvf.com/CVPR2020, con la finalidad académica de evaluar la calidad de fotografías obtenidas con celulares inteligentes tanto a través de factores técnicos de hardware/software como mediante estudios de percepción visual humana.

El conjunto contiene 11125 imágenes en resolución nativa, sin compresión ni reducción del mapa de pixels que afecte sus características nativas. Las fotos en su mayoría tienen resolución nativa de 4000 x 3000 pixeles, y algunas se encuentran con tamaño mínimo full HD (1920x1080). Las imágenes fueron capturadas en 66 teléfonos inteligentes diferentes, de un conjunto de 11 fabricantes.

La calidad de las imágenes recibió una puntuación humana (MOS, en escala de 1 a 10), con múltiples evaluadores por imagen. Para las imágenes se anotaron los siguientes atributos, brillo, colorido, contraste, nivel de ruido y nitidez. Además, las imágenes se clasificaron en nueve tipos de escenas, animal, paisaje urbano, personas, interiores, paisaje natural, escenas nocturnas, plantas, naturaleza muerta y otros. Cada fotografía contiene un set de metadatos exif.

La base maneja cinco atributos principales, brillo, colorido, contraste, nivel de ruido, nitidez (brightness, colorfulness, contrast, noisiness, sharpness).

Incluye un grupo de 1,000 imágenes capturadas exactamente bajo las mismas condiciones visuales intercalando los distintos teléfonos, ideal para comparar el rendimiento de procesamiento de color y algoritmos de una marca contra otra.

Familias de variables y significado estadístico

Lectura estadística del conjunto: 11.125 observaciones corresponden a 11.125 entradas de fotografías; sus bytes representan 10.803 contenidos diferentes según SHA-256, pues existen 322 pares duplicados. La variable respuesta MOS y las cinco valoraciones auxiliares Brightness, Colorfulness, Contrast, Noisiness y Sharpness son juicios humanos numéricos. Las nueve variables de escenas expresan membresías simultáneas, no clases nominales únicas. Los campos EXIF contienen atributos numéricos y categóricos del registro de adquisición; sus ausencias y valores sospechosos requieren diagnósticos separados. A partir de los JPEG se calcularon 68 descriptores de tono, color, estructura espacial y distintas escalas. La tabla analítica integra 153 campos de distintas procedencias, incluidos identificadores y variables de auditoría: no representa 153 predictores. Fuentes de comprobación: diccionario de datos de la sección 3.2, tablas join_cardinality.csv y missing_sentinel_audit.csv y manifiesto SHA-256 del notebook aprobado.

Tabla 1. Familias de variables y cautelas de interpretación. Fuente: cálculos propios sobre las anotaciones e imágenes originales de SPAQ.

Familia	Naturaleza	Interpretación y restricción
MOS	Cuantitativa; juicio humano agregado	Variable dependiente central; no equivale a calidad instrumental medida
Cinco ratings	Cuantitativas; valoraciones humanas	Brightness, Colorfulness, Contrast, Noisiness, Sharpness: análisis descriptivo, excluidas de predictores automáticos
Nueve pesos de escena	Cuantitativas discretizadas por fracciones de membresía	Cada categoría activa recibe 1/c; no son probabilidades de confianza ni clases exclusivas
EXIF	Mixtas; metadata nominal y cuantitativa	Unidades y sentinelas requieren verificación; disponibilidad puede depender de dispositivo
68 descriptores	Cuantitativas derivadas de JPEG	Tonales/cromáticas/espaciales/regionales/multiescala; proxies del resultado digital, no mediciones ópticas calibradas
ID/SHA	Identificadores técnicos	Sirven para unir registros y detectar contenidos repetidos; no predictores

3.2. Diccionario de datos

El diccionario agrupa variables que comparten definición y conserva sus nombres exactos. Los dominios indicados son los definidos por el instrumento o por la operación matemática; donde no hay información suficiente se señala «no documentado». Los identificadores, rutas, códigos de error, campos de integración y registros de trazabilidad se describen en el notebook, pero no son variables científicas adicionales. Se documentan por agrupación las definiciones compartidas, pero cada identificador de descriptor incluido en una agrupación designa una columna distinta de la tabla analítica.

Variable(s)	Tipo estadístico	Descripción funcional	Dominio / valores permitidos
MOS	Cuantitativa continua	Puntuación media de opinión: calidad perceptual evaluada por personas.	0–100 (escala SPAQ)
Brightness; Colorfulness; Contrast; Noisiness; Sharpness	Cuantitativas continuas	Cinco puntuaciones humanas auxiliares: brillo, color, contraste, ruido y nitidez percibidos.	0–100 (escala SPAQ)
Animal; Cityscape; Human; Indoor scene; Landscape; Night scene; Plant; Still-life; Others	Cuantitativas discretas (fracciones)	Nueve pertenencias de escena no exclusivas; una fotografía con c escenas activas aporta 1/c a cada una.	0 o 1/c, con c=1,…,9
Focal length	Cuantitativa continua	Distancia focal declarada en el Excel EXIF.	Milímetros; valores positivos; plausibilidad no verificada
F-number	Cuantitativa continua	Relación de apertura declarada en el Excel EXIF.	Números f positivos; plausibilidad no verificada
Exposure time	Cuantitativa continua	Tiempo de exposición declarado en el Excel EXIF.	Segundos positivos; extremos por verificar
ISO	Cuantitativa discreta	Sensibilidad ISO declarada en el Excel EXIF.	Valores ISO positivos; dominio de exportación no documentado
Brightness (Excel EXIF)	Cuantitativa continua	Brillo codificado en anotaciones EXIF; no equivale a juicio humano.	Dominio no acreditado; el cero no implica ausencia
Aperture value	Cuantitativa continua	Valor de apertura en codificación APEX.	Dominio de exportación no documentado
Time value	Cuantitativa continua	Valor temporal codificado en APEX.	Dominio de exportación no documentado
Sensitivity vaue	Cuantitativa continua	Valor de sensibilidad en la hoja APEX; nombre original preservado.	Dominio de exportación no documentado
Brightness value	Cuantitativa continua	Valor de brillo en codificación APEX.	Dominio de exportación no documentado
Flash (Excel EXIF)	Cualitativa nominal	Código de estado del flash declarado en Excel EXIF.	Códigos originales; equivalencias no documentadas
Time (Excel EXIF)	Cuantitativa continua	Componente temporal codificado; no es una fecha completa.	Dominio de exportación no documentado
Unnamed: 8 (Excel EXIF)	Tipo no verificado	Campo sin encabezado semántico en el Excel original.	Valores originales; dominio y significado no documentados
make; model; datetime; datetime_original	Cualitativas nominales	Fabricante, modelo y fechas de cabeceras EXIF de los JPEG.	Cadenas y fechas disponibles; dominio no documentado
focal_length (JPEG)	Cuantitativa continua	Distancia focal en EXIF nativo del JPEG.	Milímetros positivos o ausente
f_number (JPEG)	Cuantitativa continua	Número f en EXIF nativo del JPEG.	Positivo o ausente
exposure_time (JPEG)	Cuantitativa continua	Exposición en EXIF nativo del JPEG.	Segundos positivos o ausente
iso (JPEG)	Cuantitativa discreta	Sensibilidad en EXIF nativo del JPEG.	ISO positivo o ausente

Variable(s)	Tipo estadístico	Descripción funcional	Dominio / valores permitidos
brightness (JPEG)	Cuantitativa continua	BrightnessValue de EXIF nativo.	Escala EXIF/APEX; validación física pendiente
flash (JPEG)	Cualitativa nominal	Código de flash EXIF nativo.	Código entero de estado o ausente
s512_luma_mean; s256_luma_mean; s128_luma_mean	Cuantitativas continuas	Media de luma sRGB codificada a tres escalas (lado máximo 512, 256 y 128 píxeles).	[0,1]
s512_luma_std; s256_luma_std; s128_luma_std	Cuantitativas continuas	Desviación estándar de luma digital a tres escalas.	[0,0,5]
s512_gradient_mean; s256_gradient_mean; s128_gradient_mean	Cuantitativas continuas	Magnitud media del gradiente Sobel digital en tres escalas.	≥0
s512_laplacian_var; s256_laplacian_var; s128_laplacian_var	Cuantitativas continuas	Varianza de respuesta discreta del Laplaciano, en tres escalas.	≥0
s512_fft_high_fraction; s256_fft_high_fraction; s128_fft_high_fraction	Cuantitativas continuas	Fracción de energía espectral digital en altas frecuencias, a tres escalas.	[0,1]
s512_tile_mean_std; s256_tile_mean_std; s128_tile_mean_std	Cuantitativas continuas	Variación entre medias de bloques espaciales en tres escalas.	[0,0,5]
s512_entropy; s256_entropy; s128_entropy	Cuantitativas continuas	Entropía de histograma de luma digital en tres escalas.	[0,8] bits
analysis_width; analysis_height	Cuantitativas discretas	Dimensiones reales de la representación analizada.	Enteros positivos, píxeles
luma_median; luma_min; luma_max; luma_range; luma_skew; luma_p01; luma_p05; luma_p25; luma_p75; luma_p95; luma_p99	Cuantitativas continuas	Localización, amplitud, asimetría y percentiles de luma codificada.	[0,1], salvo luma_skew: real
near_black_01; near_black_05; near_black_10; near_white_245; near_white_250; near_white_254; channel_clip_245; channel_clip_250; channel_clip_254	Cuantitativas continuas	Proporciones de píxeles oscuros, claros o canales cercanos a saturación, según umbrales indicados.	[0,1]
gradient_p95; neighbor_absdiff; tile_gradient_cv	Cuantitativas continuas	Percentil de gradientes, diferencia local absoluta y variabilidad regional de gradientes.	≥0 (neighbor_absdiff en [0,1])
tile_dark_fraction; tile_bright_fraction; tile_entropy_mean; tile_entropy_std	Cuantitativas continuas	Proporciones de regiones oscuras/claras y estadísticos regionales de entropía.	Fracciones [0,1]; entropía en bits
fft_centroid; lbp_entropy	Cuantitativas continuas	Centroide espectral en frecuencia digital y entropía de patrones binarios locales.	≥0; límites definidos por implementación
hsv_s_mean; hsv_s_std; hsv_v_mean	Cuantitativas continuas	Estadísticos de saturación HSV y media de valor HSV.	[0,1]; desviación ≤0,5
rgb_r_mean; rgb_g_mean; rgb_b_mean; rgb_r_minus_g; rgb_b_minus_g	Cuantitativas continuas	Promedios de canales RGB codificados y diferencias medias entre canales.	Medias [0,1]; diferencias [−1,1]
lab_l_mean; lab_a_mean; lab_b_mean; lab_chroma_mean; lab_chroma_std; tile_chroma_std	Cuantitativas continuas	Estadísticos de color CIELAB y croma, global y por regiones.	L* [0,100]; a*,b* aproximadamente [−128,128]; croma ≥0
color_entropy; tile_color_entropy_std	Cuantitativas continuas	Entropía cromática RGB y dispersión de entropía entre regiones.	Entropía [0,9] bits; dispersión ≥0

4. Metodología

Se integraron por identificador las calificaciones perceptuales, las pertenencias de escena y dos hojas de metadatos EXIF del conjunto SPAQ. Cada archivo JPEG fue decodificado y su contenido comprobado mediante un resumen SHA-256, algoritmo criptográfico que permite detectar archivos idénticos byte a byte. Se calcularon 68 descriptores tonales, cromáticos, espaciales, regionales y multiescala, incluyendo estadísticas sobre canales sRGB y medidas digitales de gradientes y frecuencias. La exploración comprendió medidas de tendencia central y dispersión, cuantiles, detección de valores extremos mediante intervalo intercuartílico (IQR) y puntuaciones z, correlaciones de Pearson y Spearman, comparación ponderada entre escenas y prueba χ^2 sobre completitud de metadatos.

La unidad tabular corresponde a una fotografía anotada. La identidad de contenido se examinó por separado para distinguir observaciones distintas de archivos JPEG con bytes idénticos. Los valores extremos y potenciales códigos centinela se señalaron para revisión sin alterar las observaciones originales. Las asociaciones se interpretan como propiedades descriptivas del conjunto de datos y no como estimaciones de efecto causal.

El cálculo de correlaciones es exploratorio. Pearson resume asociación lineal y Spearman asociación monótona sobre rangos; los empates y la dependencia de filas por duplicación restringen el alcance de p nominales incluso con corrección BH. Los análisis de escenas utilizan pesos originales y soporte efectivo, no una asignación arbitraria por argmax. Los criterios IQR y $|z|>3$ identifican candidatos de inspección; no implican eliminación automática ni juicio de error. La prueba χ^2 se aplica solamente a categorías discretas justificadas (modelos agrupados por frecuencia y completitud binaria EXIF).

5. Distribución de MOS, valores ausentes y extremos

En las 11.125 fotografías, la puntuación media de opinión (MOS) tiene media 50,32, mediana 50,20, desviación estándar 20,90 y valores entre 2 y 96. La Figura 1 y la Tabla 2 muestran una distribución amplia y permiten compararla con las cinco evaluaciones humanas auxiliares. La cercanía entre media y mediana no basta para afirmar normalidad.

Las valoraciones de brillo (media 56,00), colorido (60,45) y contraste (57,28) describen dimensiones perceptuales diferentes. No son mediciones físicas ni deben emplearse como entradas de un predictor automático de MOS.

La asimetría y la curtosis, calculadas en las tablas siguientes, complementan la descripción de las distribuciones:

Puntuación humana	Asimetría	Curtosis (exceso)	N
mos	-0.048	-1.142	11125
brightness	-0.505	-0.091	11125
colorfulness	-0.528	0.079	11125
contrast	-0.405	-0.217	11125
noisiness	-0.102	-0.845	11125
sharpness	-0.027	-1.378	11125

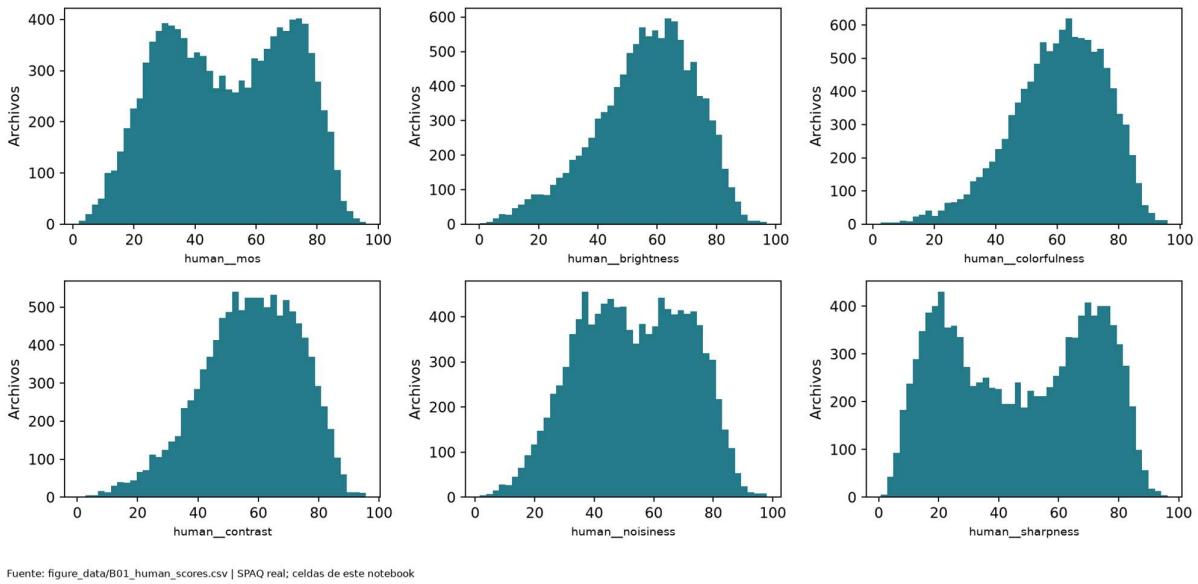


Figura 1. MOS y cinco evaluaciones humanas. Todas las observaciones; las cinco escalas auxiliares son anotaciones humanas. Fuente: cálculos propios sobre SPAQ.

Tabla 2. Distribución de MOS y puntuaciones humanas. Fuente: cálculos propios sobre las anotaciones e imágenes originales de SPAQ.

column	N_valid	mean	median	sd_ddof1	P25	P75
human__mos	11125	50.3179	50.2000	20.9023	32.4600	68.8200
human__brightness	11125	56.0046	57.6000	16.8149	45.5700	68.3000
human__colorfulness	11125	60.4545	61.8600	15.3254	50.6700	72.0000
human__contrast	11125	57.2844	58.3300	16.2383	46.6300	69.8000
human__noisiness	11125	52.9997	53.0000	18.3707	38.4300	68.2700
human__sharpness	11125	47.0470	47.5000	24.2272	24.1400	69.3800
scene__animal	11125	0.0101	0.0000	0.0924	0.0000	0.0000

El análisis distingue valores ausentes, extremos y posibles códigos especiales. Por ejemplo, 7.585 registros tienen Brightness EXIF igual a cero; sin evidencia adicional, ese valor no debe tratarse automáticamente como ausencia. También se examinaron los tiempos de exposición y sus unidades.

Los valores extremos se identificaron mediante la regla de 1,5 veces el intervalo intercuartílico y $|z| > 3$; se señalaron para revisión, sin eliminarlos.

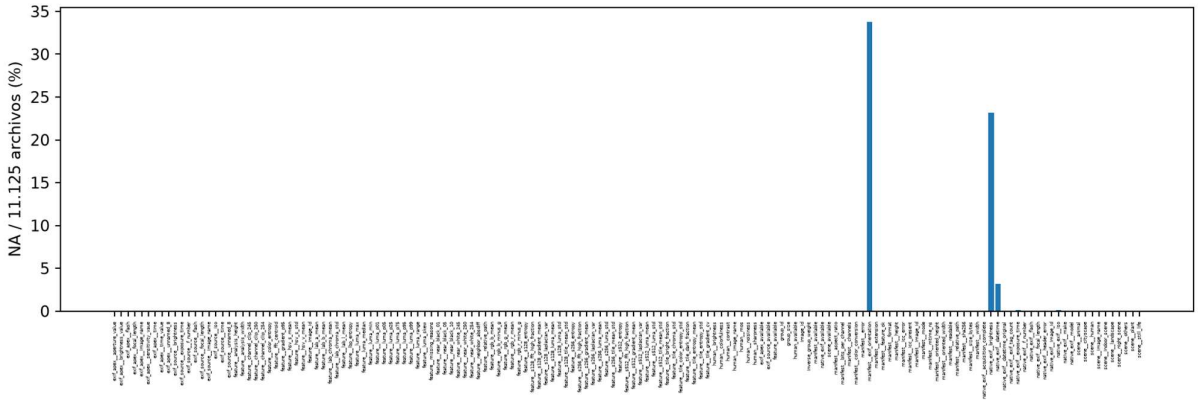
Variable	Fuera de 1,5 IQR	%	$\|z\| > 3$
mos	0	0.00%	0
brightness	102	0.92%	19
colorfulness	119	1.07%	52
contrast	53	0.48%	24
noisiness	0	0.00%	0
sharpness	0	0.00%	0

La tabla siguiente resume los campos con ausencias explícitas (N=11.125). Los porcentajes restantes y los valores sospechosos se conservan en las tablas de resultados del notebook.

Variable	N ausentes	% ausente
manifest__exif_orientation	3758	33.7798%
native_exif__datetime	354	3.1820%
native_exif__datetime_original	6	0.0539%
native_exif__f_number	5	0.0449%
native_exif__exposure_time	13	0.1169%
native_exif__iso	12	0.1079%
native_exif__brightness	2579	23.1820%
native_exif__flash	10	0.0899%

También se calcularon frecuencias absolutas y relativas de variables categóricas, como fabricante, completitud de adquisición y perfil de color.

Campo	Categoría	Frecuencia	Porcentaje
make	HUAWEI	3086	27.74%
make	Apple	2063	18.54%
make	vivo	1369	12.31%
acquisition_complete	True	8545	76.81%
acquisition_complete	False	2580	23.19%
icc_present	False	10771	96.82%
icc_present	True	354	3.18%



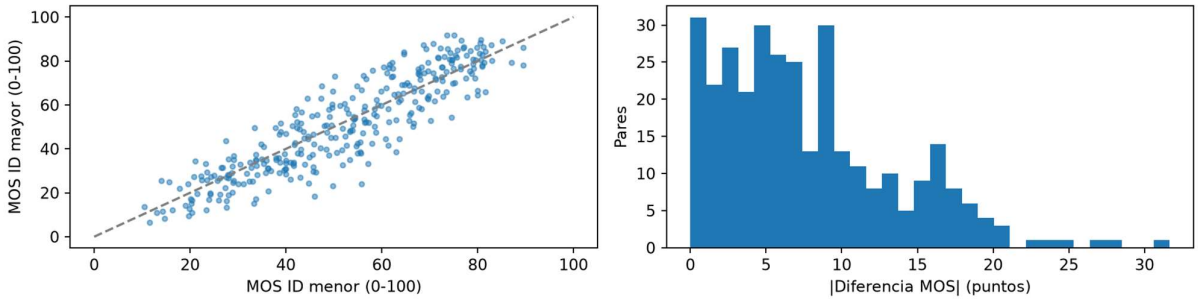
Fuente: data_dictionary.csv | SPAQ real; celdas de este notebook

Figura 2. Ausencia por variable. Se distinguen ausencias reconocidas de ceros o sentinelas candidatos; no se imputan datos en el estudio. Fuente: cálculos propios sobre SPAQ.

Se identificaron 76 cadenas de modelo de dispositivo, 2.580 registros con información de adquisición incompleta y 11 etiquetas de modelo que requieren comprobación. Estas incidencias no invalidan por sí solas las fotografías.

6. Identidad de contenido y consistencia de las anotaciones

Entre las 11.125 observaciones hay 10.803 contenidos únicos según SHA-256: se encontraron 322 pares de JPEG idénticos. En 321 pares difiere MOS (diferencia absoluta mediana de 6,575 y máxima de 31,66 puntos), y en 98 difieren las escenas anotadas. La identidad del archivo no garantiza, por tanto, que coincidan sus etiquetas (Figura 3). No es posible establecer aquí la causa de esas diferencias.



Fuente: eda_tables/duplicate_mos_disagreement.csv | SPAQ real; celdas de este notebook

Figura 3. Desacuerdo MOS en contenidos idénticos. Diferencias entre etiquetas en 322 pares de contenidos binariamente idénticos, no diferencias en píxeles. Fuente: cálculos propios sobre SPAQ.

Estos duplicados deben mantenerse en el mismo grupo cuando se dividan los datos para evaluar modelos. Las correlaciones también pueden variar según cómo se ponderen los contenidos repetidos; las puntuaciones discordantes no se promedian automáticamente.

7. Heterogeneidad del contenido de escena

Las nueve categorías de escena no son excluyentes. Si una fotografía pertenece a c categorías, aporta un peso 1/c a cada una. En 2.771 imágenes existe empate en el peso máximo, por lo que no se puede asignar una clase única sin una regla adicional. La Tabla 3 resume la distribución y los pesos por escena.

Las medias de MOS por escena describen grupos que se superponen. Su interpretación debe considerar el número de fotografías y los pesos de cada categoría; las diferencias observadas no prueban un efecto causal de la escena.

Tabla 3. Distribución y peso de categorías de escena. Fuente: cálculos propios sobre las anotaciones e imágenes originales de SPAQ.

scene	N_positive	weight_sum	kish_n_eff	MOS_weighted_mean
scene__animal	146	112.0000	130.6667	60.1889
scene__cityscape	3114	2331.7833	2784.2021	54.0828
scene__human	1589	1079.9500	1388.1357	53.3639
scene__indoor_scene	1150	798.9500	998.5169	47.3446
scene__landscape	1488	1216.0000	1360.3091	58.1156
scene__night_scene	969	806.8667	889.7808	37.9531
scene__plant	1776	1359.6666	1586.2183	52.9180
scene__still_life	3347	2910.1666	3128.5172	50.8605
scene__others	581	509.6167	544.9495	20.0633

La asociación entre un descriptor y MOS puede variar de una escena a otra. Este resultado aconseja comprobar posteriormente la estabilidad de los modelos entre tipos de contenido, especialmente cuando hay pocos ejemplos.

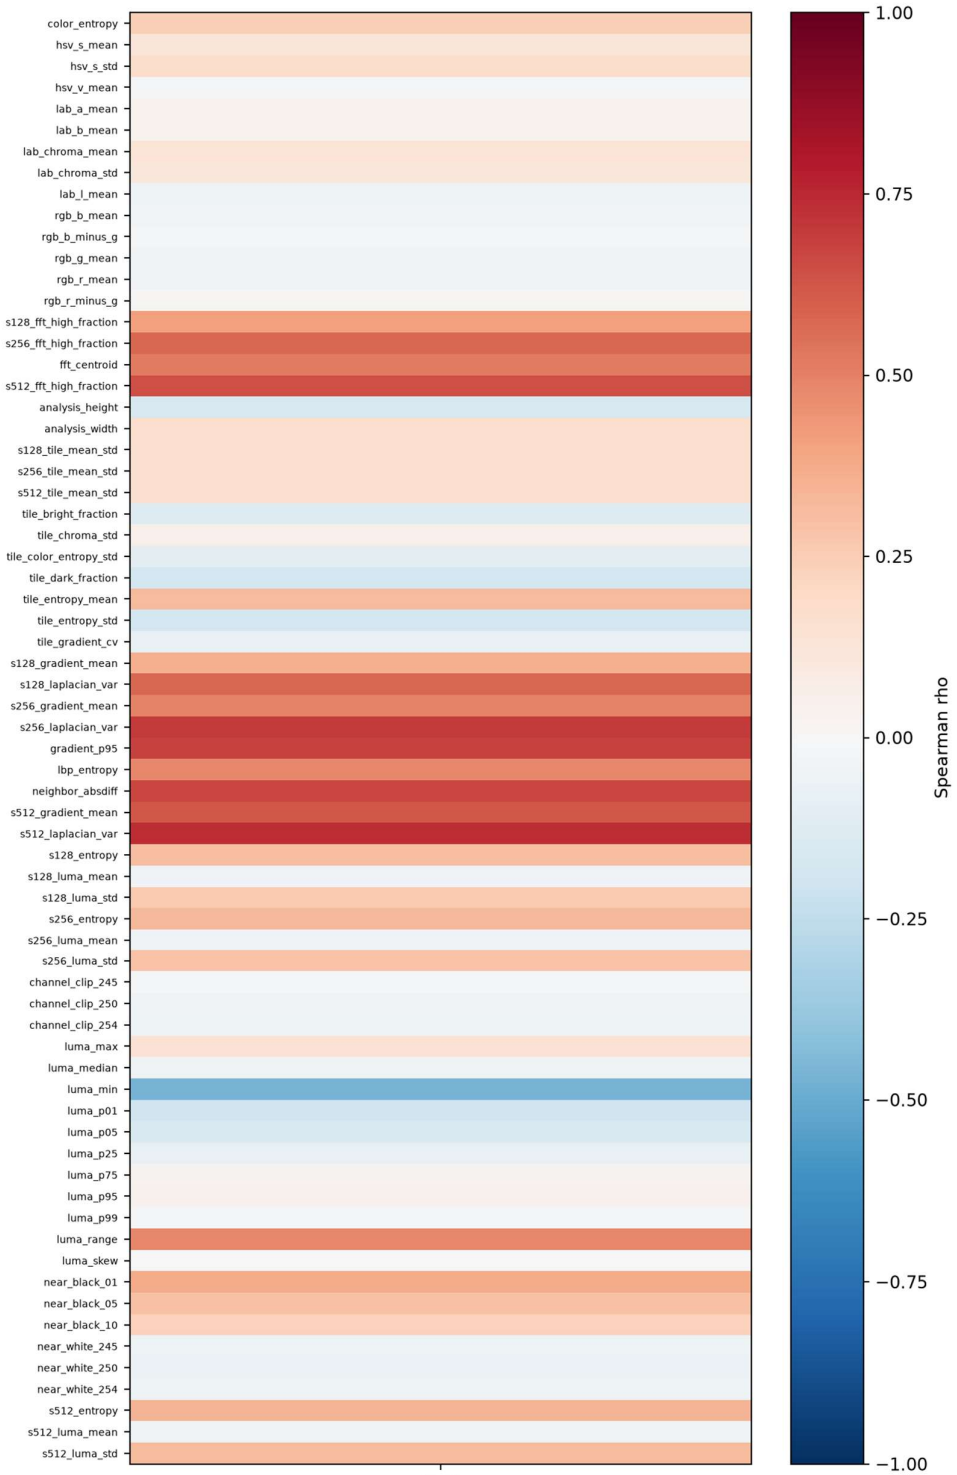
8. Relaciones entre MOS, descriptores y escalas

De los 68 descriptores, “s512_laplacian_var” presenta la mayor correlación de Spearman con MOS (ρ=0,735819; Pearson r=0,522371; N=11.125). En estas fotografías, valores mayores de este descriptor tienden a corresponder a calificaciones más altas (Tabla 4; Figuras 4–5). Sin embargo, el Laplaciano responde también a textura, contraste y ruido, y no mide por sí solo la resolución óptica.

La diferencia entre Spearman y Pearson sugiere que la relación no se resume bien mediante una recta. Las dispersiones muestran variabilidad de MOS para valores semejantes del descriptor. Por tanto, la correlación observada no equivale a capacidad predictiva demostrada.

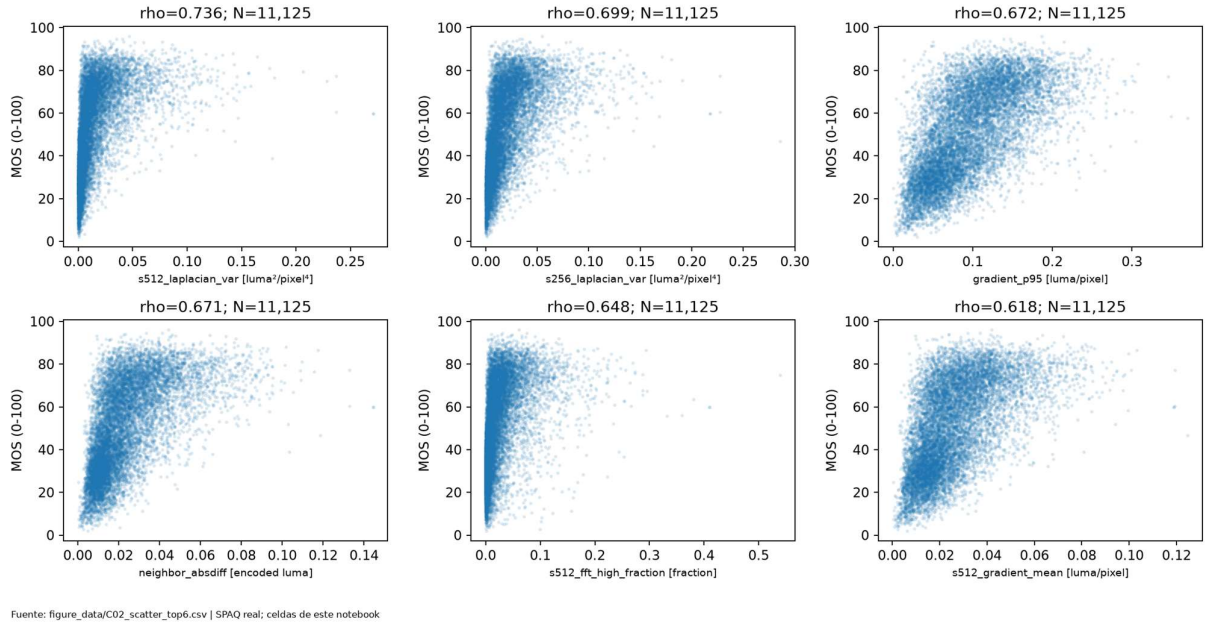
Tabla 4. Correlaciones entre MOS y descriptores digitales. Fuente: cálculos propios sobre las anotaciones e imágenes originales de SPAQ.

original_name	family	pearson_r	spearman_rho	n_valid
s512_laplacian_var	spatial_texture	0.5224	0.7358	11125
s256_laplacian_var	spatial_texture	0.5450	0.6985	11125
gradient_p95	spatial_texture	0.6440	0.6724	11125
neighbor_absdiff	spatial_texture	0.5927	0.6714	11125
s512_fft_high_fraction	frequency	0.4521	0.6483	11125
s512_gradient_mean	spatial_texture	0.5765	0.6183	11125
s256_fft_high_fraction	frequency	0.4344	0.5775	11125
s128_laplacian_var	spatial_texture	0.4945	0.5766	11125



Fuente: eda_tables/feature_mos_correlations.csv | SPAQ real; celdas de este notebook

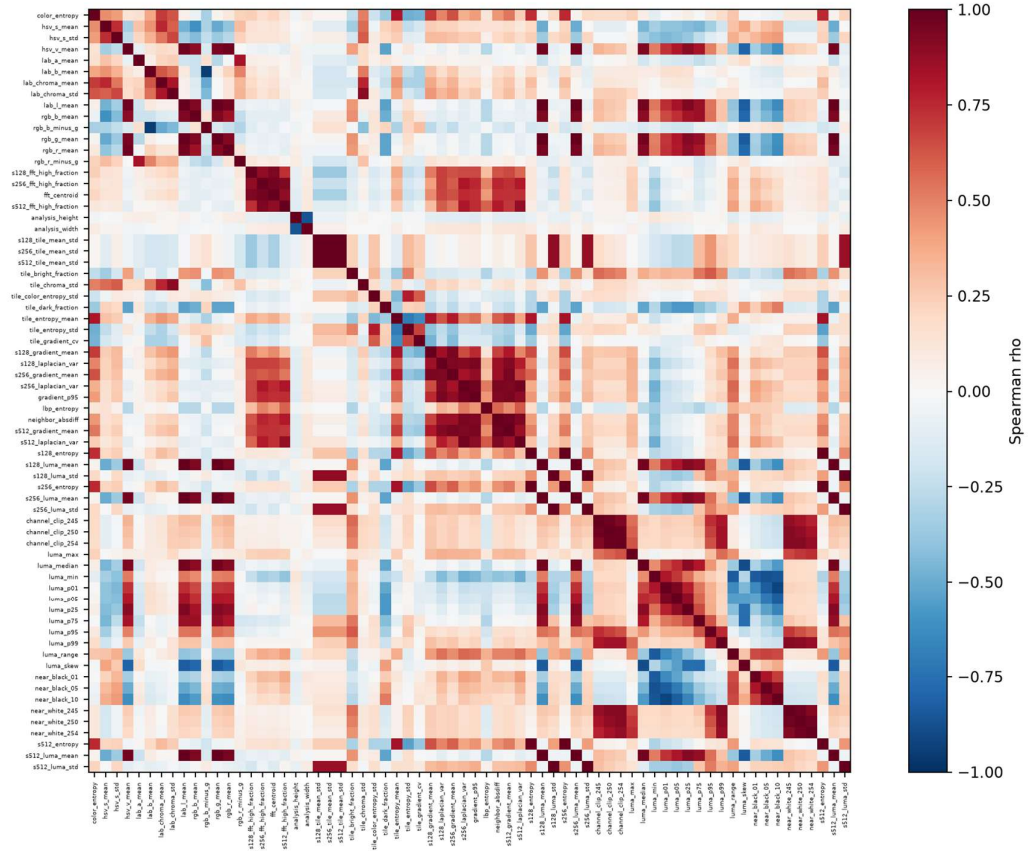
Figura 4. Correlaciones de 68 descriptores con MOS. Magnitud y signo son asociaciones marginales; pruebas nominales requieren cautela ante datos repetidos. Fuente: cálculos propios sobre SPAQ.



Fuente: figure_data/C02_scatter_top6.csv | SPAQ real; celdas de este notebook

Figura 5. Dispersión de asociaciones destacadas. Se observan relaciones bivariadas sin controlar covariables ni medir capacidad predictiva. Fuente: cálculos propios sobre SPAQ.

Entre los 68 descriptores se hallaron 79 pares con |ρ|≥0,9, de 2.278 posibles (Figura 6). Esta redundancia aconseja estudiar la colinealidad y comparar familias de características, pero no significa que deban eliminarse 79 variables.



Fuente: eda_tables/feature_spearman_matrix.csv | SPAQ real; celdas de este notebook

Figura 6. Redundancia dentro del espacio de descriptores. Agrupamientos por correlación pueden orientar selección futura, sin borrado automático de columnas en este análisis. Fuente: cálculos propios sobre SPAQ.

Las comparaciones entre escalas muestran comportamientos distintos: la media de luma mantiene casi el mismo orden de imágenes, mientras que algunos descriptores de gradiente y frecuencia cambian más. Para `fft_high_fraction`, la correlación entre 512 y 128 píxeles es ρ=0,728625 (Tabla 5).

La escala de análisis influye en la información que resume cada descriptor. Por eso conviene evaluar distintas resoluciones antes de seleccionar variables; estos resultados aún no identifican una escala óptima.

Tabla 5. Consistencia de los descriptores entre escalas. Fuente: cálculos propios sobre las anotaciones e imágenes originales de SPAQ.

definition	scale_a	scale_b	spearman_between_scales	MOS_spearman_a	MOS_spearman_b
luma_mean	512	256	1.0000	-0.0374	-0.0374
luma_mean	512	128	1.0000	-0.0374	-0.0373
luma_mean	256	128	1.0000	-0.0374	-0.0373
luma_std	512	256	0.9985	0.3141	0.2881
luma_std	512	128	0.9935	0.3141	0.2582
luma_std	256	128	0.9981	0.2881	0.2582
gradient_mean	512	256	0.9472	0.6183	0.4952

9. Completitud de EXIF y asociación con modelo de dispositivo

La prueba χ^2 comparó el modelo de dispositivo con la completitud de los metadatos EXIF. Se obtuvo χ^2=10.599,0552, con 48 grados de libertad y V de Cramér=0,9761 (Tabla 6), lo que indica una asociación muy fuerte entre ambas variables. Las frecuencias esperadas cumplen los criterios examinados. Este resultado se refiere a disponibilidad de metadatos, no a calidad perceptual.

Tabla 6. Independencia entre dispositivo y completitud EXIF. Fuente: cálculos propios sobre las anotaciones e imágenes originales de SPAQ.

choice	N	chi2	df	cramers_V	expected_min	percent_expected_lt5
all_observations	11125	10599.0552	48	0.9761	12.7551	0.0000
lexicographic_first_ID	10803	10286.1025	48	0.9758	10.5262	0.0000
lexicographic_last_ID	10803	10286.1025	48	0.9758	10.5262	0.0000

10. Discusión

10.1. Asociaciones, redundancia y escala

La asociación más alta con MOS corresponde a la varianza del Laplaciano a escala 512 (ρ=0,735819). También se observaron 79 pares de descriptores muy correlacionados y diferencias de estabilidad entre escalas. En conjunto, estos resultados muestran que las características comparten información, pero no permiten medir todavía su contribución predictiva independiente.

10.2. Escenas y fiabilidad de las anotaciones

Los pesos de escena describen pertenencias simultáneas, por lo que las comparaciones entre escenas son descriptivas y no identifican efectos causales. Las diferencias entre calificaciones de archivos idénticos añaden una fuente de incertidumbre que debe considerarse al evaluar modelos.

10.3. Estructura de variables para análisis no supervisado

Los 68 descriptores ofrecen una base para explorar agrupamientos de fotografías. Antes de interpretarlos habrá que examinar su redundancia y estandarización.

11. Conclusiones

1. La calidad perceptual MOS presenta asociaciones destacadas con descriptores de estructura espacial, especialmente la varianza del Laplaciano a escala 512 (ρ de Spearman = 0,735819). Se trata de asociaciones descriptivas, no de pruebas de causalidad ni de capacidad predictiva.

2. Se identificaron 79 pares de descriptores con $|\rho| \geq 0{,}9$, así como diferencias entre escalas y contenidos de escena. Estos hallazgos muestran redundancia y heterogeneidad que deben considerarse al estudiar el aporte complementario de las variables.

3. Entre los 322 pares de fotografías con contenido idéntico, 321 presentan puntuaciones MOS distintas. Esta discordancia exige controlar las duplicaciones y la consistencia de las anotaciones en futuras evaluaciones, evitando separar copias idénticas entre entrenamiento y prueba.

Referencias

Fang, Y., Zhu, H., Zeng, Y., Ma, K., & Wang, Z. (2020). Perceptual Quality Assessment of Smartphone Photography. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 3677–3686. https://doi.org/10.1109/CVPR42600.2020.00373

Fang et al. SPAQ, repositorio de los autores: https://github.com/h4nwei/SPAQ (consulta documentada en la auditoría técnica: 25 de octubre de 2026; licencia MIT declarada por el responsable del repositorio el 20 de septiembre de 2023).

NIST/SEMATECH. e-Handbook of Statistical Methods, sección sobre detección de valores atípicos: https://www.itl.nist.gov/div898/handbook/eda/section3/eda35h.htm

SciPy. Documentación de scipy.stats.chi2_contingency: https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.chi2_contingency.html

Anexo

Se anexa el script Python usado para este análisis, implementado en un cuaderno Jupyter. El script puede ser descargado desde

https://drive.google.com/file/d/1cOJfqhldWYkU-fvXCWow-FJZBRaCkfh2/view?usp=sharing